



**Escuela Técnica Superior de Ingeniería
Universidad de Huelva**

Máster en Ingeniería Informática

Trabajo Fin de Máster

*DeepSexist: Detección y Categorización de Mensajes
Sexistas en Vídeos Cortos Mediante Deep Learning*

Adrián Moreno Monterde
septiembre, 2026

*A mi abuelo, mi estrella favorita en el cielo.
Tal y como te prometí, cada uno de mis éxitos sigue siendo tuyo.*

Resumen

La proliferación de las redes sociales basadas en vídeos cortos, como *TikTok*, ha traído consigo un aumento exponencial del discurso de odio y la misoginia en entornos digitales. La detección automática de este contenido es un desafío crítico, ya que el sexismo rara vez se manifiesta de forma explícita porque a menudo se oculta tras el sarcasmo, los estereotipos o el contexto visual de la escena. Este Trabajo de Fin de Máster aborda el problema proponiendo un sistema de clasificación multimodal avanzado, diseñado y evaluado bajo el marco de la competición oficial *EXIST 2025*.

A nivel metodológico, la investigación abandona el enfoque clásico unimodal basado únicamente en el texto. Se extraen y procesan las tres dimensiones fundamentales del contenido multimedia: el discurso verbal (transcripción), la disposición espacial (imágenes estáticas) y el movimiento a lo largo del tiempo (secuencia de vídeo). Para ello, se entrenan arquitecturas de estado del arte de forma independiente, aplicando técnicas de *Fine-Tuning* y cuantización (*QLoRA*) sobre modelos discriminativos (*RoBERTa*), modelos de lenguaje generativos masivos (*Mistral-7B*), y arquitecturas de visión (*ConvNeXt* y *TimeSFormer*). Las predicciones de los mejores modelos expertos se unifican posteriormente mediante una estrategia de fusión tardía (*Late Fusion*). Además, la investigación explora el paradigma del Perspectivismo (*Learning with Disagreement*), modelando cómo la identidad de género del anotador afecta matemáticamente a la definición de sexismo.

Los resultados empíricos sugieren una clara ventaja de la arquitectura híbrida frente a los enfoques aislados, logrando un *F1-Score* de 0.7261 sobre un subconjunto de prueba local utilizado para la calibración. Al ser evaluado de forma independiente frente al conjunto ciego de la competición, el sistema alcanzó un *F1-Score* final de 0.6311, reforzando la viabilidad de la propuesta multimodal. El análisis multietiqueta indica que el texto destaca como una modalidad efectiva para detectar sesgos ideológicos, mientras que la visión temporal resulta de gran utilidad para identificar dinámicas físicas como la cosificación. No obstante, se identifican limitaciones relevantes ligadas al fuerte desbalance de clases y al ruido derivado de la extracción automática de texto, lo que subraya el carácter de estos resultados. Finalmente, los experimentos de perspectivismo respaldan la hipótesis de que el género condiciona la detección del discurso de odio, indicando que la anotación femenina genera fronteras de decisión más robustas para el aprendizaje de los modelos, sentando un precedente valioso para la moderación objetiva en plataformas digitales.

Palabras clave: Inteligencia Artificial, Aprendizaje Profundo, Procesamiento del Lenguaje Natural, Visión Artificial, Multimodalidad, Análisis del Discurso de Odio, Sexismo, Transformers, LLM, Perspectivismo.

Abstract

The proliferation of short-video social networks, such as *TikTok*, has led to an exponential increase in hate speech and misogyny in digital environments. The automatic detection of this content is a critical challenge, as sexism rarely manifests itself explicitly, because it often hides behind sarcasm, stereotypes, or the visual context of the scene. This Master's Thesis addresses the problem by proposing an advanced multimodal classification system, designed and evaluated under the framework of the official *EXIST 2025* competition.

Methodologically, the research moves away from the classic unimodal approach based only on text. The three fundamental dimensions of multimedia content are extracted and processed: verbal discourse (transcription), spatial arrangement (static images), and movement over time (video sequences). To this end, state-of-the-art architectures are trained independently, applying *Fine-Tuning* and quantization (*QLoRA*) techniques on discriminative models (*RoBERTa*), massive generative language models (*Mistral-7B*), and vision architectures (*ConvNeXt* and *TimeSFormer*). The predictions of the best expert models are subsequently unified using a *Late Fusion* strategy. Furthermore, the research explores the Perspectivism paradigm (*Learning with Disagreement*), modeling how the gender identity of the annotator mathematically affects the definition of sexism.

Empirical results suggest a clear advantage of the hybrid architecture over isolated approaches, achieving an *F1-Score* of 0.7261 on a local test subset used for calibration. When evaluated independently against the competition's blind test set, the system achieved a final *F1-Score* of 0.6311, supporting the viability of the multimodal proposal. Multi-label analysis indicates that text stands out as an effective modality for detecting ideological biases, while temporal vision proves highly valuable for identifying physical dynamics such as objectification. However, relevant limitations are identified regarding severe class imbalance and noise from automatic text extraction, highlighting the nature of these results. Finally, perspectivism experiments support the hypothesis that gender conditions the detection of hate speech, suggesting that female annotation generates more robust decision boundaries for model learning, setting a valuable precedent for objective moderation on digital platforms.

Keywords: Artificial Intelligence, Deep Learning, Natural Language Processing, Computer Vision, Multimodality, Hate Speech Analysis, Sexism, Transformers, LLM, Perspectivism.

Agradecimientos

La culminación de este Trabajo de Fin de Máster representa el final de una etapa llena de retos, aprendizajes y superación personal. Sin embargo, este logro no es únicamente el resultado de horas de investigación y código, sino también del apoyo de quienes me han acompañado en el camino.

En primer lugar, quiero expresar mi más sincero agradecimiento a mi tutor, Jacinto. Gracias por tu guía, por tu paciencia y por brindarme la orientación necesaria para llevar este proyecto por buen camino. Tu supervisión ha sido un pilar fundamental para dar forma a todas las ideas de esta investigación.

A mi madre, gracias por ser mi mayor refugio y por apoyarme incondicionalmente en cada paso que doy. Tu respaldo silencioso y tu confianza en mí son el motor que me impulsa a seguir adelante y a apuntar cada vez más alto. Este éxito es tan mío como tuyo.

Por último, me van a permitir que me dedique unas líneas a mí mismo. Quiero agradecerme no haberme rendido. Por mantener la disciplina cuando todo era caos, por tener la fuerza de levantarme tras cada caída, y por la constancia de superar mis propios límites cada día. Prometí que lograría lo que me propusiera, y este trabajo es la prueba de que, con perseverancia, todo esfuerzo tiene su recompensa.

Adrián Moreno Monterde
Huelva, 2026

Índice general

Resumen	II
Abstract	III
Agradecimientos	IV
Índice de Figuras	VII
Índice de Tablas	VIII
1. Introducción	1
1.1. Motivación	1
1.2. Objetivos	2
1.3. Competencias	3
1.4. Estructura de la Memoria	4
2. Marco Teórico	5
2.1. Aprendizaje Automático	5
2.2. Clasificación de textos, imágenes y vídeos	6
2.3. Aprendizaje Profundo	8
2.3.1. Epochs y tamaño de lote	9
2.3.2. Tasa de aprendizaje y <i>weight decay</i>	10
2.3.3. Función de pérdida	11
2.3.4. Overfitting y técnicas de regularización	11
2.3.5. Early stopping y validación	12
2.4. Procesamiento del Lenguaje Natural	13
2.4.1. Preprocesamiento del texto	14
2.4.2. Representación del texto	14
2.4.3. Clasificación de texto en PLN	15
2.5. Modelos Avanzados para Texto	16
2.5.1. Transformers	16
2.5.2. Modelos Generativos de Lenguaje (<i>LLMs</i>)	19
2.6. Modelos Avanzados para Visión Estática (Imágenes)	21
2.6.1. <i>Vision Transformers</i> (<i>ViT</i>) y variantes jerárquicas	21
2.6.2. Redes Neuronales Convolucionales Modernas (<i>ConvNeXt</i>)	23
2.6.3. Agregación temporal para clasificación de vídeo	23
2.7. Modelos Avanzados para Visión Temporal (Vídeos)	24
2.7.1. Adaptación de la Arquitectura <i>Transformer</i> al Vídeo	24
2.7.2. Enfoques Basados en Autoencoders Enmascarados	25
2.8. Aprendizaje por Transferencia	26
2.8.1. Fine-tuning y optimización de hiperparámetros	27
2.9. Ensemble de Modelos y Fusión multimodal	28
2.9.1. Ventajas de los <i>Transformers</i> en tareas multimodales	29
2.9.2. Fusión Temprana vs Fusión Tardía	29
2.10. Subjetividad en la anotación de los datos	30
2.10.1. Aprendizaje con Desacuerdo (Learning with Disagreement)	30

2.10.2. Perspectivismo en Inteligencia Artificial	31
2.11. Medidas de Evaluación	32
2.11.1. <i>Accuracy</i> , Precisión, Exhaustividad y <i>F1-Score</i>	32
2.11.2. Evaluación en clasificación multietiqueta	33
2.11.3. Métricas para evaluación con desacuerdo	34
2.12. Tecnologías y Recursos Utilizados	35
3. Metodología, Experimentación y Resultados	37
3.1. Participación en el desafío <i>EXIST 2025</i>	37
3.2. Descripción General de la Metodología	40
3.3. Preparación de los Datos	41
3.3.1. Descripción del Conjunto de Datos y División (<i>Train</i> y <i>Test</i>)	42
3.3.2. Preprocesado de texto, limpieza y tokenización	44
3.3.3. Extracción de Características Visuales	45
3.4. Experimentación Unimodal en Texto	46
3.4.1. Arquitecturas Discriminativas (<i>Transformers</i>)	47
3.4.2. Arquitecturas Generativas (<i>LLMs</i>)	49
3.5. Experimentación con Modelos de Visión Estática	50
3.5.1. Selección de Arquitectura y Volumen de Fotogramas	50
3.5.2. Optimización de Hiperparámetros y Data Augmentation	53
3.6. Experimentación con Modelos de Visión Temporal	55
3.6.1. Selección de la Arquitectura Temporal	55
3.6.2. Optimización de Hiperparámetros y Data Augmentation Temporal	56
3.7. Fusión Multimodal (<i>Ensemble</i>)	58
3.7.1. Estrategia de <i>Late Fusion</i>	58
3.7.2. Optimización de Pesos y Resultados Finales	59
3.7.3. Análisis de Errores	60
3.7.4. Evaluación Final sobre el Conjunto de <i>Test Ciego</i>	63
3.8. Perspectivismo en <i>LeWiDi</i>	64
3.8.1. Segmentación demográfica en <i>Transformers</i>	64
3.8.2. Análisis de Sensibilidad al <i>Prompt</i> en <i>LLMs</i> (<i>Persona Prompting</i>)	69
3.8.3. Análisis de los Resultados Exploratorios	70
3.9. Experimentación Multietiqueta (Tarea 3.3)	72
3.9.1. Preparación del Dataset Multietiqueta	73
3.9.2. Resultados y Análisis Cruzado por Tipología	73
3.10. Resumen Global de Resultados	75
4. Conclusiones y Trabajo Futuro	77
4.1. Conclusiones	77
4.2. Trabajo Futuro	80
4.3. Planificación Temporal del Trabajo Realizado	80
Referencias	82
A. Anexos	87
A.1. Aplicación Web para la Visualización y Prueba del Modelo	87

Índice de Figuras

2.1. Flujo de procesamiento multimodal de vídeos (texto + imagen + vídeos) (Elaboración propia)	7
2.2. Principal diferencia entre <i>Machine</i> y <i>Deep Learning</i> (Fuente: [12])	8
2.3. Arquitectura de los modelos <i>Transformers</i> (Fuente: [31])	17
2.4. Ejemplo de funcionamiento del mecanismo de atención (Fuente: Elaboración propia)	18
2.5. Entradas necesarias para el codificador de <i>BERT</i> (Fuente: [32])	18
2.6. Arquitectura de un <i>ViT</i> (Fuente: [51])	22
2.7. Ilustración de los mecanismos de atención de un <i>TimeSformer</i> (Fuente: [55])	24
2.8. Representación de los <i>Tubelets</i> de los <i>ViViT</i> (Fuente: [56])	25
2.9. Arquitectura de <i>VideoMAE</i> (Fuente: [57])	26
2.10. Tecnologías usadas para el desarrollo del TFM	35
3.1. Pipeline general del marco de experimentación	40
3.2. Ejemplo de un registro del dataset original	42
3.3. Dataset transformado para la tarea 3.1	43
3.4. Resultados del <i>Ensemble</i> Multimodal contra el conjunto local de desarrollo .	60
3.5. Resultados de la estrategia <i>Hard Consensus</i> en hombres	65
3.6. Resultados de la estrategia <i>Hard Consensus</i> en mujeres	66
3.7. Resultados de la estrategia <i>Pessimistic</i> en hombres	66
3.8. Resultados de la estrategia <i>Pessimistic</i> en mujeres	67
3.9. Resultados de la estrategia <i>Optimistic</i> en hombres	67
3.10. Resultados de la estrategia <i>Optimistic</i> en mujeres	68
3.11. Resultados de la estrategia <i>Unrolling</i> en hombres	68
3.12. Resultados de la estrategia <i>Unrolling</i> en mujeres	69
3.13. Resultados de la técnica <i>Persona Prompting</i> instruyendo el rol de hombre .	70
3.14. Resultados de la técnica <i>Persona Prompting</i> instruyendo el rol de mujer . .	70
A.1. Interfaz web desarrollada con Gradio alojada mediante un <i>iframe</i> en <i>Hugging Face Spaces</i>	89

Índice de Tablas

2.1. Hiperparámetros de las estrategias avanzadas de optimización	28
3.1. Resultados oficiales obtenidos en la Subtarea 3.1 de EXIST 2025	39
3.2. Distribuciones del fichero Train y <i>Test</i> para la tarea 3.1	44
3.3. Tamaños de los ficheros Train y <i>Test</i> en función de los <i>frames</i> extraídos . .	46
3.4. Rendimiento de los modelos <i>baseline</i> sobre el conjunto local de desarrollo <i>holdout</i>	47
3.5. Configuración estándar con las que fueron entrenados los <i>Transformers</i> . . .	48
3.6. Configuración alternativa seleccionada para el modelo <i>RoBERTa-base</i>	48
3.7. Rendimiento interno de los modelos <i>Transformers</i>	49
3.8. Rendimiento interno de los modelos <i>LLMs</i>	50
3.9. Rendimiento de los modelos de Visión Estática con las diferentes combina- ciones de <i>datasets</i> de <i>frames</i> y técnicas de <i>pooling</i>	52
3.10. Resultados de las estrategias de hiperparámetros aplicadas al <i>baseline</i> de <i>ConvNeXt</i> de 4 <i>frames</i>	53
3.11. Resultados de las estrategias de <i>data augmentation</i> aplicadas al <i>baseline</i> de <i>ConvNeXt</i> de 4 <i>frames</i>	54
3.12. Rendimiento de los modelos de Visión Temporal	56
3.13. Rendimiento del <i>TimeSFormer</i> con las estrategias de hiperparámetros . . .	57
3.14. Rendimiento del <i>TimeSFormer</i> con las estrategias de <i>data augmentation</i> . .	57
3.15. Resultados oficiales obtenidos en la Subtarea 3.1 de <i>EXIST 2025</i> con el modelo <i>Ensemble</i>	63
3.16. Distribución de los <i>datasets</i> de entrenamiento tras la segmentación por gé- nero y aplicación de estrategias de resolución de empates.	65
3.17. Rendimiento comparativo de las estrategias exploratorias filtradas por género.	71
3.18. Resultados de <i>Accuracy</i> y <i>F1-score</i> de cada una de las etiquetas	74
3.19. Resumen de los mejores modelos obtenidos por modalidad para la Tarea 3.1.	76
4.1. Estimación de la planificación temporal del trabajo realizado.	81

Introducción

Todo proyecto de investigación necesita un contexto claro que justifique su desarrollo. Esta memoria recoge el trabajo realizado durante nuestra participación en la competición internacional *EXIST 2025*, cuyo reto principal es la detección y categorización automática del sexismo en redes sociales a partir del análisis combinado de texto, imágenes y vídeos.

A lo largo de este capítulo introductorio vamos a desglosar los motivos que nos han llevado a elegir este tema, destacando la necesidad urgente de aplicar la Inteligencia Artificial para frenar la discriminación y el odio en las redes sociales. Además, definiremos los objetivos concretos que han marcado el rumbo técnico del proyecto y repasaremos las competencias académicas adquiridas como frutos de la investigación. Como cierre, se presenta un breve itinerario al lector para guiarlo a través de los capítulos posteriores: el marco teórico, la metodología aplicada, la fase de experimentación y las conclusiones finales.

1.1. Motivación

Las redes sociales, y en especial las plataformas de consumo rápido como *TikTok*, se han convertido en un altavoz principal para la propagación del discurso de odio a gran escala debido al anonimato y la impunidad. En este contexto digital, el sexismo destaca como un problema estructural que afecta de manera desproporcionada a las mujeres [1]. En redes basadas en texto como *Twitter* (actualmente *X*), la misoginia se hace patente mediante el acoso y la creación de narrativas discriminatorias, mientras que en plataformas de consumo rápido como *TikTok*, las dinámicas de los algoritmos pueden amplificar ideologías machistas y fomentar la hipersexualización. Paralelamente, el uso de formatos multimodales, como los memes, permite camuflar los prejuicios bajo la apariencia de humor o ironía, convirtiéndolos en mecanismos de difusión muy escurridizos.

Uno de los grandes retos para frenar este fenómeno es que el sexismo no siempre se manifiesta de forma explícita o mediante el uso de palabras malsonantes. Frecuentemente, se apoya en estereotipos profundamente arraigados, sesgos implícitos y microagresiones que normalizan la desigualdad. Comprender y detectar estas formas sutiles es crucial para abordar el problema, ya que su impunidad influye negativamente sobre la percepción social y perpetúa la discriminación. Sin embargo, la revisión y moderación manual de este tipo de contenido resulta en la actualidad completamente inviable, debido al inmenso volumen

de publicaciones que se generan constantemente, lo cual supera con creces la capacidad humana [2].

Por todo ello, resulta indispensable investigar y desarrollar herramientas automatizadas capaces de entender estas dinámicas tan complejas. Mediante este trabajo, proponemos aplicar y evaluar diversas técnicas de *Deep Learning* para construir modelos mediante un abordaje multimodal que ayuden a clasificar las publicaciones en las redes sociales. El propósito no es únicamente detectar la presencia de sexismo, sino caracterizarlo en función de la intención del mensaje y la categoría del abuso. Con la implementación de estas técnicas, buscamos proporcionar mecanismos escalables que apoyen la moderación de contenido, ayudando a mitigar la violencia de género en la red y contribuyendo a lograr plataformas digitales más inclusivas y libres de abusos.

1.2. Objetivos

El objetivo principal de este proyecto es diseñar, implementar y evaluar un sistema automatizado basado en técnicas de aprendizaje profundo (*Deep Learning*) para la detección de sexismo (Tarea 3.1) y el análisis exploratorio de tipologías específicas (Tarea 3.3) en vídeos de la plataforma *TikTok*. Para lograr este propósito, hemos planteado un enfoque multimodal capaz de procesar tanto de forma combinada como de manera independiente la información textual, a partir de las transcripciones de los vídeos, y la información visual y espaciotemporal, mediante la extracción y análisis de sus fotogramas (*frames*), enmarcando la investigación dentro de la competición internacional *EXIST 2025*.

Para alcanzar dicho objetivo general, se han definido los siguientes objetivos específicos:

- **Estudiar** el estado del arte y las técnicas actuales en el campo del *Deep Learning*, el Procesamiento del Lenguaje Natural (PLN) y la Visión Artificial aplicadas a la detección de contenido de odio y sexismo en formato vídeo.
- **Preprocesar y adecuar** el conjunto de datos proporcionado por la organización de EXIST 2025. Esto incluye el procesamiento de las transcripciones textuales y el diseño de un canal de extracción de fotogramas para posibilitar el análisis visual, gestionando además el paradigma *Learning with Disagreement* (LeWiDi).
- **Implementar y ajustar (*fine-tuning*)** modelos de estado del arte especializados en las diferentes modalidades trabajadas a partir del vídeo, contrastando arquitecturas de lenguaje con arquitecturas de visión estática y temporal.
- **Proponer y desarrollar** estrategias de fusión de modelos (*Ensemble*) para combinar las predicciones de las modalidades de texto, imagen y vídeo, con el fin de analizar el rendimiento conjunto y mitigar las deficiencias individuales de cada modelo.
- **Participar** en la tarea 3.1 de la competición *EXIST 2025*, estableciendo líneas base

de rendimiento mediante el uso de modelos de lenguaje supervisados (*RoBERTa*) y enfoques *zero-shot* mediante Grandes Modelos de Lenguaje (*Llama*).

- **Desarrollar**, en una fase de experimentación posterior a la competición, un marco de evaluación sobre partición local para la tarea 3.1 y un análisis exploratorio parcial de las tipologías de la tarea 3.3, calibrando y fusionando (*Ensemble*) los mejores modelos de cada modalidad para estudiar su comportamiento predictivo.
- **Explorar** el impacto del perspectivismo y la subjetividad en la detección del sexismo, evaluando cómo la identidad de género de los anotadores influye en el sesgo del entrenamiento de los modelos.

1.3. Competencias

La realización de este Trabajo de Fin de Máster ha permitido poner en práctica y consolidar una serie de competencias fundamentales adquiridas durante la titulación, adaptándolas a un problema de investigación real y de alto impacto social.

De acuerdo con lo establecido en el documento de propuesta (Anexo II), la **competencia principal** que rige este trabajo es:

- **Capacidad de aplicar métodos matemáticos, estadísticos y de inteligencia artificial para modelar, diseñar y desarrollar aplicaciones, servicios, sistemas inteligentes y sistemas basados en el conocimiento.** Esta competencia se ha alcanzado de manera integral mediante el diseño y desarrollo de un sistema inteligente multimodal. Para ello, se han aplicado métodos avanzados de inteligencia artificial (*Deep Learning*) y estrategias estadísticas (como la agregación de distribuciones de probabilidad en etiquetas *soft* y el diseño de *ensembles*) con el fin de modelar y detectar el comportamiento sexista en la plataforma *TikTok*.

Además de esta competencia principal, el carácter de investigación de este proyecto nos ha permitido alcanzar las siguientes competencias adicionales vinculadas al plan de estudios:

- **Capacidad para el análisis, procesamiento y extracción automática de información a partir de datos no estructurados y multimodales.** Se ha logrado mediante la construcción de un flujo de trabajo técnico capaz de extraer fotogramas (*frames*) secuenciales a partir de los archivos de vídeo, así como trabajar con las transcripciones textuales de estos. Esto ha implicado limpiar el ruido implícito del lenguaje de las redes sociales y estructurar información bajo el complejo paradigma de las anotaciones múltiples (*Learning with Disagreement*).
- **Capacidad para conocer, diseñar y entrenar modelos *Deep Learning* aplicados a Visión Artificial y Procesamiento del Lenguaje Natural.** Esta capa-

cidad se ha consolidado a través de la implementación, adaptación y optimización de diversas arquitecturas expuestas en el capítulo del estado del arte. Entre ellas destacan modelos de lenguaje, como los *Transformers* y *Large Language Model (LLMs)*, y redes avanzadas de visión estática espaciotemporal, como los *Vision Transformers (ViT)* y *Video Vision Transformers (ViViT)*.

- **Capacidad para evaluar sistemas complejos y adquirir conocimientos a partir de grandes volúmenes de datos.** Esta competencia se ha desarrollado al enfrentar problemas de modelo del mundo real, como el desbalanceo de clases y colapso modal (*Mode Collapse*). La validación del sistema se ha fundamentado en la interpretación de métricas de evaluación avanzadas, como el *Information Contrast Measure (ICM)* o el *F1-score* para determinar los mejores rendimientos de los modelos y, por ende, poder establecer las mejores estrategias de fusión de modelos.
- **Conciencia ética y capacidad para analizar el impacto social y los sesgos en los sistemas de Inteligencia Artificial.** Se ha adquirido de manera transversal al explorar el perspectivismo y la subjetividad en la detección del sexismo. El análisis de algunos de los factores de los anotadores (como el género) pueden influir en el sesgo de entrenamiento de los modelos, permitiéndonos comprender la importancia crítica de diseñar sistemas de expertos más justos, transparentes y representativos.

1.4. Estructura de la Memoria

La presente memoria se estructura en los siguientes capítulos:

- **Capítulo 2 (Marco Teórico):** Se exponen los conceptos fundamentales que sustentan este trabajo, incluyendo los principios del *Deep Learning* y el Procesamiento del Lenguaje Natural, las arquitecturas de modelos lingüísticos, de visión estática y temporal, así como las técnicas de fusión, el aprendizaje con desacuerdo (*LeWiDi*) y las métricas de evaluación.
- **Capítulo 3 (Metodología, Experimentación y Resultados):** Se detalla la aproximación práctica del trabajo, abarcando la participación en la competición *EXIST 2025*, el *pipeline* de preparación de datos, los entrenamientos unimodales y multimodales, la experimentación exploratoria multietiqueta y el análisis de perspectivismo y de errores.
- **Capítulo 4 (Conclusiones y Trabajo Futuro):** Se recogen las conclusiones derivadas de los resultados obtenidos, evaluando los objetivos alcanzados, las limitaciones detectadas y las posibles líneas de investigación futura.

Marco Teórico

En este capítulo se describen los conceptos teóricos y el estado del arte necesarios para comprender el desarrollo y las decisiones de arquitectura tomadas para la realización de este Trabajo de Fin de Máster.

Dada la naturaleza compleja y multimodal del problema abordado (la detección y categorización del sexismo en redes sociales), el marco teórico abarca desde los principios fundamentales del Aprendizaje Automático y Profundo (*Deep Learning*) hasta los enfoques más modernos en Procesamiento del Lenguaje Natural y Visión Artificial. A lo largo de las siguientes secciones, se realiza una revisión crítica de las arquitecturas de estado del arte, prestando especial atención a los modelos basados en Transformers y a los Grandes Modelos de Lenguaje (*LLMs*). Asimismo, se fundamentan de manera teórica las estrategias empleadas para la experimentación, como el aprendizaje por transferencia, la fusión de modelos (*ensembles*) y el novedoso paradigma del aprendizaje con desacuerdo (*LeWiDi*), justificando su idoneidad para modelar la subjetividad y el sesgo en las plataformas digitales.

2.1. Aprendizaje Automático

El aprendizaje automático, comúnmente conocido como *Machine Learning* (*ML*), es una de las disciplinas fundamentales dentro de la Inteligencia Artificial. Su objetivo principal es el desarrollo de algoritmos y modelos computacionales capaces de identificar patrones complejos y adquirir conocimiento empírico a partir de los datos, permitiendo a los sistemas mejorar su rendimiento en una tarea específica sin necesidad de ser explícitamente programados mediante reglas deterministas [3].

De manera clásica, atendiendo a la naturaleza de los datos de entrenamiento y al tipo de retroalimentación que recibe el sistema, distinguimos entre tres tipos de aprendizaje [4]:

- Aprendizaje Supervisado: En este enfoque, el algoritmo se entrena utilizando un conjunto de datos etiquetado, es decir, cada dato de entrada está emparejado de antemano con su resultado correcto o salida esperada. El objetivo del modelo es aprender una función matemática subyacente que relacione de forma generalizada las entradas con las salidas. Una vez entrenado, el sistema es capaz de inferir y predecir resultados

con cierto grado de precisión frente a nuevos datos con los que no ha interactuado previamente [5].

- Aprendizaje No Supervisado: A diferencia del tipo de aprendizaje anterior, en este caso el modelo recibe un conjunto de datos que carece por completo de etiquetas o salidas conocidas. El propósito del algoritmo no es predecir un valor en concreto, sino explorar la información para descubrir estructuras, patrones o agrupaciones de manera autónoma.
- Aprendizaje por Refuerzo: En este escenario no se parte de un conjunto de datos estático, sino que un agente aprende a tomar secuencias de decisiones interactuando dinámicamente con un entorno. Mediante un proceso continuo de prueba y error, el modelo ajusta su comportamiento con el objetivo de maximizar una señal de recompensa a largo plazo [6].

Para el desarrollo del presente trabajo, el enfoque central se enmarca dentro del Aprendizaje Supervisado. Dado que el objetivo es la detección y categorización del sexismo en la plataforma *TikTok*, los modelos requieren ser entrenados con colecciones de datos previamente anotados que asocian cada publicación (ya sea el vídeo, la transcripción textual o sus fotogramas) con una clase específica. Sin embargo, dada la alta subjetividad inherente a la interpretación de los discursos de odio en redes sociales, el concepto tradicional de “etiqueta única” del aprendizaje supervisado clásico presenta limitaciones, lo cual motivará la adopción de enfoques más flexibles como el aprendizaje con desacuerdo, que se abordará en secciones posteriores.

2.2. Clasificación de textos, imágenes y vídeos

La clasificación automática es una de las tareas fundamentales del aprendizaje automático supervisado. Consiste en asignar una o varias categorías a un dato de entrada a partir de un conjunto de ejemplos que estaban previamente etiquetados. Atendiendo a la cantidad de categorías y a su exclusividad, los problemas de clasificación pueden dividirse en:

- Clasificación binaria: Cuando el sistema debe discriminar entre dos únicas clases (0 o 1).
- Clasificación multiclase: Cuando el sistema debe discriminar entre más de dos clases, siendo éstas discriminantes entre sí. Esto quiere decir que dado un dato de entrada, este puede pertenecer a una de las clases sobre las que se esté clasificando.
- Clasificación multietiqueta: Cuando el sistema debe discriminar entre más de dos clases, siendo éstas no discriminantes entre sí. Esto quiere decir que una misma entrada puede no pertenecer a ninguna clase, pertenecer a una exclusivamente o pertenecer a varias simultáneamente [7].

Tradicionalmente, los modelos de clasificación se han diseñado para procesar una única modalidad de datos. En la clasificación de texto, la entrada consiste en secuencias de caracteres o palabras, requiriendo técnicas de Procesamiento de Lenguaje Natural para extraer la semántica, la sintaxis y el contexto del mensaje [8]. En la clasificación de imágenes, los algoritmos analizan la distribución espacial de los píxeles para identificar formas, texturas y patrones visuales estáticos. Por su parte, la clasificación de vídeo introduce una dimensión adicional y crítica: el tiempo. El procesamiento de este tipo de datos requiere no solo comprender la información visual estática de cada fotograma (*frame*), sino también modelar el movimiento y la evolución espaciotemporal a lo largo de la secuencia [9].

No obstante, en entornos reales donde la información es abundante y compleja, el uso de una modalidad suele ser insuficiente. Esto ha impulsado el desarrollo de la clasificación multimodal, un paradigma que integra múltiples fuentes de información de distinta naturaleza (por ejemplo, combinando un texto con una secuencia de imágenes). Para lograrlo, estos sistemas emplean arquitecturas especializadas en cada dominio y, posteriormente, aplican estrategias de fusión que combinan las representaciones extraídas, permitiendo al modelo tomar una decisión conjunta mucho más robusta frente a la ambigüedad [10].




Figura 2.1: Flujo de procesamiento multimodal de vídeos (texto + imagen + vídeos) (Elaboración propia)

Como se ilustra de manera conceptual en la Figura 2.1, un flujo de procesamiento multimodal estándar divide el contenido original en sus componentes básicos. Cada modalidad es procesada de forma independiente y en paralelo por modelos específicos para extraer sus características intrínsecas. Finalmente, estas representaciones convergen en un módulo de fusión, el cual combina la información para emitir la predicción final. Este esquema teórico sirve como pilar fundamental para el diseño de arquitecturas capaces de analizar el complejo contenido multimedia actual.

2.3. Aprendizaje Profundo

Dentro de la disciplina del aprendizaje automático, el aprendizaje profundo (*Deep Learning*) representa una evolución significativa [11]. Esta rama se fundamenta en el uso de redes neuronales artificiales, arquitecturas computacionales inspiradas en cómo el cerebro humano estructura y procesa la información. Al organizar estas neuronas artificiales en múltiples capas sucesivas, el sistema adquiere la capacidad de procesar la información de forma jerárquica, logrando un nivel de abstracción cada vez mayor. A medida que aumenta la profundidad de la red (el número de capas), el algoritmo es capaz de modelar relaciones más complejas y extraer mayor cantidad de información a partir de los datos, incluso si no es perceptible por el ser humano [12].




Figura 2.2: Principal diferencia entre *Machine* y *Deep Learning* (Fuente: [12])

La principal diferencia entre el aprendizaje automático clásico y el aprendizaje profundo radica en el proceso de extracción de características (*feature extraction*). Como se ilustra en la Figura 2.2, en los algoritmos tradicionales de *Machine Learning*, es necesario que un experto humano o un proceso algorítmico previo diseñe y extraiga manualmente las características relevantes de los datos de entrada para que el clasificador pueda tomar decisiones. Por el contrario, los modelos de *Deep Learning* automatizan este proceso por completo, integrando la extracción de características de forma implícita dentro de la propia arquitectura de la red. Esta capacidad de aprendizaje de extremo a extremo (*end-to-end*) permite al modelo descubrir por sí mismo qué patrones son los más instructivos para resolver la tarea [13].

En el contexto de este Trabajo de Fin de Máster, el aprendizaje profundo constituye el núcleo técnico del sistema propuesto. Se han empleado modelos basados en arquitecturas profundas, tanto para el procesamiento de la información textual, con modelos *Transformers* y Grandes Modelos de Lenguaje, como para el análisis visual, con modelos *Vision*

Transformers.

Dado el enorme tamaño de estas arquitecturas y la complejidad matemática que entraña su ajuste, resulta indispensable comprender cómo se lleva a cabo su fase de entrenamiento. El éxito de estos modelos no depende únicamente de su estructura interna, sino de la correcta configuración de los factores que guían su aprendizaje. Por ello, en las siguientes subsecciones se detallan los hiperparámetros, mecanismos de control y conceptos fundamentales que controlan el proceso de entrenamiento.

2.3.1. Epochs y tamaño de lote

Durante el proceso de entrenamiento de una red neuronal profunda, el modelo ajusta sus parámetros internos de forma iterativa a medida que procesa la información. El ritmo y el volumen de datos que se procesan en cada actualización de los pesos están regidos por dos hiperparámetros fundamentales de la arquitectura: la época (*epoch*) y el tamaño de lote (*batch size*).

Una época (*epoch*) se define como un ciclo de aprendizaje completo en el que la totalidad del conjunto de datos de entrenamiento pasa a través de la red neuronal, tanto hacia adelante (*forward pass*) para generar las predicciones, como hacia atrás (*backward pass*) para propagar el error. Dado que los algoritmos de optimización basados en el gradiente son iterativos, una sola época rara vez es suficiente para que el modelo minimice el error adecuadamente. Por lo tanto, el entrenamiento exige realizar múltiples épocas. Sin embargo, un número excesivamente alto de épocas puede derivar en un problema de sobreajuste (*overfitting*), donde el modelo comienza a memorizar los datos de entrenamiento perdiendo su capacidad de generalización [14].

Por otro lado, la cantidad de información que componen los conjuntos de datos actuales (especialmente aquellos con imágenes y videos) hace que sea computacionalmente inviable, debido a las limitaciones de memoria de las tarjetas gráficas (*GPU*), procesar todos los ejemplos simultáneamente. Para solucionar esta limitación, el conjunto de entrenamiento se divide en fracciones más pequeñas denominadas lotes (*batches* o *minibatches*). El tamaño de lote determina el número de muestras que la red procesa antes de evaluar el error acumulado y actualizar sus pesos [15].

La elección del tamaño de lote tiene un impacto directo en la estabilidad y velocidad del entrenamiento. Un lote grande ofrece una estimación muy precisa del gradiente, pero requiere una enorme cantidad de memoria *VRAM*. Por el contrario, un tamaño de lote pequeño introduce cierto “ruido” matemático en cada actualización. Curiosamente, este ruido suele ser beneficioso, ya que actúa como un mecanismo de regularización que ayuda a la red a escapar de mínimos locales y a encontrar soluciones que generalizan mejor ante datos nuevos [16].

En el contexto del ajuste fino (*fine-tuning*) de arquitecturas masivas, como los *Transformers* o los *LLMs* empleados en este trabajo, el enorme peso de los modelos obliga a utilizar tamaños de lote muy reducidos. Asimismo, dado que estas redes ya cuentan con un amplio conocimiento adquirido durante su preentrenamiento, el número de épocas necesarias suele ser considerablemente bajo (generalmente entre 3 y 10). Un entrenamiento prolongado en estas condiciones no solo sería ineficiente, sino que podría provocar lo que se conoce como *catastrophic forgetting*, el cual destruiría las representaciones lingüísticas o visuales que el modelo ya había aprendido previamente.

2.3.2. Tasa de aprendizaje y *weight decay*

La tasa de aprendizaje (*learning rate*) es, posiblemente, el hiperparámetro más crítico en la configuración de cualquier algoritmo de optimización basado en el gradiente. Este valor determina el tamaño del paso que da el modelo en el espacio de parámetros durante cada iteración para minimizar la función de pérdida. Su correcta elección tiene un impacto significativo en la convergencia del modelo: si la tasa de aprendizaje es demasiado alta, los saltos en la actualización de los pesos serán desproporcionados, lo que puede provocar que el modelo sobrepase el mínimo óptimo y el entrenamiento se vuelva inestable. Por el contrario, si la tasa es excesivamente baja, la red tardará demasiado tiempo en converger o correrá el riesgo de quedarse estancada en un mínimo local [17].

Para complementar el proceso de optimización y mitigar el riesgo de sobreajuste, es práctica común incorporar una técnica de regularización conocida como *weight decay* (decaimiento de pesos). Esta técnica consiste en añadir un término de penalización a la función de pérdida que es proporcional al tamaño de los pesos de la red. De este modo, el algoritmo se ve forzado a mantener los valores de los parámetros lo más pequeños y distribuidos posible. Al evitar que unos pocos pesos adquieran valores desproporcionados, se asume que el modelo resultante es más simple y estable, lo que mejora drásticamente su capacidad para generalizar ante datos no vistos en lugar de memorizar el ruido del conjunto de entrenamiento [18].

En el ámbito del procesamiento del lenguaje natural y la visión por computador con arquitecturas profundas, ambos conceptos suelen trabajar de la mano mediante optimizadores avanzados como *AdamW*. Al realizar el *fine-tuning* de modelos masivos que ya poseen un conocimiento previo (*Transformers* o *LLMs*), la teoría dictamina el uso de tasas de aprendizaje muy reducidas, a menudo acompañadas de planificadores (*schedulers*) que disminuyen este valor dinámicamente con el tiempo. El uso simultáneo de un *learning rate* bajo y un *weight decay* adecuado garantiza que el modelo se adapte a la nueva tarea de clasificación sin destruir las representaciones que adquirió durante su fase de preentrenamiento [19].

2.3.3. Función de pérdida

Durante la fase de entrenamiento, el modelo necesita una métrica cuantitativa que evalúe la precisión de sus predicciones frente a las etiquetas reales del conjunto de datos. Esta métrica es la función de pérdida (*loss function*). Su objetivo matemático es calcular el error cometido en cada predicción, devolviendo un valor que el algoritmo de optimización (mediante *backpropagation*) intentará minimizar iterativamente actualizando los pesos de la red [20]. En los problemas de clasificación, las funciones de pérdida basadas en la teoría de la información, concretamente en el concepto de entropía, son el estándar.

Para tareas de clasificación binaria o multiclase, donde las categorías son mutuamente excluyentes (es decir, una entrada solo puede pertenecer a una clase), se emplea la **Entropía Cruzada** (*Cross-Entropy Loss*). Esta función mide la diferencia entre la distribución predicha por el modelo y la distribución real de las etiquetas. Matemáticamente, penaliza de forma logarítmica las predicciones erróneas que el modelo realiza con alta confianza, forzando al sistema no solo a acertar la clase correcta, sino a hacerlo con la mayor certeza posible [21].

Por otro lado, para abordar la tarea de clasificación multietiqueta (donde un mismo registro puede presentar varias categorías de sexismo simultáneamente), el problema se modela habitualmente como un conjunto de decisiones binarias independientes. Aunque la entropía cruzada categórica tradicional no es aplicable de forma directa al no tratarse de clases mutuamente excluyentes, la familia de pérdidas de entropía cruzada sigue siendo el pilar fundamental a través de la **Entropía Cruzada Binaria** (*Binary Cross-Entropy* o *BCE*). Esta variante aplica los principios de la entropía cruzada para evaluar la probabilidad de presencia o ausencia de cada etiqueta de manera independiente, permitiendo que el modelo determine si una categoría específica aplica o no a la entrada, sin que dicha decisión restrinja las probabilidades del resto de etiquetas [22].

2.3.4. Overfitting y técnicas de regularización

Uno de los desafíos más críticos durante el entrenamiento de redes neuronales profundas es el fenómeno conocido como sobreajuste (*overfitting*). Este problema ocurre cuando un modelo es excesivamente complejo en relación con la cantidad de datos de entrenamiento disponibles. En lugar de extraer patrones generales y subyacentes, la red comienza a memorizar el ruido, las anomalías y los detalles específicos del entrenamiento. Como resultado, el modelo alcanza un rendimiento excelente sobre los datos con los que ha sido entrenado, pero fracasa drásticamente al intentar generalizar y predecir sobre datos nuevos o no vistos previamente [23].

Para mitigar el problema y forzar al modelo a aprender representaciones más robustas, se emplean diversas técnicas de regularización. Una de las estrategias más extendidas,

que actúa de manera complementaria a la penalización de pesos (*weight decay*) vista en apartados anteriores, es el *Dropout* (abandono).

El *Dropout* es una técnica de regularización estructural que consiste en desactivar aleatoriamente una proporción de las neuronas de la red, junto con sus respectivas conexiones, durante cada iteración (*forward* y *backward pass*) de la fase de entrenamiento. Al “apagar” distintas neuronas en cada paso, se evita que las unidades de la red desarrollen una dependencia mutua excesiva. Esto obliga al modelo a distribuir el aprendizaje, garantizando que la predicción final no dependa de un pequeño grupo de neuronas fuertemente conectadas, sino del conjunto de múltiples sub-redes independientes [24].

En las arquitecturas profundas basadas en mecanismos de atención, como los *Transformers* utilizados en este trabajo tanto para el procesamiento textual como visual, el *Dropout* es un componente fundamental que se encuentra integrado por defecto en el diseño de sus bloques internos. La combinación del *Dropout* arquitectónico con estrategias de optimización regularizadas asegura que el modelo mantenga su capacidad de generalización al adaptarse a la nueva tarea de clasificación.

2.3.5. Early stopping y validación

Para monitorizar de forma objetiva el rendimiento de un modelo durante su fase de entrenamiento y detectar a tiempo un posible sobreajuste, resulta relevante el uso de un conjunto de validación. Este subconjunto de datos, que se mantiene independiente de las muestras empleadas para actualizar los pesos de la red, permite evaluar iterativamente la capacidad de generalización del modelo. Este proceso se da al finalizar cada época o tras un número determinado de iteraciones y se calcula la función de pérdida y otras métricas de rendimiento sobre este conjunto de validación.

La observación continua de estas métricas es la base del *early stopping* (parada temprana), una de las técnicas de regularización dinámica más eficaces en el aprendizaje profundo. Esta estrategia consiste en interrumpir el entrenamiento de forma automática antes de completar todas las épocas definidas si se detecta que el rendimiento en validación se estanca o empieza a degradarse, mientras que el error de entrenamiento sigue disminuyendo. Este punto de inflexión es el indicador clave de que el modelo ha dejado de aprender patrones generales y ha empezado a memorizar el conjunto de datos de entrenamiento [25].

En la práctica, el *early stopping* se configura mediante un parámetro conocido como paciencia (*patience*), el cual define cuántas evaluaciones sin mejora se permiten antes de detener el proceso. Además de ahorrar valiosos recursos computacionales, esta técnica permite restaurar la configuración de pesos óptima (aquella que obtuvo el mejor resultado en la fase de validación) en lugar de retener los pesos deteriorados de la última época.

Todos estos elementos analizados en las subsecciones anteriores son fundamentales para

diseñar modelos robustos y reproducibles. Además, permiten explicar por qué un modelo ha funcionado mejor que otro cuando se ajustan frente a un problema complejo, más allá de lo que dictan las métricas de evaluación. Como señalan Bergstra y Bengio [26], el conocimiento de estos hiperparámetros y mecanismos de control es clave para mejorar la eficacia y garantizar el éxito de los modelos de aprendizaje automático.

2.4. Procesamiento del Lenguaje Natural

El Procesamiento del Lenguaje Natural (PLN) es una rama de la inteligencia artificial y lingüística computacional que se ocupa de la interacción entre los sistemas informáticos y el lenguaje humano. Su objetivo principal es dotar a las máquinas de la capacidad necesaria para comprender, interpretar, generar y analizar el lenguaje natural, ya sea en formato textual o hablado. En el contexto de este Trabajo de Fin de Máster, el PLN constituye un pilar fundamental para extraer el significado y la intención de los vídeos analizados, permitiendo detectar patrones en el discurso asociados a sesgos de género, misoginia y lenguaje sexista.

Históricamente, los sistemas de clasificación textual dependían de un preprocesamiento manual y exhaustivo. Este proceso clásico implicaba la aplicación de técnicas morfológicas para limpiar y normalizar los datos, tales como la división del texto en unidades mínimas (*tokenización* por palabras), la eliminación de términos que no tienen una carga semántica dentro de la frase (*stopwords*), la lematización y el truncamiento (*stemming*). Tras esta fase, el texto se transformaba en matrices numéricas basadas en la frecuencia de aparición de los términos (como *TF-IDF* o *Bag-of-Words*). Sin embargo, estos enfoques tradicionales presentaban una limitación estructural crítica: al ignorar el orden de las palabras, se perdía gran parte del contexto y de la semántica subyacente de las frases [27].

En la actualidad, la disciplina del PLN ha experimentado una profunda evolución gracias a la adopción de nuevas arquitecturas profundas de aprendizaje automático. Los nuevos modelos, especialmente aquellos basados en la arquitectura *Transformer*, han transformado el paradigma del análisis textual. En lugar de requerir una limpieza léxica manual, estos modelos utilizan tokenizadores de subpalabras (como *Byte-Pair-Encoding*) y proyectan el texto en espacios vectoriales continuos de alta dimensión denominados *embeddings*. Esta representación vectorial permite al modelo conservar de manera simultánea tanto la información sintáctica como la riqueza semántica. Al procesar secuencias de forma bidireccional y contextual, el sistema es capaz de captar matices lingüísticos complejos, como la ironía, el sarcasmo o el doble sentido, elementos que son intrínsecos al lenguaje natural y vitales para detectar el discurso sexista [28].

2.4.1. Preprocesamiento del texto

Para que un modelo de aprendizaje profundo pueda procesar y extraer valor de la información textual, los datos deben someterse a una fase previa de acondicionamiento. Tal y como se ha mencionado en la sección anterior, aunque las arquitecturas basadas en *Transformers* no requieren técnicas clásicas de limpieza lingüística (como la lematización), sí exigen un proceso de eliminación de ruido específico del dominio y una tokenización matemática estricta.

En la fase de experimentación de este trabajo, las transcripciones y textos analizados se han sometido a una tubería de limpieza (*pipeline*) mediante el uso de expresiones regulares. El objetivo ha sido estandarizar el vocabulario (convirtiendo todo el texto a minúsculas) y eliminar aquellos elementos sin valor semántico que introducen ruido en la red. Concretamente, se ha procedido a la eliminación de enlaces web (*URLs*), menciones a otros usuarios, etiquetas de metadatos (*hashtags*), emoticonos (*emojis*) y etiquetas estructurales derivadas de la transcripción de los vídeos (como los prefijos “AUDIO:” o “VIDEO:”). La supresión de estos elementos resulta fundamental para aislar el discurso real y evitar que el modelo dedique recursos a aprender patrones sintácticos irrelevantes para la tarea de clasificación [29].

Una vez que el texto ha sido limpiado, se aplica el proceso de tokenización. Las nuevas arquitecturas emplean algoritmos de subpalabras, como *Byte-Pair Encoding* (BPE) o *WordPiece*. Estos enfoques son altamente eficientes, ya que conservan las palabras comunes enteras, pero dividen los términos raros, mal escritos o específicos de la jerga de internet en subunidades más pequeñas y conocidas.

Finalmente, el tokenizador actúa como puente entre el texto y la red neuronal: toma estas subpalabras y las convierte en vectores de identificadores numéricos (*input IDs*). Para garantizar que todas las secuencias adquieran una dimensión matricial uniforme antes de ser procesadas por el modelo, se aplica un proceso de truncamiento (estableciendo una longitud máxima permitida para los registros demasiado largos) y de relleno (*padding*) para los textos más cortos. Adicionalmente, el tokenizador genera estructuras de control, como las máscaras de atención (*attention masks*), las cuales indican al algoritmo qué partes del vector contienen información real y cuáles son simples rellenos. Este formato numérico es el único lenguaje que los modelos de aprendizaje profundo pueden procesar internamente.

2.4.2. Representación del texto

Una vez que el texto ha sido tokenizado, el siguiente reto del PLN es transformar esos identificadores numéricos en un formato que capture el significado lingüístico. Históricamente, esta tarea se realizaba mediante técnicas de extracción de características basadas en frecuencias, como el *Bag-of-Words* o *TF-IDF*. Aunque resultan útiles en algoritmos

de aprendizaje automático clásico, estas estrategias generan representaciones dispersas y asumen la independencia entre los términos, fallando a la hora de capturar las relaciones semánticas intrínsecas.

Para superar estas limitaciones, se introdujeron los *Word Embeddings* o representaciones vectoriales densas. En términos generales, un *Word Embedding* proyecta cada palabra como un vector de números reales en un espacio continuo de alta dimensión, lo que permite cuantificar el contexto de una palabra, así como su similitud semántica y sintáctica, mediante distancias matemáticas.

Uno de los enfoques pioneros en este ámbito fue *Word2Vec*, el cual utiliza redes neuronales poco profundas para aprender representaciones vectoriales mediante dos posibles arquitecturas: *Continuous Bag-of-Words (CBOW)*, que predice una palabra objetivo a partir de su contexto, o *Skip-Gram*, que realiza la tarea inversa prediciendo el contexto a partir de una palabra principal. Posteriormente, surgieron alternativas como *GloVe (Global Vectors for Word Representation)*, un modelo que combina las ventajas de los métodos de ventana de contexto local con la factorización matricial global del corpus.

Sin embargo, estos modelos estáticos presentaban una limitación estructural sin solución: el problema de la polisemia. Dado que algoritmos como *Word2Vec* o *GloVe* precaculan un único vector inamovible para cada término en el vocabulario, son incapaces de distinguir cuándo una misma palabra tiene significados distintos en función del contexto en la oración [30].

Esta debilidad impulsó el desarrollo de la actual generación de representaciones contextuales densas. Las nuevas arquitecturas, en lugar de consultar un diccionario estático de vectores, calculan la representación numérica de cada subpalabra de manera dinámica, analizando simultáneamente toda la secuencia que la rodea. Esta necesidad de contextualización profunda dio lugar a las arquitecturas basadas en mecanismos de atención, las cuales se abordarán en detalle en las siguientes secciones.

2.4.3. Clasificación de texto en PLN

La clasificación de textos es una de las tareas computacionales más fundamentales dentro del PLN. Su objetivo principal consiste en asignar, de forma automática, una o varias categorías semánticas predefinidas a un fragmento de texto no estructurado. Dependiendo de la complejidad y la naturaleza del problema, los sistemas de clasificación se dividen en tres grandes grupos: clasificación binaria, multiclase y multietiqueta, las cuales ya fueron definidas anteriormente en el apartado 2.2 de esta memoria.

En el contexto de este Trabajo de Fin de Máster, la clasificación de texto se emplea como motor analítico para auditar las transcripciones de los videos seleccionados. El proceso se aborda desde una doble vertiente. En primer lugar, se aplica una clasificación binaria para

dictaminar si el contenido expresa algún tipo de lenguaje sexista o misógino. En caso afirmativo, el problema evoluciona hacia un esquema de clasificación más fino y detallado, cuyo objetivo es identificar qué tipos específicos de sesgos, roles de género o violencias discursivas están presentes en el mensaje.

La relevancia de este desafío tecnológico y social queda patente en las prestigiosas campañas de evaluación competitiva organizadas por congresos internacionales como *IberLEF* o *CLEF*. De hecho, el marco experimental y metodológico desarrollado en este trabajo se fundamenta directamente en la competición *EXIST 2025 (sEXism Identification in Social neTworks)*.

Concretamente, los modelos implementados en este proyecto dan respuesta a los retos planteados en la **Tarea 3.1** de dicha competición, centrada en la detección binaria de misoginia en redes sociales, y en la **Tarea 3.3**, enfocada en la categorización avanzada y el análisis multietiqueta del discurso machista. La participación y adaptación a este tipo de iniciativas garantiza que las soluciones aquí propuestas operan sobre un conjunto de datos estandarizado y contribuyen activamente al estado del arte en la mitigación del discurso de odio en entornos digitales.

2.5. Modelos Avanzados para Texto

La necesidad de capturar el contenido dinámico y resolver el problema de la polisemia en la representación textual ha propiciado el desarrollo de arquitecturas neuronales de última generación. En esta sección se describen los fundamentos de los modelos basados en mecanismos de atención y su evolución hasta los modernos sistemas generativos, los cuales constituyen el núcleo de las tecnologías aplicadas en este trabajo.

2.5.1. Transformers

La arquitectura *Transformer*, la cual se puede apreciar en la [Figura 2.3](#), supuso un cambio de paradigma en el PLN tras ser propuesta en el influyente artículo *Attention is all you need* [31]. A diferencia de los modelos recurrentes tradicionales, como las Redes Neuronales Recurrentes (RNN) o las redes de memoria a corto-largo plazo (*LSTM*), los *Transformers* prescinden del procesamiento secuencial. Esta característica permite analizar las secuencias de texto en paralelo, lo que acelera drásticamente los tiempos de entrenamiento y facilita la captura de dependencias a muy largo plazo.




Figura 2.3: Arquitectura de los modelos *Transformers* (Fuente: [31])

El pilar de esta arquitectura es el mecanismo de autoatención (*self-attention*), cuyo funcionamiento se ejemplifica gráficamente en la [Figura 2.4](#). Este mecanismo relaciona diferentes posiciones de una simple secuencia para computar una representación global de la misma. Matemáticamente, asigna una consulta (*query*) y un conjunto de pares clave-valor (*key-value*) a una salida, calculando pesos que determinan la importancia relativa de cada palabra respecto a las demás dentro de la misma oración.




Figura 2.4: Ejemplo de funcionamiento del mecanismo de atención (Fuente: Elaboración propia)

Esta innovación dio lugar a una nueva generación de modelos de lenguaje preentrenados fundamentados en la codificación bidireccional, siendo *BERT* (*Bidirectional Encoder Representations from Transformers*) [32] el exponente clásico. Este necesita de las entradas que se muestran en la Figura 2.5. *BERT* es capaz de aprender el contexto de una palabra observando su secuencia antecesora y predecesora de manera simultánea. Posteriormente, surgieron optimizaciones robustas como *RoBERTa* (*Robustly Optimized BERT Approach*) [33], que mejora el rendimiento eliminando la predicción de la siguiente oración durante el preentrenamiento, utilizando secuencias más largas e introduciendo un enmascaramiento dinámico de los datos.




Figura 2.5: Entradas necesarias para el codificador de *BERT* (Fuente: [32])

Modelos implementados en este trabajo

Para abordar la complejidad de esta tarea y asegurar una evaluación exhaustiva, en el desarrollo empírico de este Trabajo de Fin de Máster se ha implementado una amplia batería de arquitecturas discriminativas basadas en *Transformers*, adaptadas a diferentes dominios lingüísticos:

- **Modelos Multilingües**, se han utilizado:
 - mmBERT (mediante el *checkpoint* jhu-clsp/mmBERT-base) [34].
 - xlm-roberta-base (FacebookAI/xlm-roberta-base) [35].
 - TwHIN-BERT (Twitter/twhin-bert-base) [36].
 - Idóneos para captar estructuras semánticas universales y transferir conocimiento entre idiomas.
- **Modelos específicos para Español**, se han evaluado:
 - BETO (dccuchile/bert-base-spanish-wwm-uncased) [37].
 - BERTin (bertin-project/bertin-roberta-base-spanish) [38].
 - RoBERTuito (pysentimiento/robertuito-base-uncased) [39], siendo este último optimizado para el lenguaje informal de redes sociales.
- **Modelos específicos para Inglés**, se ha experimentado con:
 - RoBERTa-Base (FacebookAI/roberta-base).
 - BERTweet (vinai/bertweet-base) [40] (preentrenado en mensajes cortos y jerga digital).
 - Electra (google/electra-base-discriminator) [41] (que introduce un paradigma de reemplazo de tokens más eficiente computacionalmente).

2.5.2. Modelos Generativos de Lenguaje (LLMs)

Paralelamente a la consolidación de modelos discriminativos como *BERT*, la evolución del aprendizaje profundo ha propiciado la explosión de los Modelos Generativos de Lenguaje (*Large Language Models*) [42]. A diferencia de los enfoques anteriores, los cuales están entrenados para comprender y clasificar, los *LLMs* utilizan arquitecturas autorregresivas fundamentadas habitualmente en la parte decodificadora del *Transformer*. Su objetivo matemático principal es predecir el siguiente token de una secuencia para generar texto altamente coherente y contextualizado.

Modelos como GPT-3, GPT-4 [43], Llama [44] o PaLM [45] se entrenan sobre volúmenes masivos de datos no estructurados. Gracias a este gran conocimiento subyacente, han

demostrado capacidades de generalización sorprendentes. Una de las ventajas más potentes de los *LLMs* es su capacidad para ejecutar tareas supervisadas a través del diseño de instrucciones o *prompting*. Existen tres estrategias principales de aplicación:

- **Zero-shot**: El modelo realiza la tarea directamente con una única instrucción, sin recibir ejemplos previos. Es idóneo cuando se busca rapidez o no se dispone de datos etiquetados.
 - *Ejemplo*: “¿La siguiente transcripción de un vídeo de TikTok a texto contiene lenguaje sexista? Texto: ‘Las mujeres no sirven para liderar proyectos.’ Responde únicamente Sí o No”
- **Few-shot**: Se incluyen varios ejemplos demostrativos dentro de la propia instrucción para que el modelo identifique el patrón deseado antes de emitir su respuesta.
 - *Ejemplo*:
 - Texto de ejemplo: “Todos merecemos las mismas oportunidades.” → No sexista.
 - Texto de ejemplo : “Las chicas son demasiado emocionales para los negocios.” → Sexista.
 - Texto nuevo: “Ellas deberían quedarse cuidando la casa.” → El modelo infiere y dictamina que es Sexista.
- **Fine-tuning (Ajuste fino)**: Consiste en entrenar los pesos del modelo preentrenado utilizando un conjunto de datos específicos del dominio. Aunque requiere mayores recursos computacionales, suele ofrecer un rendimiento superior y constante.

Aplicación práctica en este trabajo: *PEFT* y *QLoRA*

En el marco experimental de este proyecto se ha apostado firmemente por el ajuste fino. Sin embargo, debido al masivo número de parámetros de los *LLMs* modernos, el reentrenamiento completo resulta computacionalmente inviable. Para solucionar este obstáculo, se ha implementado la técnica **QLoRA** (*Quantized Low-Rank Adaptation*) [46] sobre tres modelos generativos de última generación: *Mistral* 7B (mediante el *checkpoint* `mistralai/Mistral-7B-Instruct-v0.3`) [47], *Llama* 3.1 (`meta-llama/Llama-3.1-8B-Instruct`) [48] y *Gemma* 2 (`google/gemma-2-2b-it`) [49]. Esta metodología ha permitido cuantizar los pesos base de los modelos a una precisión de 4 bits, congelarlos, y entrenar únicamente matrices de bajo rango insertadas en las proyecciones matemáticas de atención.

Para adaptar estos modelos a la clasificación binaria de las transcripciones de vídeo, se han desarrollado dos estrategias arquitectónicas distintas:

- **Enfoque Discriminativo (*Sequence Classification*)**: En los modelos *Mistral* y

Gemma, se sustituyó la cabeza de modelado de lenguaje original por una capa lineal de clasificación pura (`AutoModelForSequenceClassification`), ajustando los pesos de esta nueva capa (`score`) para extraer directamente la probabilidad matemática de que el texto contenga lenguaje misógino.

- **Enfoque Generativo Autorregresivo (*Causal LM*)**: En el modelo de la familia *Llama*, se mantuvo la arquitectura generativa intacta (`AutoModelForCausalLM`). El ajuste fino se realizó formateando las instrucciones de entrada (*prompts*) para forzar al modelo a predecir y autocompletar exclusivamente un token de clasificación (“YES” para contenido sexista o “NO” para contenido no sexista) mediante un optimizador supervisado (`SFTTrainer`).

Ventajas y limitaciones de la clasificación con *LLMs*

La adopción de estas arquitecturas masivas para tareas de clasificación del discurso de odio es una tendencia en alza, aunque presenta características contrastadas:

- **Ventajas**: Permiten aprovechar un conocimiento semántico universal y el contexto general del mundo, se adaptan rápidamente a nuevas definiciones de categorías, y alcanzan un nivel de comprensión profundo de la ironía o el sarcasmo.
- **Limitaciones**: Su naturaleza generativa los hace susceptibles a sufrir alucinaciones o generar salidas inconsistentes si no se ajustan correctamente (como ocurre con la modalidad *zero-shot*), exhiben una alta sensibilidad al diseño de la instrucción (*prompt*) y conllevan un coste computacional elevado para inferencias masivas.

2.6. Modelos Avanzados para Visión Estática (Imágenes)

De manera análoga a la evolución experimentada en el PLN, la visión por computador ha sufrido una profunda transformación en los últimos años. Una de las estrategias más eficientes para el análisis de vídeo consiste en eludir el altísimo coste computacional de las arquitecturas tridimensionales (*3D-CNNs*) [50] extrayendo secuencias de fotogramas clave y tratándolos como imágenes estáticas independientes. Para procesar estas imágenes, el estado del arte actual se divide en dos grandes enfoques según su topología.

2.6.1. *Vision Transformers (ViT)* y variantes jerárquicas

Inspirados por el abrumador éxito de los mecanismos de autoatención en el texto conseguido gracias a los *Transformers*, en 2020 se introdujeron los *Vision Transformers (ViT)*

[51], demostrando que la dependencia de las redes convolucionales tradicionales no era estrictamente necesaria para tareas de visión complejas.

La arquitectura *ViT* divide la imagen original en una cuadrícula de pequeños parches (por ejemplo, 16x16 píxeles). Tal y como se muestra en la Figura 2.6 cada parche es aplanado y proyectado linealmente para formar un vector, operando funcionalmente como si fuera un *token* o palabra en una frase. Tras añadir *embeddings* posicionales para retener la información espacial, esta secuencia de parches se introduce directamente en el codificador de un *Transformer* estándar. Al procesar las relaciones globales entre todos los parches mediante la autoatención, *ViT* es capaz de captar un contexto visual integral desde las primeras capas.




Figura 2.6: Arquitectura de un *ViT* (Fuente: [51])

A pesar de su éxito, *ViT* presenta una complejidad computacional cuadrática respecto a la resolución de la imagen. Para solventar este problema, surgieron variantes como *Swin Transformer (Shifted Window Transformer)* [52]. Esta arquitectura jerárquica computa la atención de manera local dentro de ventanas no superpuestas que se van desplazando entre capas, lo que otorga mayor flexibilidad y eficiencia a la hora de procesar distintas escalas visuales.

2.6.2. Redes Neuronales Convolucionales Modernas (*ConvNeXt*)

El auge de los *ViT* llevó a repensar y modernizar el diseño clásico de las Redes Neuronales Convolucionales (*CNNs*). Investigadores de *Facebook* y de la Universidad de California propusieron *ConvNeXt* [53], una arquitectura puramente convolucional construida a partir de una red residual estándar (*ResNet*) [54], pero incorporando las decisiones de diseño que hicieron triunfar a los *Transformers*.

Entre estas mejoras estructurales destacan el uso de tamaños de filtro (*kernel*) más grandes, la sustitución de la normalización por lotes (*Batch Normalization*) por la normalización de capas (*Layer Normalization*), y el uso de funciones de activación más suaves. El resultado es una red que sostiene la propia eficiencia computacional de las *CNNs*, pero que logra igualar o incluso superar la precisión de arquitecturas basadas en mecanismos de atención como *Swin Transformer*.

2.6.3. Agregación temporal para clasificación de vídeo

Cuando estas arquitecturas de imagen estática se aplican a la clasificación de vídeos (como es el caso de este trabajo), el sistema emite una predicción matemática probabilística de forma aislada para cada fotograma extraído de la secuencia temporal. Dado que el objetivo final es emitir un único veredicto global para todo el archivo multimedia, resulta teóricamente indispensable aplicar heurísticas de agregación o *pooling*.

En la literatura científica, las estrategias de consolidación más habituales para agrupar estas predicciones independientes son:

- **Max-Pooling (sensibilidad máxima)**: Consiste en evaluar el valor máximo de probabilidad de toda la secuencia. Entonces, si un solo fotograma contiene evidencias claras que superan el umbral de activación, todo el vídeo hereda dicha clasificación. Es ideal para detectar anomalías o infracciones breves pero críticas.
- **Average-Pooling (Promedio continuo)**: Se calcula la media aritmética de las probabilidades de todos los fotogramas. Esta técnica exige que el contenido mantenga un nivel de confianza sostenido a lo largo del tiempo para influir en el veredicto final.
- **Majority Vote (votación por mayoría)**: Cada fotograma emite un voto discreto (positivo o negativo). El vídeo adopta la clasificación que haya obtenido si supera un umbral definido previamente (lo que se consideraría como mayoría). Es una estrategia altamente robusta frente a fotogramas ruidosos, corruptos o atípicos (*outliers*).

Los detalles específicos sobre la selección de estos modelos, el volumen de fotogramas extraídos por vídeo y la implementación práctica de estas métricas de agregación se detallarán exhaustivamente en el capítulo correspondiente a la metodología experimental.

2.7. Modelos Avanzados para Visión Temporal (Vídeos)

Aunque el análisis basado en la extracción de fotogramas estáticos reduce drásticamente la carga computacional, esta metodología descarta una dimensión fundamental de los archivos multimedia: la progresión temporal. Para comprender acciones complejas, ironías o comportamientos que se desarrollan a lo largo de un clip, los sistemas de inteligencia artificial deben ser capaces de modelar conjuntamente el espacio (los píxeles en un instante dado) y el tiempo (la evolución de dichos píxeles a través de los fotogramas). En esta sección se abordan las arquitecturas modernas diseñadas para procesar el vídeo como un volumen continuo.

2.7.1. Adaptación de la Arquitectura *Transformer* al Vídeo

La aplicación directa del mecanismo de *self-attention* a todos los píxeles de todos los fotogramas de un vídeo resulta computacionalmente inviable, ya que la complejidad matemática crece de forma cuadrática respecto a la longitud de la secuencia de entrada. Para solucionar este enorme cuello de botella, la literatura científica ha propuesto adaptaciones eficientes que extienden el éxito del *ViT* al ámbito tridimensional.




Figura 2.7: Ilustración de los mecanismos de atención de un *TimeSformer* (Fuente: [55])

Dentro de este campo, destacan dos enfoques arquitectónicos fundamentales implementados en el desarrollo de este trabajo:

- **TimeSformer (Time-Space Transformer)**: Propuesto por investigadores de *Facebook* [55], este modelo resuelve el problema de la explosión paramétrica mediante la **atención dividida**. En lugar de comparar cada parche con todos los demás parches del vídeo simultáneamente, *TimeSformer* realiza el cálculo en dos pasos: primero aplica una atención puramente espacial (comparando los parches dentro de un mismo fotograma) y, a continuación, aplica una atención puramente temporal (comparando el mismo parche exclusivamente con sus homólogos en los fotogramas anteriores y posteriores), tal y como se puede observar en la [Figura 2.7](#).
- **ViViT (Video Vision Transformer)**: Desarrollado por investigadores de *Google* [56], es la evolución directa del *ViT* estático. Su mayor innovación es el cambio en la forma de extraer las características iniciales: en lugar de dividir la imagen en parches bidimensionales (2D), *ViViT* extrae lo que se conoce como **Tubelets** o tubos tridimensionales. Como se puede apreciar en la [Figura 2.8](#), estos tubos agrupan un bloque de píxeles que atraviesa varios fotogramas consecutivos, permitiendo a la red capturar dinámicas espaciotemporales (como la dirección y la velocidad de un movimiento) desde la primera capa del codificador.




Figura 2.8: Representación de los *Tubelets* de los *ViViT* (Fuente: [56])

2.7.2. Enfoques Basados en Autoencoders Enmascarados

Paralelamente a las adaptaciones topológicas del *Transformer*, el entrenamiento de modelos de vídeo ha experimentado una gran revolución gracias a las técnicas de aprendizaje autosupervisado. El principal reto del aprendizaje en vídeo es la **redundancia de la información**: dos fotogramas consecutivos suelen ser casi idénticos, lo que provoca que las redes neuronales colapsen o memoricen atajos visuales en lugar de aprender características

profundas.

Para combatir este fenómeno, surgieron modelos como *VideoMAE* (*Video Masked Autoencoders*) [57], una arquitectura inspirada en los métodos de entrenamiento con enmascaramiento nacidos en el PLN (como *BERT*).

El funcionamiento de *VideoMAE* se basa en un paradigma de reconstrucción extrema. Tal y como podemos observar en la [Figura 2.9](#), el modelo toma un volumen de vídeo (dividido en cubos espaciotemporales) y **oculta deliberadamente hasta el 90 % de la información**. El codificador (*encoder*) solo procesa el 10 % de los parches visibles, y posteriormente, un decodificador (*decoder*) es forzado a reconstruir todos los píxeles originales que faltan. Este nivel de enmascaramiento tan agresivo impide que la red se apoye en la redundancia temporal de los píxeles vecinos, obligándola a desarrollar una comprensión semántica de muy alto nivel sobre la física, el movimiento y la estructura de los objetos que aparecen en pantalla.




Figura 2.9: Arquitectura de *VideoMAE* (Fuente: [57])

2.8. Aprendizaje por Transferencia

El aprendizaje por transferencia (*Transfer Learning*) ha revolucionado el desarrollo de la inteligencia artificial, consolidándose como el enfoque estándar en el PLN, la Visión Artificial y el aprendizaje multimodal [58]. Este paradigma consiste en reutilizar el conocimiento previamente adquirido por un modelo computacional al resolver una tarea genérica (generalmente entrenado con volúmenes de datos masivos) para aplicarlo a la resolución de una tarea nueva y específica, la cual suele disponer de una cantidad mucho menor de datos etiquetados.

Históricamente, el desarrollo de sistemas de aprendizaje profundo exigía inicializar los pesos de las redes neuronales de forma aleatoria y entrenarlas desde cero, un proceso que requería un enorme coste computacional y bases de datos gigantescas para evitar el sobreajuste. El aprendizaje por transferencia elimina esta barrera: en lugar de aprender a extraer características desde la nada, se parte de un modelo preentrenado que ya posee representaciones universales del lenguaje (como es el caso de *BERT*, *RoBERTa* o *GPT*) o de las imágenes [59]. Este conocimiento base se transfiere y se refina para la nueva tarea,

permitiendo democratizar el uso de modelos masivos y obtener resultados competitivos con tiempos de entrenamiento significativamente menores.

2.8.1. Fine-tuning y optimización de hiperparámetros

Dentro del aprendizaje por transferencia, la estrategia de adaptación más utilizada y efectiva es el ajuste fino o *fine-tuning*. Este proceso, popularizado en el PLN por enfoques como ULMFiT [60], consiste en tomar la arquitectura de un modelo preentrenado, añadirle una nueva capa de salida orientada a la tarea específica a resolver (por ejemplo, una capa de clasificación binaria) y ajustar los pesos internos de toda la red, o de una parte de ella, utilizando un conjunto de datos propio del dominio.

Sin embargo, la literatura científica ha demostrado que modelos masivos como *BERT* o *RoBERTa* son altamente inestables y sensibles durante esta fase de adaptación [61]. Para que el *fine-tuning* sea exitoso y el modelo no “olvide” catastróficamente lo que aprendió en su preentrenamiento, resulta de gran utilidad realizar un proceso de **Optimización de Hiperparámetros** (*HPO*). A nivel teórico, existen diversas estrategias para explorar el espacio de hiperparámetros: desde la búsqueda exhaustiva (*Grid Search*) y la búsqueda aleatoria (*Random Search*), hasta métodos avanzados como la optimización bayesiana, que modela probabilísticamente el rendimiento de combinaciones pasadas para guiar la búsqueda de forma inteligente [62].

Durante este proceso de optimización, las variables de configuración que rigen cómo aprende el algoritmo son determinantes y se dividen en:

- Por un lado, parámetros estructurales como el *Learning Rate*, *Weight Decay* y *Epochs*, que ya fueron definidos en la [Subsección 2.3.2](#) y [Subsección 2.3.1](#) respectivamente.
- Por otro lado tenemos:
 - **Calentamiento** (*Warmup*): Consiste en iniciar el entrenamiento con una tasa de aprendizaje cercana a cero y aumentarla gradualmente durante un porcentaje inicial de los pasos, evitando actualizaciones bruscas que desestabilicen el modelo.
 - **Planificador de la tasa** (*LR Scheduler*): Algoritmo que ajusta de forma dinámica la tasa de aprendizaje a medida que avanzan las épocas (por ejemplo, reduciéndola de forma lineal o mediante una curva coseno).

Estrategias avanzadas de optimización

En la práctica empírica de entrenamiento de modelos masivos como los de visión estática y los de visión temporal, la combinación de estos hiperparámetros ha dado lugar a estrategias

de ajuste específicas:

- **Estrategia conservadora o *Slow Cooker***: Consiste en someter al modelo a un entrenamiento prolongado (mayor número de épocas) utilizando un *learning rate* muy bajo y un *weight decay* excepcionalmente alto (regularización agresiva). Se acompaña de un periodo de *warmup* prolongado. Es ideal para que el modelo aprenda patrones complejos y sutilezas en conjuntos de datos difíciles sin memorizarlos.
- **Simulación de lotes masivos (*Gradient Accumulation*)**: La memoria de las tarjetas gráficas (*VRAM*) suele limitar el tamaño del lote de datos (*batch size*) que se puede procesar simultáneamente. Para lograr gradientes matemáticamente estables como los que ofrecería un lote masivo, se acumulan los gradientes de varios lotes pequeños durante múltiples iteraciones antes de ejecutar la actualización de los pesos.
- **Ajuste agresivo o *Sprint Final***: Se utiliza una combinación de *learning rate* y regularización moderadas, pero aplicando un planificador tipo coseno (*Cosine Scheduler*). Tras un calentamiento inicial, la tasa de aprendizaje se mantiene estable para luego decaer rápida y suavemente hacia el final, exprimiendo el máximo rendimiento de la red en las últimas iteraciones.

Los valores de los hiperparámetros en cada una de las estrategias se pueden apreciar en la [Tabla 2.1](#).

Hiperparámetro	<i>Slow Cooker</i>	<i>Gradient Accumulation</i>	<i>Sprint Final</i>
<i>learning_rate</i>	3e-5	5e-5	5e-5
<i>weight_decay</i>	0.1	0.01	0.05
<i>num_train_epochs</i>	8	7	6
<i>warmup_ratio</i>	0.1	0	0.1
<i>gradient_accumulation_steps</i>	2	4	2
<i>lr_scheduler_type</i>	<i>linear</i>	<i>linear</i>	<i>cosine</i>

Tabla 2.1: Hiperparámetros de las estrategias avanzadas de optimización

2.9. Ensemble de Modelos y Fusión multimodal

En el ámbito del aprendizaje automático, la técnica de *ensemble* (conjunto de modelos) consiste en combinar las predicciones de múltiples algoritmos diversos para generar una única decisión final más robusta, estable y precisa [63]. La premisa matemática detrás de esta técnica es que, al agregar diferentes perspectivas, los errores individuales de cada modelo se compensan mutuamente, reduciendo la varianza y mitigando los sesgos específicos de cada arquitectura.

En el contexto del análisis del discurso de odio en redes sociales, la información es

inherentemente multimodal. Un vídeo no se compone de una única fuente de información, sino que abarca la transcripción textual del audio, la composición visual de sus fotogramas estáticos y la evolución temporal de sus movimientos.

2.9.1. Ventajas de los *Transformers* en tareas multimodales

La capacidad de los *Transformers* y de las modernas arquitecturas convolucionales para manejar secuencias de cualquier tipo y capturar dependencias a largo plazo los convierte en herramientas extremadamente potentes para tareas multimodales. En lugar de depender de un único modelo monolítico que intente comprender todo a la vez, la tendencia actual se orienta a utilizar arquitecturas expertas dedicadas que procesan el texto, la imagen y el vídeo en paralelo, combinando su información a posteriori para realizar predicciones conjuntas. Este enfoque permite capturar con una altísima precisión las relaciones y contradicciones entre lo que se dice en la transcripción de un vídeo y lo que se muestra en su componente visual.

2.9.2. Fusión Temprana vs Fusión Tardía

A nivel teórico, la integración de múltiples modalidades de datos se divide principalmente en dos tipos [64]:

- **Fusión Temprana (*Early Fusion*)**: Los datos o características extraídas de diferentes modalidades se combinan en las primeras etapas de la red neuronal, creando un vector unificado que es procesado por un único clasificador final. Aunque permite que el modelo aprenda interacciones cruzadas desde el principio, es computacionalmente muy costoso y propenso al *overfitting* si una modalidad domina sobre las demás.
- **Fusión Tardía (*Late Fusion*)**: Cada modalidad es procesada por un modelo experto independiente hasta generar una predicción final (una probabilidad matemática). Posteriormente, estas probabilidades aisladas se combinan mediante algoritmos estadísticos para emitir el veredicto definitivo.

En la práctica empírica y en las competiciones de Ciencia de Datos, el *late fusion* mediante predicción estática se ha estandarizado como la metodología más eficiente. Al separar la fase de inferencia de la fase de combinación, esta técnica permite ajustar y recalcular el peso de **cada modelo** miles de veces en cuestión de milisegundos, sin necesidad de repetir la costosa fase de extracción de características y cómputo matemático en la unidad de procesamiento gráfico (GPU), optimizando así tanto el tiempo de ejecución como el consumo de memoria de vídeo (*VRAM*).

Promedio Ponderado (*Weighted Average*)

Una de las estrategias matemáticas más utilizadas en la fusión tardía es el promedio ponderado. En este método, a la probabilidad emitida por cada modelo experto se le asigna un peso específico (w) que refleja su nivel de fiabilidad o importancia empírica en el conjunto del sistema. Matemáticamente, la probabilidad final unificada se calcula del siguiente modo:

$$P_{final} = (w_{texto} \cdot P_{texto}) + (w_{imagen} \cdot P_{imagen}) + (w_{video} \cdot P_{video}) \quad (2.1)$$

Sujeto a la restricción de que la suma de todos los pesos sea exactamente 1. Los valores óptimos de estos pesos no se definen arbitrariamente, sino que se descubren mediante algoritmos de búsqueda y validación cruzada que evalúan qué combinación exacta maximiza las métricas de rendimiento sobre un conjunto de datos estático.

2.10. Subjetividad en la anotación de los datos

En los sistemas de aprendizaje automático tradicionales, se asume que existe una única “verdad absoluta” para cada conjunto de datos. Sin embargo, en tareas vinculadas al PLN que involucren un alto componente subjetivo, como la detección del discurso de odio, el sexismo o la toxicidad, esta premisa se desvanece. La percepción de un mensaje como ofensivo está intrínsecamente ligada a la sensibilidad, el contexto cultural y las experiencias vitales de la persona que lo evalúa. Por tanto, el desacuerdo entre los anotadores humanos no debe considerarse necesariamente como un “ruido” o un error en el conjunto de datos, sino como una señal valiosa que refleja la ambigüedad real del lenguaje humano.

2.10.1. Aprendizaje con Desacuerdo (*Learning with Disagreement*)

Para gestionar esta multiplicidad de opiniones en la fase de entrenamiento de los modelos, el estado del arte ha evolucionado desde el consenso estricto hacia el **Aprendizaje con Desacuerdo** (*Learning with Disagreement* o *LeWiDi*) [65]. A nivel teórico, el tratamiento de las etiquetas asignadas por múltiples anotadores se aborda mediante distintas estrategias:

- **Hard Labels (Etiquetas rígidas o por Consenso)**: Consiste en fusionar las opiniones de los diferentes evaluadores en una única etiqueta definitiva. La técnica más común es el **voto por mayoría** (si dos de tres anotadores consideran un texto como sexista, la etiqueta final será positiva). En los casos donde existe un empate exacto (por ejemplo, un anotador vota a favor y otro en contra), las estrategias tradicionales

optan por descartar la muestra para evitar confundir al modelo. Como alternativa, se pueden aplicar heurísticas de desempate sesgadas hacia la sensibilidad de la tarea: un enfoque pesimista (ante la duda, se cataloga como sexismo) o un enfoque optimista (ante la duda, se absuelve el comentario).

- **Soft Labels (Etiquetas Probabilísticas):** En lugar de forzar una etiqueta binaria (0 o 1), el modelo se entrena para predecir la distribución de probabilidad de los anotadores. Si tres personas evalúan un texto y dos lo marcan como sexista, la etiqueta *soft* será 0.66. Esto enseña a la red neuronal a medir el grado de polarización o ambigüedad de un mensaje.
- **Desenrollado o Unrolling:** Una estrategia de aumento de datos que evita la pérdida de información de las minorías. Consiste en duplicar el registro original tantas veces como anotadores lo hayan evaluado, asignando a cada copia la etiqueta individual de un anotador diferente. De este modo, la red neuronal se expone a todas las perspectivas humanas sin forzar un consenso matemático.

2.10.2. Perspectivismo en Inteligencia Artificial

Aunque frecuentemente están ligados en la literatura, es fundamental establecer la diferencia teórica entre el Aprendizaje con Desacuerdo (*LeWiDi*) y el Perspectivismo (*Data Perspectivism*) [66]. Mientras que *LeWiDi* es un marco metodológico enfocado en cómo gestionar la multiplicidad de etiquetas (preservando la varianza matemática sin importar si el desacuerdo proviene de un error del anotador, ambigüedad sintáctica o factores sociales), el perspectivismo se centra en el origen subyacente de dicho desacuerdo. Por tanto, no todo *LeWiDi* implica un análisis demográfico.

El perspectivismo es una corriente reciente en la inteligencia artificial que sostiene que gran parte del desacuerdo no es aleatorio, sino que las características sociodemográficas de los anotadores (como su género, edad, raza o nivel educativo) condicionan radicalmente sus respuestas. En la detección de sexismo, por ejemplo, la perspectiva de una mujer y la de un hombre frente a un mismo texto pueden diferir por completo debido a sus vivencias. El perspectivismo se apoya en las técnicas algorítmicas de *LeWiDi* para lograr modelar y representar estas visiones sociológicas del mundo.

Para capturar y representar estas visiones dependiendo de la naturaleza de la arquitectura utilizada, la literatura propone distintas metodologías de modelado:

- **Segmentación demográfica para modelos discriminativos *Transformers*:** Consiste en dividir y filtrar el conjunto de datos de entrenamiento basándose exclusivamente en el perfil demográfico de los anotadores (por ejemplo, filtrando solo los votos emitidos por mujeres o solo por hombres). A partir de estos subconjuntos, se entrenan modelos discriminativos independientes. Esto da como resultado arquitect-

turas “expertas” que han interiorizado la sensibilidad y los sesgos propios de un único grupo demográfico.

- **Asignación de roles para Modelos Generativos (*LLMs*)**: Los grandes modelos de lenguaje han interiorizado múltiples perspectivas durante su preentrenamiento masivo. Para evocar una visión demográfica específica sin necesidad de reentrenar la red, se utiliza la técnica de *Persona Prompting* (ingeniería de instrucciones basada en roles) [67]. Al inyectar directrices explícitas en el *prompt* del sistema (instruyendo al modelo para que “actúe como un hombre” o “actúe como una mujer”), se condiciona la generación de texto para que adopte patrones lingüísticos asociados estadísticamente a ese rol. No obstante, es fundamental matizar que esta técnica simplemente guía las salidas textuales del modelo basándose en las correlaciones de sus datos de entrenamiento, pero no equivale a autenticar ni reproducir un sesgo cognitivo o una perspectiva humana real.

2.11. Medidas de Evaluación

Para cuantificar de manera rigurosa y objetiva el rendimiento de los modelos desarrollados en este trabajo, se utilizan métricas estándar derivadas del aprendizaje automático. La elección de una métrica adecuada es un paso crítico en el diseño experimental, ya que no todas las medidas son igualmente válidas en todos los contextos. En tareas sensibles como la detección del discurso de odio o el sexismo, donde los conjuntos de datos suelen presentar un fuerte desbalanceo (con una presencia mayoritaria de comentarios no sexistas frente a los sexistas), basarse en métricas simples puede ofrecer una falsa sensación de eficacia algorítmica. Por ello, es necesario definir medidas específicas adaptadas a la topología de la tarea: clasificación binaria, multitiqueta o evaluación con desacuerdo.

2.11.1. *Accuracy*, Precisión, Exhaustividad y *F1-Score*

En las tareas de clasificación binaria (como determinar si un contenido es o no es sexista), la evaluación parte de la matriz de confusión, la cual clasifica las predicciones en Verdaderos Positivos (*TP*), Verdaderos Negativos (*TN*), Falsos Positivos (*FP*) y Falsos Negativos (*FN*). A partir de estos valores se derivan las siguientes métricas teóricas [68]:

- **Exactitud (*Accuracy*)**: Mide el porcentaje total de predicciones correctas sobre el total de casos evaluados. Aunque es intuitiva, resulta engañosa en conjuntos de datos desbalanceados.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.2)$$

- **Precisión (*Precision*)**: Evalúa la proporción de identificaciones positivas que fue-

ron realmente correctas. Es fundamental cuando el coste de un Falso Positivo es inaceptable.

$$Precision = \frac{TP}{TP + FP} \quad (2.3)$$

- **Exhaustividad (*Recall*)**: Mide la proporción de positivos reales que el modelo logró identificar correctamente. En la detección de discursos de odio, un alto *recall* es vital para garantizar que ningún comentario dañino (Falso Negativo) pase desapercibido.

$$Recall = \frac{TP}{TP + FN} \quad (2.4)$$

- **F1-Score**: Representa la media armónica entre la precisión y el *recall*. Es la métrica estándar por excelencia en el PLN para lidiar con el desbalanceo de clases, ya que penaliza fuertemente a los modelos que favorecen una métrica a costa de destruir la otra.

$$F1-score = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (2.5)$$

2.11.2. Evaluación en clasificación multietiqueta

En el caso de clasificación multietiqueta (donde una misma instancia puede pertenecer a múltiples categorías simultáneamente), la evaluación matemática se vuelve más compleja. Para abordar este problema se utilizan las siguientes variantes [69]:

- **F1 Macro (*Macro-F1*)**: Calcula el *F1-Score* de manera independiente para cada clase o etiqueta y, posteriormente, extrae la media aritmética no ponderada. Esta aproximación otorga exactamente el mismo peso a todas las clases, independientemente de su frecuencia, lo que la hace ideal para evaluar si el modelo es capaz de detectar las categorías minoritarias.

$$Macro\ F1 = \frac{1}{C} \sum_{c=1}^C F1_c \quad (2.6)$$

Donde C es el número total de clases posibles.

- **F1 Micro (*Micro-F1*)**: Agrega globalmente las contribuciones de todas las clases sumando los verdaderos positivos, falsos negativos y falsos positivos antes de calcular la métrica. Está fuertemente influenciada por las clases mayoritarias.
- **Exact Match Ratio (Tasa de coincidencia exacta)**: Es la métrica multietiqueta más estricta. Un acierto solo se contabiliza si el conjunto de etiquetas predichas por el modelo coincide de forma absoluta e idéntica con el conjunto de etiquetas reales

de la instancia.

$$Exact\ Match = \frac{1}{N} \sum_{i=1}^N I(Y_i = \hat{Y}_i) \quad (2.7)$$

Donde I es la función indicadora que devuelve 1 si los conjuntos son idénticos y 0 en caso contrario.

2.11.3. Métricas para evaluación con desacuerdo

Cuando se abandona el paradigma del consenso absoluto y se entrena a los modelos utilizando *Soft Labels*, las métricas tradicionales basadas en coincidencias binarias (como el *Accuracy* o el *F1-score*) dejan de ser completamente representativas. En estos escenarios, el objetivo es medir qué tan bien se alinea la predicción del modelo con la distribución real de los anotadores humanos.

Durante el entrenamiento, esta alineación se optimiza habitualmente utilizando la **Entropía Cruzada** (*Cross-Entropy*) como función de pérdida. Esta métrica penaliza matemáticamente las divergencias entre la probabilidad predicha por el modelo ($\hat{y}$) y la opinión humana real (y):

$$CE(y, \hat{y}) = - \sum_{c=1}^C y_c \log(\hat{y}_c) \quad (2.8)$$

Sin embargo, para la evaluación final en el marco de competencias recientes de análisis de subjetividad (como la tarea *EXIST*), el rendimiento no se mide con la entropía cruzada, sino que se cuantifica mediante la métrica **ICM** (*Information Contrast Measure*), fundamentada metodológicamente por Amigó y Delgado [70]. A diferencia de las funciones de pérdida estándar, el *ICM* se basa en la teoría de la información para evaluar la cantidad de información útil que las predicciones del modelo aportan frente a un modelo base o aleatorio.

Para abarcar las distintas naturalezas de salida de los sistemas de clasificación, la métrica se divide en dos variantes:

- **ICM-Hard**: Diseñada para evaluar las predicciones categóricas o rígidas (0 o 1). Mide el contraste de información de la etiqueta absoluta elegida por el modelo frente a la distribución real de los anotadores, penalizando de forma severa aquellas respuestas que contradicen frontalmente a la opinión mayoritaria.
- **ICM-Soft**: Diseñada para evaluar las predicciones probabilísticas. Si el modelo logra predecir con exactitud la incertidumbre y el grado de polarización (por ejemplo, arrojando un 60 % de probabilidad de sexismo en un mensaje altamente debatido por los humanos), el *ICM-Soft* recompensa esta flexibilidad del modelo, validando

que la máquina ha comprendido de manera correcta la ambigüedad inherente al lenguaje natural.

2.12. Tecnologías y Recursos Utilizados

El desarrollo de este proyecto se ha llevado a cabo utilizando un conjunto de herramientas y bibliotecas de código abierto ampliamente integradas en el ámbito de la inteligencia artificial, el PLN y la visión por computador. Más que una simple enumeración, estas tecnologías conforman un ecosistema cohesionado que ha permitido desde el preprocesamiento de los datos hasta el despliegue de modelos masivos.



Figura 2.10: Tecnologías usadas para el desarrollo del TFM

Como se puede observar en la [Figura 2.10](#), las principales herramientas utilizadas han sido las siguientes:

- **Python:** Lenguaje de programación principal de todo el proyecto, elegido por su flexibilidad, su inmenso ecosistema de librerías científicas y su estandarización absoluta en la comunidad de *Data Science* y el aprendizaje automático.
- **Google Colab Pro y Jupyter Notebook:** Como entorno de desarrollo interactivo se han utilizado cuadernos de *Jupyter* a través de la plataforma *Google Colab*. En concreto, se ha hecho uso de recursos avanzados (aceleradores de hardware como las *GPU NVIDIA L4*) para llevar a cabo el entrenamiento de modelos masivos. En total se han consumido unas 300 unidades informáticas.
- **PyTorch: Framework** de *Deep Learning* que ha servido como núcleo matemático para construir, entrenar y evaluar todos los modelos basados en *Transformers* imple-

mentados en la fase empírica.

- **Ecosistema *Hugging Face***: Plataforma y conjunto de bibliotecas clave en el proyecto. Se ha utilizado para importar modelos preentrenados (*Mistral*, *Llama*, *Gemma*, *ConvNeXt*, etc.), aplicar técnicas de *PEFT* mediante inserción de matrices de bajo rango, ejecutar optimizadores supervisados como *SFTTrainer*, y formatear eficientemente los conjuntos de datos.
- ***BitsAndBytes***: Librería fundamental de optimización de hardware que ha permitido aplicar la técnica de cuantización *QLoRA*, reduciendo los pesos de los *LLMs* a una precisión de 4 bits para que pudieran ser procesados en la memoria de la tarjeta gráfica disponible.
- ***Decord* y *OpenCV (cv2)***: Bibliotecas especializadas en el procesamiento audiovisual. Han sido fundamentales para el tratamiento de la modalidad de vídeo, permitiendo una lectura optimizada de los archivos multimedia y la extracción precisa de los fotogramas clave (*frames*) requeridos por los modelos visuales.
- ***Scikit-Learn* y *Evaluate***: Herramientas de análisis de datos utilizadas en la fase de evaluación para computar métricas complejas de rendimiento (*F1-Score*, *Accuracy*, matrices de confusión) sobre los conjuntos de prueba estáticos.
- ***Google Drive***: Sistema de almacenamiento en la nube utilizado como repositorio de datos centralizado. Ha servido para alojar, gestionar y sincronizar todos los conjuntos de datos (*datasets*), los pesos de los modelos guardados y los archivos generados durante la experimentación, permitiendo una integración y un acceso directo desde los entornos de *Google Colab*.
- ***GitHub***: Plataforma de desarrollo colaborativo y control de versiones. Se ha empleado para estructurar de forma metódica y segura el proyecto mediante repositorios independientes: uno destinado a la centralización del código fuente y los cuadernos de experimentación ¹, y otro para el control de versiones de la presente memoria ².
- ***L^AT_EX***: Sistema de composición de textos utilizado para la redacción, estructuración y maquetación de esta memoria. Su elección garantiza un formato académico riguroso, así como una gestión impecable de las referencias bibliográficas y la representación de fórmulas matemáticas.

A modo de conclusión, en este capítulo se han establecido los fundamentos teóricos necesarios para comprender los enfoques tecnológicos implementados a lo largo del proyecto. Esta base conceptual resulta indispensable para justificar las decisiones técnicas, algorítmicas y metodológicas que se abordarán en detalle en el próximo capítulo.

¹<https://github.com/visumania/DeepSexist>

²<https://github.com/visumania/MemoriaTFM>

Metodología, Experimentación y Resultados

Este capítulo detalla el núcleo práctico y experimental del presente Trabajo de Fin de Máster. A lo largo de las siguientes secciones, se describe exhaustivamente la metodología aplicada para abordar la detección y clasificación del discurso sexista en redes sociales. En primer lugar, se contextualiza el marco del proyecto dentro del desafío de *EXIST 2025*. A continuación, se expone el pipeline de preparación de los datos y se desglosan los experimentos realizados de forma unimodal (abarcando el procesamiento de texto, imágenes estáticas y secuencias de vídeo). Finalmente, se detalla la integración de estas arquitecturas mediante técnicas de fusión multimodal, culminando con un análisis profundo sobre el perspectivismo de los datos y la presentación de los resultados globales obtenidos.

3.1. Participación en el desafío *EXIST 2025*

El presente trabajo se ha desarrollado en el marco del desafío internacional *EXIST 2025* (*sEXism Identification in Social neTworks*). Esta iniciativa tiene como objetivo principal pedir a los participantes que identifiquen y caractericen el sexismo en las redes sociales. Su propósito fundamental es ayudar a identificar tendencias y patrones de comportamiento sexista en diversos formatos multimedia y de interacción de usuarios, contribuyendo así a una comprensión más profunda de estas dinámicas sociales y a su potencial aplicabilidad en sistemas de moderación de contenido.

Estructura del reto y modalidades

En su edición de 2025, la organización ha dado un salto cualitativo hacia la multimodalidad, conformando un total de nueve subtarefas disponibles en dos idiomas (inglés y español). Estas subtarefas se estructuran en torno a tres ejes principales (Identificación de sexismo, Detección de la intención de la fuente y Categorización del sexismo) aplicadas a tres tipos de datos diferentes:

- **Tarea 1 (Texto):** Centrada en el análisis de *tweets*.

- **Tarea 2 (Imágenes):** Enfocada en la evaluación de memes, extrayendo su información visual y textual mediante *OCR*.
- **Tarea 3 (Vídeos):** Basada en archivos multimedia extraídos de la plataforma *TikTok*.

Esta aproximación completamente multimedia resulta esencial para evaluar la capacidad real de los sistemas a la hora de detectar la subjetividad y la ofensa en fuentes de datos complejas.

Participación global y datos del reto

La relevancia de esta edición quedó demostrada por un nivel de implicación excepcional en la comunidad científica. Un total de 244 equipos de 38 países se registraron en *EXIST 2025*, de los cuales 114 (procedentes de 23 países) lograron enviar al menos una entrega (*run*) oficial. En conjunto, se recibieron 873 envíos, de los cuales 589 se evaluaron mediante *Hard-labels* y 284 mediante *Soft-labels*.

Aunque la mayoría de los participantes concentraron sus esfuerzos en el análisis puramente textual de la Tarea 1 (596 envíos evaluados), la Tarea 3 dedicada al análisis de vídeo atrajo un interés significativo con 211 envíos, lo que subraya la creciente relevancia de los enfoques multimodales en el PLN.

Nuestras entregas oficiales y motivación del TFM

En el contexto oficial del desafío, la participación de nuestro equipo (*I2C-UHU*) se enmarcó dentro de la Tarea 3 de vídeos, concretamente en la **Subtarea 3.1 (Identificación de Sexismo)**. Se trata de un problema de clasificación binaria donde el sistema debe decidir si un contenido dado refleja expresiones o comportamientos sexistas, clasificándolo bajo las categorías “YES” o “NO”.

Para nuestras dos entregas oficiales, se optó por un enfoque inicial unimodal, evaluando la capacidad de la transcripción textual del vídeo para resolver la tarea. Se realizaron los siguientes envíos bajo la evaluación *Hard*:

1. **I2C-UHU-Sirius_1:** Un modelo discriminativo de la familia *Transformer* (**bert-base-multilingual-cased**), ajustado mediante *fine-tuning* para la clasificación de secuencias.
2. **I2C-UHU-Sirius_2:** Un *LLM* generativo (**meta-llama/Llama-3.2-1B-Instruct**), evaluado bajo un enfoque *Zero-Shot* mediante técnicas de *Prompt Engineering*.

En la [Tabla 3.1](#) se detallan las métricas oficiales obtenidas por nuestros sistemas en la evaluación oficial sobre un total de 43 participaciones admitidas en la tabla de clasificación

(*leaderboard*) para esta subtarea. Cabe destacar que estas métricas oficiales basadas en *ICM-Hard* y el *F1* de la clase *YES* responden a un protocolo específico (el definido por la organización) y no son directamente comparables con los resultados locales obtenidos en fases posteriores de este trabajo (medidos habitualmente mediante *macro-F1*).

Envío Oficial	Ranking	ICM-Hard	ICM-Hard Norm	F1 (Clase YES)
(<i>BERT</i>)	31	-0.1278	0.4355	0.5768
(<i>Llama</i>)	39	-0.4212	0.2874	0.1379

Tabla 3.1: Resultados oficiales obtenidos en la Subtarea 3.1 de EXIST 2025

Lejos de ser el objetivo final de esta investigación, la participación en el desafío y los resultados expuestos actuaron como el *baseline* de este Trabajo de Fin de Máster. Las métricas alcanzadas (en especial el bajo rendimiento del enfoque *Zero-Shot*) permiten plantear la hipótesis de que la restricción metodológica a un formato exclusivamente textual (sumada a factores simultáneos como el tamaño del modelo, el diseño del *prompt*, la ausencia de ajuste fino y la naturaleza específica del conjunto de validación) pudo influir en los resultados. Esta comprobación preliminar sirvió de base para motivar y justificar el posterior trabajo empírico, desarrollado en esta memoria: la extracción de fotogramas, la experimentación profunda con modelos de visión estática y temporal, la integración mediante *Ensembles* y el análisis de la subjetividad de los anotadores.

3.2. Descripción General de la Metodología




Figura 3.1: Pipeline general del marco de experimentación

El marco de experimentación diseñado para este Trabajo de Fin de Máster se ha dividido en un flujo de trabajo iterativo e incremental: comenzando por el preprocesamiento de los datos, pasando por el diseño y entrenamiento de modelos unimodales, y culminando con la fusión multimodal y la evaluación del rendimiento bajo diferentes perspectivas. En esta sección se ofrece una visión general del proceso completo, el cual será detallado en profundidad en secciones posteriores.

La [Figura 3.1](#) muestra el *pipeline* del marco de experimentación seguido en este trabajo.

De forma estructurada, la secuencia completa de procesos abordada para resolver la

detección y categorización del discurso sexista se divide en las siguientes fases principales:

1. **Preparación y Tratamiento de Datos:** Esta fase inicial engloba la limpieza del corpus textual, la estandarización del conjunto de datos mediante una división estratificada (conjuntos de *Train* y *Test* de desarrollo para garantizar la reproducibilidad) y la extracción automatizada de características visuales. Para esto último, se procesaron los archivos multimedia generando diferentes conjuntos de *frames*.
2. **Selección y Entrenamiento Unimodal:** Ante la complejidad del formato vídeo, se optó por la estrategia de “divide y vencerás”, seleccionando y entrenando arquitecturas expertas para cada modalidad de forma aislada:
 - *Modalidad de texto:* Experimentación con modelos discriminativos multilingües (familia *Transformer*) y modelos generativos masivos (*LLMs*).
 - *Modalidad de Visión Estática y Temporal:* Ajuste de modelos convolucionales de imágenes y redes especializadas en vídeo para captar el contexto visual del problema.
3. **Ajuste de Hiperparámetros:** Proceso crítico aplicado a los mejores modelos base seleccionados en la fase anterior. Implicó la exploración del espacio de hiperparámetros (*learning rate*, *weight decay*, *warmup*) para lograr un *fine-tuning* estable, evitando el olvido catastrófico del conocimiento previo de las redes.
4. **Fusión Multimodal (*Ensemble*):** Etapa de consolidación donde las predicciones aisladas de los modelos de texto, imagen y vídeo se combinaron en un único sistema robusto mediante una estrategia de *Late Fusion*, optimizando matemáticamente los pesos de cada modalidad para la Tarea 3.1.
5. **Perspectivismo y Análisis de Errores:** Aprovechando el *LeWiDi* del conjunto de datos original, se volvieron a entrenar las mejores arquitecturas de la modalidad de texto segmentando los datos en función del género de los anotadores (perspectiva de hombres frente a mujeres) y se inyectaron roles en los *LLMs* mediante *Persona Prompting* para analizar la subjetividad de los fallos del sistema.
6. **Evaluación y Experimentación Multietiqueta:** Fase final orientada a cuantificar el rendimiento mediante métricas estándar sobre los conjuntos estáticos y a adaptar los mejores modelos unimodales para resolver el problema secundario de la Tarea 3.3 (clasificación independiente de las distintas categorías del sexismo).

3.3. Preparación de los Datos

El rendimiento de los modelos de *deep learning* depende de la calidad y el formato de los datos con los que son entrenados. Por ello, antes de proceder a la fase de modelado, se diseñó un riguroso *pipeline* de preparación. Esta sección detalla la exploración inicial del

conjunto proporcionado, la resolución de conflictos con las etiquetas, el preprocesado de las transcripciones textuales y la extracción estructurada de las características visuales a partir de los vídeos originales.

3.3.1. Descripción del Conjunto de Datos y División (*Train* y *Test*)

	0
id_Tiktok	7281385962049998086
id_EXIST	120001
lang	es
text	cuando ves a las del 08 en la fiesta tu amigo...
video	7281385962049998086.mp4
path_video	videos/7281385962049998086.mp4
url	https://www.tiktok.com/@inazumamemes_/video/72...
annotators	[Annotator_4, Annotator_8, Annotator_9]
number_annotators	3
gender_annotators	[F, M, M]
labels_task3_1	[YES, NO, YES]
labels_task3_2	[DIRECT, -, DIRECT]
labels_task3_3	[[OBJECTIFICATION], [-], [OBJECTIFICATION]]
split	TRAIN-VIDEO_ES

Figura 3.2: Ejemplo de un registro del dataset original

El conjunto de datos original proporcionado por la organización para la Tarea 3 estaba compuesto por 2524 vídeos extraídos de la plataforma *TikTok* (1524 en español y 1000 en inglés). Estos datos se encontraban estructurados en un archivo *JSON* donde los campos más relevantes para nuestra tarea eran el identificador (`id_EXIST`), el texto (`text`), la ruta del archivo (`path_video`), el recuento de los anotadores (`number_annotators`) y la lista de valoraciones (`labels_task3_1`). Al basarse en el paradigma de *Le WiDi*, los vídeos no contaban con una etiqueta única, sino que presentaban las decisiones individuales de 2 o 3 anotadores distintos, tal y como se puede observar en la [Figura 3.2](#).

Para adaptar este conjunto a los requisitos de la Tarea 3.1 (clasificación binaria *Hard* en

“YES” o “NO”) era necesario fusionar las múltiples opiniones en una única etiqueta. Según la documentación oficial del reto, el proceso de anotación contemplaba la participación de dos anotadores independientes y la intervención de un investigador experto para adjudicar y resolver los casos de desacuerdo. Al explorar el campo `labels_task3_1`, se verificó que la presencia de un tercer voto correspondía a la inclusión de este veredicto de desempate.

Dado que el archivo en bruto proporcionado no exponía de forma explícita una columna con la etiqueta *Gold Standard* unificada, se optó por ignorar el supuesto *label* oficial externo y reconstruir las etiquetas desde las matrices de votación para asegurar la coherencia absoluta del conjunto de entrenamiento:

- **Voto por mayoría:** En la inmensa mayoría de las instancias, que contaban con 3 anotadores (reflejando la adjudicación), se asignó directamente la etiqueta mayoritaria. Por ejemplo: un registro con los votos [YES, NO, YES] se catalogó de forma automática como sexista.
- **Descarte por conflicto:** Durante la extracción, se detectaron 16 casos residuales evaluados únicamente por 2 anotadores en los que existía un empate absoluto (1 voto a favor y 1 en contra), sin constancia de un tercer voto de resolución en la matriz de datos. En lugar de forzar una etiqueta de manera manual o aleatoria, se tomó la decisión de eliminar estas muestras para evitar introducir ruido en el entrenamiento de la red neuronal.

Para asegurar la total reproducibilidad de esta reducción, el filtro se ejecutó automáticamente mediante un *script* incluido en el cuaderno `Dataset_Task_3_1.ipynb`. Tras aplicarlo, tal y como se puede apreciar en la [Figura 3.3](#), el conjunto original de 2524 vídeos se redujo a 2508 registros limpios (1306 no sexistas y 1202 sexistas), garantizando que los modelos se entrenaran exclusivamente sobre instancias con un consenso humano verificable.

	id_EXIST	lang	text	path_video	label_task_3_1_merged
0	120001	es	cuando ves a las del 08 en la fiesta tu amigo...	videos/7281385962049998086.mp4	1
1	120002	es	mujer sola caminando por la calle yo automat...	videos/7164058026352168197.mp4	1
2	120003	es	mi amigo no le importa ni las mujeres ni las ...	videos/7248606026386263323.mp4	0
3	120004	es	confirman las chicas cogiendo confianza despué...	videos/7305803156074597665.mp4	1
4	120005	es	aplantar la realidad la gordita del salón tien...	videos/7318400739775204614.mp4	1
...	...	...	...	...	...
2503	121520	es	temach le contesta a juan guarizo 'compa_revj...	videos/7200979592717339910.mp4	1
2504	121521	es	sígueme, persona, rk, nik, meuk, ad0, mefor, ...	videos/7211806336047156486.mp4	0
2505	121522	es	vas a seguir regalando flores? no regales ni a...	videos/7213218074936315141.mp4	1
2506	121523	es	héctor dice que el sábado puse un pedo en cas...	videos/7217265848409492782.mp4	0
2507	121524	es	palabras que duelen broken_heart femach 8766...	videos/7218429008445312261.mp4	0

2508 rows x 5 columns

Figura 3.3: Dataset transformado para la tarea 3.1

Posteriormente, el conjunto consolidado se dividió en dos subconjuntos manteniendo una proporción del 80 % para *Train* y un 20 % para *Test* de validación interna. Se utilizó

una técnica de muestreo estratificado (*stratify*) para asegurar que la proporción de clases se mantuviera idéntica en ambos bloques, fijando una semilla aleatoria (`random_state=42`) para garantizar la reproducibilidad de la partición. Como se puede observar en la Tabla 3.2, el conjunto de *Train* final quedó conformado por 2006 instancias (1045 negativas, 961 positivas), mientras que el conjunto de *Test* local constó de 502 instancias (261 negativas, 241 positivas).

Cabe reconocer que esta metodología no reproduce el protocolo empleado por la organización para generar el *Test* ciego oficial, el cual está fundamentado en una partición cronológica y agrupada por autor para evitar sesgos. Por consiguiente, nuestro marco de calibración local asume un riesgo potencial de fuga de información (*data leakage*), ya que vídeos de un mismo autor de *TikTok* podrían quedar repartidos entre entrenamiento y validación. Esto remarca el carácter exploratorio de nuestras métricas locales, haciendo indispensable la evaluación final sobre el entorno de desafío para confirmar la viabilidad del sistema.

Fichero	Train	Test
Etiqueta 1	961	241
Etiqueta 0	1045	261
Total	2006	502

Tabla 3.2: Distribuciones del fichero *Train* y *Test* para la tarea 3.1

3.3.2. Preprocesado de texto, limpieza y tokenización

Las transcripciones automáticas de los vídeos suelen presentar irregularidades gramaticales. Por ello, el *pipeline* de limpieza se diseñó para operar directamente sobre el campo *text* unificando el tratamiento para ambos idiomas (español e inglés). Primero, el texto fue estandarizado transformando los valores nulos y forzando la compatibilidad de tipo *string* para evitar fallos de ejecución. A continuación, tal y como se describió en el marco teórico, se aplicó una tubería secuencial basada en la librería nativa de expresiones regulares (*regex*), siguiendo este orden de ejecución:

1. **Normalización base:** Conversión de toda la cadena de texto a caracteres en minúsculas.
2. **Estructuras de transcripción:** Eliminación de prefijos originados por el sistema de captura del reto (ej. borrado literal de los patrones “AUDIO:” y “VIDEO:”).
3. **Metadatos web:** Búsqueda y eliminación de enlaces externos (*URLs*).
4. **Interacciones sociales:** Supresión de menciones directas a otros usuarios de la red social (patrón `@usuario`) y limpieza de etiquetas (*hashtags*).

5. **Símbolos y ruido:** Borrado de emoticonos (*emojis*), caracteres especiales y puntuaciones atípicas que no aportan significado semántico al clasificador.

Una vez finalizada la limpieza del texto, el proceso de tokenización varió drásticamente en función de la familia de modelos utilizados:

- **Transformers:** Se emplearon los tokenizadores nativos de cada arquitectura. Los textos fueron truncados y rellenados dinámicamente (*padding*) para igualar las longitudes de los tensores. A nivel interno, una frase como “*El machismo no existe*” se descompone en tokens elementales y se traduce a un vector numérico estructurado (por ejemplo: [101, 235, 14234, 156, ...]) denominado `input_ids`, acompañando de una máscara de atención (`attention_mask`).
- **LLMs:** Para el *fine-tuning* de modelos como *Llama* o *Mistral*, el preprocesamiento exigió la implementación de una técnica de *Prompt Engineering*. Cada transcripción se envolvió en una plantilla estructurada que indicaba explícitamente al modelo su tarea, restringiendo su vocabulario de salida exclusivamente a las palabras “YES” o “NO”.

3.3.3. Extracción de Características Visuales

Para que los modelos de visión por computador pudieran analizar el contenido de *TikTok*, fue necesario transformar los archivos temporales de vídeo (.mp4) en fotogramas estáticos legibles por redes convolucionales. Este proceso se llevó a cabo utilizando la biblioteca de visión artificial *OpenCV*.

Es importante resaltar que la separación de los datos en los subconjuntos *Train* y *Test* descrita en la primera subsección se realizó aislando el identificador único del vídeo `id_EXIST` de manera completamente previa a la extracción de imágenes. El script de procesamiento de *frames* operó leyendo de forma aislada los ficheros que ya estaban particionados. Esta metodología actúa como una estrategia robusta de *GroupSplit*, asegurando que no exista fuga de datos (*data leakage*): todos los datos extraídos de un mismo vídeo recaen íntegramente en la misma partición, impidiendo que el modelo sea evaluado con escenas que ya memorizó durante el entrenamiento.

Con el objetivo de explorar la cantidad óptima de información visual requerida, se construyeron múltiples *datasets* extrayendo un número variable de fotogramas por vídeo: $N \in \{2, 4, 6, 8, 10\}$. En la [Tabla 3.3](#) se aprecian los tamaños y distribuciones de los nuevos *corpus* de imagen generados. Para garantizar que las capturas fueran verdaderamente representativas del contenido global y evitar *frames* en negro al inicio o al final del vídeo, se diseñó un algoritmo de muestreo equidistante. La frecuencia o paso de extracción (*step*) se calculó matemáticamente mediante la siguiente ecuación:

$$step = \left\lfloor \frac{\text{total_frames}}{N + 1} \right\rfloor \quad (3.1)$$

Fichero	Train	Test
Original	2006	502
2 <i>Frames</i>	4012	1004
4 <i>Frames</i>	8024	2008
6 <i>Frames</i>	12036	3012
8 <i>Frames</i>	16048	4016
10 <i>Frames</i>	20060	5020

Tabla 3.3: Tamaños de los ficheros *Train* y *Test* en función de los *frames* extraídos

Posteriormente, las imágenes extraídas se almacenaron en formato *JPG* y se indexaron en un nuevo fichero tabular, heredando la etiqueta binaria de su vídeo original, lo que permitió el entrenamiento supervisado de las arquitecturas de imagen.

3.4. Experimentación Unimodal en Texto

La primera fase de la metodología empírica se centró de manera exclusiva en el procesamiento de la modalidad textual. Las transcripciones de los vídeos de *TikTok* que se nos aportaron en el *dataset* por parte de los organizadores poseen una alta densidad de información, ya que la mayor carga semántica e ideológica del discurso sexista suele residir en el lenguaje verbal. Para abordar esta tarea, se dividió la experimentación en dos vertientes del PLN: el uso de arquitecturas discriminativas clásicas y la implementación de Grandes Modelos de Lenguaje (*LLMs*) generativos.

En todos los experimentos de esta fase, se partió del conjunto maestro de entrenamiento (2006 instancias), el cual fue subdividido internamente en un 90 % para *Train* (1805 instancias) y un 10 % para *Validation* (201 instancias), fijando la semilla aleatoria para garantizar un marco comparativo justo entre arquitecturas.

Entorno de Experimentación y Limitaciones

Para asegurar la reproducibilidad de los resultados presentados, es fundamental detallar el entorno técnico. Todos los experimentos se ejecutaron sobre una *GPU NVIDIA L4* con 23.66 GB de *VRAM*, utilizando el marco de trabajo de *PyTorch*, *PyTorch Lightning* y la librería *Transformers*.

Debido a las estrictas limitaciones computacionales y de tiempo operativo derivadas del

procesamiento profundo en redes neuronales, cada configuración se ejecutó una única vez. Esta metodología constituye una limitación formal del estudio; al carecer de ejecuciones múltiples, las variaciones en el rendimiento entre ciertos modelos podrían atribuirse a la aleatoriedad de la inicialización de los pesos y no únicamente a la superioridad de una arquitectura frente a otra.

Establecimiento del *Baseline* Local

Para poder medir objetivamente el impacto de las nuevas estrategias y modelos que se detallarán en las siguientes secciones, resultó indispensable establecer un punto de referencia o *baseline* local. Para ello, se evaluaron los dos modelos originales enviados a la competición oficial sobre el **conjunto local de desarrollo o *holdout* exploratorio** (las 502 instancias reservadas en la fase de preprocesamiento).

En la [Tabla 3.4](#) se exponen las métricas obtenidas por la arquitectura discriminativa multilingüe y el modelo generativo *Zero-Shot* ante este conjunto exploratorio:

Modelo (<i>Baseline</i>)	Accuracy	F1-score (Macro)
bert-base-multilingual-cased	0.6275	0.6215
Llama-3.2-1B-Instruct (<i>Zero-Shot</i>)	0.6135	0.4748

Tabla 3.4: Rendimiento de los modelos *baseline* sobre el conjunto local de desarrollo *holdout*

Estos resultados locales actúan como el umbral a batir y evidencian el margen de mejora existente, motivando la exploración de arquitecturas más robustas, optimizaciones de hiperparámetros y técnicas de ajuste fino avanzado que se exponen a continuación.

3.4.1. Arquitecturas Discriminativas (*Transformers*)

El *baseline* para esta fase fue el modelo multilingüe **bert-base-multilingual-cased**, utilizado en la entrega oficial de la tarea. A partir de este, se planteó una etapa de experimentación cruzada para evaluar el comportamiento de diferentes modelos *Transformers* preentrenados. El objetivo era comprobar qué tipo de conocimiento base se adaptaba mejor al lenguaje de la plataforma *TikTok*: se evaluaron arquitecturas preentrenadas específicamente en inglés, modelos preentrenados en español y modelos multilingües, todos ellos ajustados sobre el corpus completo del proyecto.

Durante el entrenamiento, se aplicó precisión mixta (*fp16*) para optimizar el uso de memoria y se minimizó la función de pérdida de Entropía Cruzada. La longitud máxima de los tensores de entrada (*max_length*) se limitó dinámicamente mediante *padding* y truncamiento. El proceso estuvo regulado por un *Early Stopping* con una paciencia de 2

épocas, monitorizando constantemente el *F1-Score* sobre el conjunto de *Validation* interno para guardar el mejor *checkpoint*.

Tras una primera iteración de entrenamientos, con los hiperparámetros estándar que se observan en la [Tabla 3.5](#), la arquitectura **RoBERTa-base** se consolidó como el modelo con mejor rendimiento sobre este conjunto exploratorio para esta tarea específica.

Hiperparámetro	Valor
<i>batch_size</i>	16
<i>num_train_epochs</i>	15
<i>learning_rate</i>	1e-5
<i>weight_decay</i>	0.1

Tabla 3.5: Configuración estándar con las que fueron entrenados los *Transformers*

El hecho de que **RoBERTa-base** (un modelo optimizado puramente para el idioma inglés) superase ligeramente a los modelos multilingües o nativos en español, responde a la siguiente hipótesis: la “jerga lingüística” de *TikTok* y las redes sociales hispanohablantes está compuesta por anglicismos, acrónimos y calcos sintácticos. No obstante, al no haber desglosado las métricas de evaluación separando el conjunto de datos por idioma, no es posible atribuir este éxito a la arquitectura o a una posible menor complejidad del subconjunto de datos en inglés. Se asume, por tanto, como otra limitación del análisis empírico.

Con el objetivo de maximizar sus métricas y extraer su máximo potencial, **roberta-base** fue el elegido para someterse a un proceso de optimización de hiperparámetros. Se ejecutó una búsqueda sistemática en cuadrícula (*Grid Search*) explorando un espacio de configuraciones acotado: *learning_rate* $\in \{1e-5, 2e-5, 5e-5\}$, *batch_size* $\in \{8, 16\}$ y *weight_decay* $\in \{0.01, 0.05, 0.1\}$. El mejor modelo (*RoBERTa*), seleccionado en base a la métrica *F1-Score* devuelta sobre el conjunto de *Validation*, arrojó los valores de la [Tabla 3.6](#). A pesar de la búsqueda, esta configuración seleccionada no consiguió mejorar el rendimiento del modelo respecto a sus hiperparámetros iniciales.

Hiperparámetro	Valor
<i>batch_size</i>	16
<i>learning_rate</i>	2e-5
<i>weight_decay</i>	0.05
<i>warmup_ratio</i>	0.1
<i>lr_scheduler</i>	cosine
<i>max_grad_norm</i>	0.75

Tabla 3.6: Configuración alternativa seleccionada para el modelo *RoBERTa-base*

En la [Tabla 3.7](#) se presentan los resultados comparativos de los distintos modelos *Trans-*

formers evaluados, así como el rendimiento interno de **RoBERTa-base** tras la prueba de configuración alternativa.

Familia	Modelo	Accuracy	F1-score (Macro)
Español	bertin-roberta-base-spanish	0.6076	0.6049
	bert-base-spanish-wwm-uncased	0.6833	0.6819
	robertuito-base-uncased	0.6932	0.6909
Inglés	bertweet-base	0.5498	0.4764
	electra-base-discriminator	0.6793	0.6764
	roberta-base	0.6972	0.6934
	roberta-base (config. seleccionada)	0.6833	0.6794
Multilingüe	mmbert-base	0.6813	0.6810
	twhin-bert-base	0.6853	0.6852
	xlm-roberta-base	0.6912	0.6910

Tabla 3.7: Rendimiento interno de los modelos *Transformers*

3.4.2. Arquitecturas Generativas (LLMs)

De forma paralela, se abordó el problema utilizando arquitecturas generativas de última generación. Partiendo de las carencias observadas durante el enfoque *Zero-Shot* inicial, la metodología evolucionó hacia el *Supervised Fine-Tuning* o *SFT*.

El preprocesamiento para esta familia de modelos requirió estructurar los datos mediante *Prompt Engineering*. A cada transcripción se le antepuso el contexto de la tarea (indicando al modelo que debía decidir si el mensaje contenía contenido sexista) y se restringió la respuesta esperada a las etiquetas binarias “1” (YES) y “0” (NO). El truncamiento se estableció en un máximo de 128 *tokens*.

Dado el inmenso tamaño paramétrico de estas arquitecturas y las restricciones de memoria *VRAM*, el entrenamiento se llevó a cabo utilizando la técnica **QLoRA** (*Quantized Low-Rank Adaptation*). Específicamente, se cargaron los modelos base con una precisión reducida de 4 bits (formato **nf4** mediante **BitsAndBytes**), habilitando internamente los cálculos matemáticos en **bfloat16** (*bf16*) para optimizar el rendimiento y la estabilidad computacional. Se congeló la red principal; el aprendizaje se proyectó exclusivamente sobre unas matrices adaptadoras de bajo rango insertadas en las capas de atención (incluyendo la capa final para el enfoque discriminativo), configuradas con un rango (r) de 16, un factor de escalado (α) de 32 y un *dropout* del 0.05 para prevenir el sobreajuste.

Bajo esta configuración, se entrenaron diferentes variantes de modelos utilizando la clase **Trainer** y el optimizador **paged_adamw_8bit** con un *learning rate* de $2e-4$. Tras evaluar los modelos resultantes con el conjunto de desarrollo local, **Mistral** demostró el mejor desempeño en la clasificación de narrativas sexistas.

Los resultados conseguidos por los *LLMs* tras la aplicación de estas técnicas se muestran en la [Tabla 3.8](#). Como podemos observar, se constata una mejoría con respecto al mejor resultado obtenido en los *Transformers* (0.6934).

Modelo	Accuracy	F1-score (Macro)
gemma-2-2b-it	0.6873	0.6866
llama-3.1-8b-instruct	0.6335	0.6249
mistral-7b-instruct-v0.3	0.7171	0.7141

Tabla 3.8: Rendimiento interno de los modelos *LLMs*

3.5. Experimentación con Modelos de Visión Estática

La segunda fase de la metodología se centró en la modalidad visual. A diferencia del procesamiento de texto, donde la información fluye de manera secuencial y estructurada, el análisis del componente visual en *TikTok* presenta un desafío particular: determinar cuánta información es necesaria para capturar el contexto de un vídeo sin saturar el entrenamiento ni perder detalles cruciales.

Para resolver esto, la experimentación se estructuró de manera escalonada: en primer lugar, se buscó la combinación óptima entre arquitectura de red y volumen de fotogramas extraídos. Posteriormente, se diseñaron lógicas de inferencia (*pooling*) para emitir un veredicto por vídeo. Finalmente, sobre el modelo seleccionado, se aplicaron técnicas de optimización y aumento de datos (*Data Augmentation*).

3.5.1. Selección de Arquitectura y Volumen de Fotogramas

Tal y como se detalló en la [Subsección 3.3.3](#), se construyeron múltiples subconjuntos extrayendo un número variable de fotogramas estáticos por vídeo (2, 4, 6, 8 y 10).

Para evaluar qué arquitectura extraía mejores características espaciales, se seleccionaron tres modelos preentrenados en clasificación de imágenes de la librería de *Hugging Face*:

- **ViT** (`google/vit-base-patch16-224-in21k`): Es estándar en *Vision Transformers*.
- **Swin Transformer** (`microsoft/swin-tiny-patch4-window7-224`): Variante que computa la atención mediante ventanas desplazadas.
- **ConvNeXt** (`facebook/convnext-tiny-224`): Arquitectura puramente convolucional modernizada para competir con los *Vision Transformers*.

El proceso de entrenamiento evaluaba el modelo fotograma a fotograma. Sin embargo, dado que el objetivo de la Tarea 3.1 es clasificar el vídeo en su conjunto, durante la fase

de inferencia sobre el conjunto local de desarrollo se implementaron tres estrategias de *pooling*:

1. **Max-Pooling**: Si al menos un fotograma del vídeo es clasificado como sexista (probabilidad >0.5), el vídeo completo se cataloga como sexista.
2. **Mean-Pooling**: Se calcula la media aritmética de las probabilidades de todos los fotogramas del vídeo. Si la media supera el 50 %, se clasifica como sexista.
3. **Majority vote**: El vídeo se etiqueta como sexista solo si la mitad o más de sus fotogramas individuales superan el umbral de decisión.

Observando los resultados obtenidos en la [Tabla 3.9](#), la combinación de la arquitectura *ConvNeXt* sobre el *dataset* de 4 *frames* utilizando *Mean-Pooling* obtuvo la puntuación más alta en esta fase exploratoria, alcanzando un *F1-score* de 0.6245. Este rendimiento puede fundamentarse teóricamente en tres factores claves:

- **Eficiencia convolucional**: Planteamos la hipótesis a posteriori de que, a diferencia de los *Vision Transformers* (*ViT* y *Swin*), que requieren volúmenes masivos de datos para generalizar correctamente, *ConvNeXt* se beneficia de los sesgos inductivos característicos de las redes convolucionales, permitiéndole aprender patrones visuales de manera mucho más eficiente en *datasets* de tamaño moderado.
- **Equilibrio de información (4 frames)**: Este volumen representa el punto óptimo de contexto. Extraer menos *frames* eleva el riesgo de perder el instante clave de la acción, mientras que procesar 8 o 10 introduce un exceso de planos neutros que terminan añadiendo ruido a la señal discriminativa del sesgo sexista.
- **Robustez del Mean-Pooling**: Frente al *Max-Pooling* (altamente sensible a falsos positivos) y al *Majority-Vote* (demasiado conservador), el promedio actúa como un regularizador eficaz. Mitiga las predicciones dudosas al suavizar las probabilidades conjuntas, aunque requiere un consenso general de la secuencia o la presencia de fotogramas con una probabilidad extremadamente alta para poder desplazar la media por encima del umbral de decisión, dependiendo siempre del factor N .

Frames	Modelo	<i>Pooling</i>	Accuracy	F1-score (Macro)
2	ViT	Max-Pooling	0.5100	0.5092
		Mean-Pooling	0.5159	0.5127
		Majority Vote	0.5100	0.5092
	Swin	Max-Pooling	0.5677	0.5648
		Mean-Pooling	0.5657	0.5627
		Majority Vote	0.5677	0.5648
	ConvNeXt	Max-Pooling	0.5657	0.5656
		Mean-Pooling	0.5976	0.5932
		Majority Vote	0.5657	0.5656
4	ViT	Max-Pooling	0.4721	0.3665
		Mean-Pooling	0.4841	0.4127
		Majority Vote	0.4821	0.4057
	Swin	Max-Pooling	0.5438	0.5391
		Mean-Pooling	0.5279	0.5054
		Majority Vote	0.5398	0.5315
	ConvNeXt	Max-Pooling	0.5817	0.5739
		Mean-Pooling	0.6275	0.6245
		Majority Vote	0.6195	0.6195
6	ViT	Max-Pooling	0.4960	0.4919
		Mean-Pooling	0.5060	0.5058
		Majority Vote	0.5060	0.5058
	Swin	Max-Pooling	0.5120	0.4372
		Mean-Pooling	0.5458	0.5383
		Majority Vote	0.5319	0.5167
	ConvNeXt	Max-Pooling	0.5100	0.4591
		Mean-Pooling	0.5598	0.5595
		Majority Vote	0.5478	0.5467
8	ViT	Max-Pooling	0.4900	0.4167
		Mean-Pooling	0.5159	0.5149
		Majority Vote	0.5199	0.5187
	Swin	Max-Pooling	0.5319	0.4918
		Mean-Pooling	0.5737	0.5729
		Majority Vote	0.5717	0.5717
	ConvNeXt	Max-Pooling	0.5438	0.4971
		Mean-Pooling	0.5657	0.5657
		Majority Vote	0.5777	0.5774
10	ViT	Max-Pooling	0.5139	0.4730
		Mean-Pooling	0.5299	0.5259
		Majority Vote	0.5558	0.5518
	Swin	Max-Pooling	0.5478	0.5066
		Mean-Pooling	0.5598	0.5581
		Majority Vote	0.5677	0.5674
	ConvNeXt	Max-Pooling	0.5319	0.4601
		Mean-Pooling	0.5697	0.5684
		Majority Vote	0.5797	0.5746

Tabla 3.9: Rendimiento de los modelos de Visión Estática con las diferentes combinaciones de *datasets* de *frames* y técnicas de *pooling*

3.5.2. Optimización de Hiperparámetros y Data Augmentation

Una vez fijado el modelo *ConvNeXt* sobre el escenario de 4 *frames* como la arquitectura base, se procedió a intentar superar sus métricas iniciales mediante estrategias de regularización.

Como se puede apreciar en la [Tabla 3.10](#) aplicamos las estrategias de hiperparámetros definidas en la [Subsección 2.8.1](#).

Estrategia	<i>Pooling</i>	Accuracy	F1-score (Macro)
Slow Cooker	Max-Pooling	0.5737	0.5575
	Mean-Pooling	0.5976	0.5976
	Majority-Vote	0.5996	0.5984
Gradient Accumulation	Max-Pooling	0.5737	0.5614
	Mean-Pooling	0.5876	0.5868
	Majority-Vote	0.5697	0.5697
Sprint Final	Max-Pooling	0.5498	0.5244
	Mean-Pooling	0.5896	0.5896
	Majority-Vote	0.5876	0.5843

Tabla 3.10: Resultados de las estrategias de hiperparámetros aplicadas al *baseline* de *ConvNeXt* de 4 *frames*

Al evaluar las estrategias de optimización avanzadas (*Slow Cooker*, *Gradient Accumulation* y *Sprint Final*), observamos que ninguna logró superar la barrera del 0.60 en el *F1-score*, quedando notablemente por debajo del 0.6245 obtenido por el modelo original. Esto sugiere que la arquitectura preentrenada de *ConvNeXt* ya posee mapas de características muy optimizados. Forzar dinámicas de actualización de pesos más agresivas o conservadoras sobre un conjunto de datos reducido no ha favorecido el ajuste local, sino que ha frenado la convergencia natural del modelo.

De forma simultánea, y para intentar mejorar la extracción de patrones, se aplicaron varias técnicas de *Data Augmentation*. Las transformaciones se aplicaron dinámicamente en tiempo de ejecución (*on-the-fly*) a través de la librería nativa `torchvision` durante la iteración del *dataset*, manteniendo la resolución final de las imágenes en 224×224 píxeles. El orden de las operaciones y sus parámetros fueron: un volteo horizontal aleatorio (`RandomHorizontalFlip`, $p = 0.5$), rotación (`RandomRotation` acotada a ± 10 grados), y variación de colores (`ColorJitter` alterando un 15 % el brillo, contraste y saturación). Las estrategias de muestreo definidas fueron las siguientes:

- Aumentar el tamaño total del entrenamiento.
- Aumentar exclusivamente los datos etiquetados como no sexistas.
- Aumentar exclusivamente los datos etiquetados como sexistas.

- Aumentar el 10 % de los datos de entrenamiento etiquetados como sexistas. Esta decisión parte de la distribución real del fichero de *Train*, el cual cuenta con un ligero desbalanceo: aproximadamente un 52 % de la clase 0 (1045 instancias) frente al 48 % de la clase 1 (961 instancias). Aplicar las transformaciones únicamente al 10 % de los datos de la clase minoritaria añade 96 muestras extras a dicha categoría, acercando la proporción matemática a un 50/50 casi exacto.

En la [Tabla 3.11](#) se muestran los resultados finales obtenidos por las diferentes variaciones del modelo *ConvNeXt*:

Estrategia	Pooling	Accuracy	F1-score (Macro)
Train completo	Max-Pooling	0.5398	0.5179
	Mean-Pooling	0.5697	0.5682
	Majority-Vote	0.5857	0.5855
Train etiqueta 0	Max-Pooling	0.4781	0.3424
	Mean-Pooling	0.4900	0.4186
	Majority-Vote	0.4721	0.3783
Train etiqueta 1	Max-Pooling	0.5418	0.5221
	Mean-Pooling	0.5139	0.4265
	Majority-Vote	0.5239	0.4546
Train 10 % etiqueta 1	Max-Pooling	0.5219	0.3467
	Mean-Pooling	0.5199	0.3421
	Majority-Vote	0.5199	0.3421

Tabla 3.11: Resultados de las estrategias de *data augmentation* aplicadas al *baseline* de *ConvNeXt* de 4 *frames*

Al analizar las estrategias de *Data Augmentation*, vemos que la caída de rendimiento es aún más notoria. El intento de balancear o enriquecer los datos provocó un colapso en la métrica *F1-Score*, llegando a caer hasta un 0.3421 en el *Mean-Pooling* de la estrategia de aumentar un 10 % la clase 1.

Aunque para afirmar que existe un sobreajuste sería necesario un análisis de las curvas de pérdida de entrenamiento y validación, la justificación principal de esta degradación apunta a la naturaleza del dominio visual. A diferencia de un conjunto de imágenes “naturales” (donde un perro sigue siendo un perro aunque se rote 15 grados), los vídeos de redes sociales como *TikTok* poseen una fuerte dependencia espacial: voltear horizontalmente la imagen destruye la legibilidad de los textos superpuestos, y alterar la saturación puede eliminar elementos vitales para el contexto. Por lo tanto, deducimos de forma precavida que estas técnicas, en lugar de regularizar el modelo, han inyectado ruido semántico.

En conclusión, la experimentación empírica nos dictamina que la arquitectura en su configuración base original, sin la aplicación de técnicas agresivas de aumento de datos, es la que mejor preserva el contexto espacial y se adapta a este dominio de redes sociales.

3.6. Experimentación con Modelos de Visión Temporal

A pesar de los resultados obtenidos mediante la extracción de *frames* estáticos, esta aproximación tiene una limitación fundamental: la pérdida del eje temporal. El discurso sexista en plataformas como *TikTok* a menudo no se manifiesta en una única imagen congelada, sino a través de una secuencia de acciones, expresiones faciales o gestos corporales que requieren del contexto del tiempo para ser interpretados correctamente.

Para superar esta limitación técnica, se procedió a la implementación y *fine-tuning* de arquitecturas de visión temporal. Estos modelos son capaces de procesar secuencias completas de *frames* de forma simultánea, evaluando tanto la relación espacial (los *píxeles* dentro de un fotograma) como la relación temporal (la evolución de dichos *píxeles* a lo largo del vídeo).

La experimentación siguió el mismo enfoque metódico empleado en la visión estática: selección de la arquitectura base, seguida de una fase de optimización y culminando con técnicas de *Data Augmentation*.

3.6.1. Selección de la Arquitectura Temporal

La manipulación de tensores de vídeo exige un alto consumo de memoria computacional (*VRAM*). Para garantizar la viabilidad del entrenamiento bajo las limitaciones técnicas del proyecto, se estableció un tamaño de clip fijo de 16 *frames* (u 8 *frames* para modelos de mayor densidad computacional) utilizando la librería **decord** para la lectura eficiente en *GPU*.

Se seleccionaron tres modelos fundacionales para la clasificación de vídeo:

- **VideoMAE** (MCG-NJU/*videomae-base*): Arquitectura basada en el aprendizaje autosupervisado mediante máscaras espaciotemporales. El modelo aprende ocultando el 90 % de los “cubos” de píxeles del vídeo y forzándose a reconstruir la secuencia completa a partir del 10 % restante.
- **TimeSFormer** (facebook/*timesformer-base-finetuned-k400*): Introduce el concepto de “Atención Dividida Espaciotemporal”. Para evitar el colapso de memoria al calcular la atención sobre todos los píxeles de todos los *frames*, esta arquitectura aplica primero la atención espacial (dentro del *frame*) y luego la atención temporal (a través de los *frames*), reduciendo drásticamente el coste computacional.
- **ViViT** (google/*vivit-b-16x2-kinetics400*): Evolución directa del modelo *ViT* estático. Extrae bloques de píxeles tridimensionales (*tubelets*) que atraviesan múltiples *frames* simultáneamente, capturando el movimiento desde la primera capa de la red.

Tras someter a los tres modelos a un proceso de *fine-tuning* (utilizando el mismo *split* de validación del 10 % para monitorizar el aprendizaje), las inferencias se proyectaron directamente sobre el conjunto local de desarrollo. A diferencia del enfoque por *frames* de la sección anterior, estos modelos emiten una única probabilidad unificada para todo el vídeo, eliminando la necesidad de aplicar algoritmos de *pooling* posteriores.

Modelo	Accuracy	F1-score (Macro)
videomae-base	0.5378	0.5360
timesformer-base-finetuned-k400	0.5857	0.5837
vivit-b-16x2-kinetics400	0.5438	0.5379

Tabla 3.12: Rendimiento de los modelos de Visión Temporal

Como se puede observar en la [Tabla 3.12](#), la arquitectura *TimeSFormer* obtiene el mejor rendimiento interno, alcanzando un *F1-score* macro de 0.5837 y superando a los otros dos modelos por un margen de casi 5 puntos porcentuales en esta fase exploratoria.

Dadas las limitaciones de memoria computacional (*VRAM*) y el tamaño fijo de secuencias establecido en este experimento (16), el mecanismo de Atención Dividida Espacio-temporal del *TimeSFormer* sugiere ser un enfoque adecuado. Planteamos la hipótesis (a falta de estudios formales que lo validen) de que este diseño ayuda a procesar la evolución temporal del vídeo de forma equilibrada. Por el contrario, estrategias como la extracción simultánea de *tubelets* tridimensionales (*ViViT*) o la reconstrucción mediante máscaras al 90 % (*VideoMAE*) podrían verse penalizadas al trabajar con un contexto temporal restringido, dificultando el ajuste en este escenario de clasificación.

3.6.2. Optimización de Hiperparámetros y Data Augmentation Temporal

Una vez seleccionado el modelo *TimeSFormer*, se ejecutó una segunda iteración de entrenamientos orientada a intentar maximizar su rendimiento.

Al igual que en la modalidad de imagen estática, se configuraron diversas estrategias de ajuste de hiperparámetros explorando diferentes lógicas de decaimiento y regularización. Como se puede observar en la [Tabla 3.13](#), se probaron configuraciones conocidas conceptualmente como *Slow Cooker Temporal*, *Gradientes Estables* (aprovechando *Gradient Accumulation* sobre un **batch** efectivo mayor) y un *LR Scheduler Agresivo* basado en la función coseno. A pesar de haber definido estas variantes, ninguna consiguió mejorar el *baseline* local del modelo.

Estrategia	Accuracy	F1-score (Macro)
Slow Cooker Temporal	0.5378	0.5374
Gradientes Estables	0.5697	0.5631
LR Scheduler Agresivo	0.5598	0.5555

Tabla 3.13: Rendimiento del *TimeSFormer* con las estrategias de hiperparámetros

Adicionalmente, se exploró el impacto del *Data Augmentation* directamente sobre la matriz espacio-temporal del vídeo. Dado que las operaciones complejas de visión (*torch-vision*) son muy exigentes con la memoria de la GPU al aplicarse sobre bloques de vídeo completos, se implementó una transformación más ligera directamente durante la carga de las secuencias: la aplicación de espejados horizontales dinámicos (`np.flip`) *on-the-fly* sobre todos los fotogramas del clip seleccionado. El volumen de datos no se duplicó materialmente, sino que la probabilidad de sufrir dicha transformación varió según la clase, generando las siguientes estrategias probabilísticas:

- 50 % de probabilidad de transformar cualquier vídeo del conjunto de entrenamiento.
- 100 % de probabilidad de transformar los datos catalogados como sexistas.
- 100 % de probabilidad de transformar los datos catalogados como no sexistas.
- 100 % de probabilidad de transformar la totalidad de los datos.
- 10 % de probabilidad de transformar los datos catalogados como sexistas.

Estrategia	Accuracy	F1-score (Macro)
Prob. 50 % a todos	0.5199	0.3421
Prob. 100 % a clase 1	0.5279	0.5277
Prob. 100 % a clase 0	0.5618	0.5580
Prob. 100 % a todos	0.5737	0.5698
Prob. 10 % a clase 1	0.5956	0.5956

Tabla 3.14: Rendimiento del *TimeSFormer* con las estrategias de *data augmentation*

Como se evidencia en la [Tabla 3.14](#), la única estrategia que logró una mejora en el rendimiento del *TimeSFormer* fue la aplicación de una probabilidad muy moderada (10 %) de volteo exclusivamente a las muestras de la clase minoritaria, alcanzando un *Accuracy* y un *F1-score* idénticos de 0.5956.

Este incremento en el rendimiento respecto al *baseline* se explica por el efecto regularizador aplicado sobre la clase minoritaria. Partiendo de la distribución inicial sesgada, donde la clase predominante (etiqueta 0) representaba aproximadamente el 52 % de los datos frente al 48 % de la clase minoritaria (etiqueta 1), la estrategia no altera matemáticamente esta proporción añadiendo nuevas instancias, sino que inyecta variabilidad espacio-temporal (espejado horizontal) a un 10 % aleatorio de las secuencias sexistas durante cada época.

Al exponer a la red neuronal a versiones modificadas de la etiqueta menos representada, se dificulta que el modelo memorice exactamente la matriz de píxeles de esos vídeos, forzándole a aprender características temporales más robustas. Por el contrario, la aplicación de estrategias más agresivas (como voltear horizontalmente la totalidad de los datos o aplicar una probabilidad ciega del 50 %) genera un deterioro grave del contexto espacial del vídeo o un exceso de ruido que termina penalizando la capacidad de generalización del sistema.

3.7. Fusión Multimodal (*Ensemble*)

El análisis del discurso sexista en plataformas como *TikTok* es un problema eminentemente multimodal. Como se ha expuesto en las secciones anteriores, un algoritmo centrado exclusivamente en el texto puede perder la acción visual que acompaña a una frase, del mismo modo que un modelo puramente visual carece del contexto semántico del audio. Para resolver esta brecha, se procedió a la integración de las modalidades abordadas mediante un sistema *Ensemble*.

Para la construcción de este sistema unificado, se seleccionaron los modelos que demostraron el mejor desempeño empírico en cada una de sus modalidades de forma aislada:

- **Modalidad Textual:** *Mistral* ajustado mediante *QLoRA*.
- **Modalidad de Visión Estática:** *ConvNeXt* entrenado sobre el conjunto de 4 *frames* y con la inferencia mediante *Mean-Pooling*.
- **Modalidad de Visión Temporal:** *TimeSFormer* afinado sobre secuencias de 16 *frames*.

3.7.1. Estrategia de *Late Fusion*

Tal y como se fundamentó en la [Subsección 2.9.2](#), se optó por implementar una estrategia de *Late Fusion* mediante *Weighted Average*. Esta técnica de predicción estática permite ajustar los parámetros de decisión en fracciones de segundo sin necesidad de volver a procesar los tensores multimedia. La probabilidad final (P_{final}) de que un vídeo fuese sexista se calculó como la suma ponderada de las probabilidades predichas de cada modelo base.

3.7.2. Optimización de Pesos y Resultados Finales

Para hallar la combinación ideal, se programó un algoritmo de búsqueda exhaustiva (*Grid search*) sobre el conjunto local de desarrollo. El algoritmo iteró a través de todas las combinaciones posibles en intervalos del 5 % (0.05), calculando en cada ciclo la predicción binaria y evaluando el *F1-score (Macro)* resultante. Cabe destacar un **hallazgo metodológico crítico**: este mismo subconjunto de 502 instancias se ha consultado de forma reiterada a lo largo de este trabajo para escoger la arquitectura textual, el número de fotogramas, las estrategias de *pooling*, los hiperparámetros y, finalmente, la ponderación del *Ensemble*. Esta reutilización adapta indirectamente el sistema a este conjunto específico, sesgando al alza la cifra final. Por ello, las métricas no representan un rendimiento de generalización, sino una medida de calibración interna fuertemente ajustada al conjunto exploratorio (*overfitting*).

Tras completar la búsqueda iterativa, la distribución óptima de pesos que maximizó el ajuste interno del sistema fue:

- **Peso Texto** (W_{texto}): 0.35 (35 %)
- **Peso Imagen** (W_{imagen}): 0.55 (55 %)
- **Peso Vídeo** (W_{video}): 0.10 (10 %)

Quedando entonces la probabilidad final de la siguiente forma:

$$P_{final} = (0,35 \cdot P_{texto}) + (0,55 \cdot P_{imagen}) + (0,10 \cdot P_{video}) \quad (3.2)$$

Es fundamental matizar que esta distribución de pesos no debe interpretarse como una demostración de que la información visual sea más determinante que el texto. Estos porcentajes representan únicamente los parámetros matemáticos seleccionados para maximizar la métrica local. Su valor final depende fuertemente de la escala de las probabilidades emitidas por cada modelo, las diferencias en su calibración inicial, la correlación estadística de sus errores y, especialmente, el sobreajuste (*overfitting*) generado al realizar la búsqueda paramétrica sobre este mismo subconjunto de datos.

La aplicación de estos pesos óptimos sobre el sistema *Ensemble* logró superar todas las marcas individuales de los modelos aislados dentro de este entorno de desarrollo, respaldando el potencial del enfoque multimodal para la tarea, aunque acotado a este subconjunto de datos. Las métricas obtenidas por este sistema unificado se detallan en la [Figura 3.4](#).




Figura 3.4: Resultados del *Ensemble* Multimodal contra el conjunto local de desarrollo

3.7.3. Análisis de Errores

Esta subsección tiene como objetivo detallar los errores cometidos por el sistema *Ensemble* multimodal, buscando patrones o causas subyacentes que expliquen los fallos del modelo. No se trata únicamente de cuantificar las equivocaciones, sino de interpretarlas, comprendiendo en qué escenarios la inteligencia artificial encuentra dificultades para procesar la complejidad, el sarcasmo o la ambigüedad del lenguaje humano en las redes sociales.

Sobre el conjunto local de desarrollo (502 instancias), el sistema generó un total de 136 predicciones erróneas. La contabilización de estas instancias en su matriz de confusión reveló un claro desbalance en el tipo de equivocación: 84 correspondieron a Falsos Negativos (el sistema no detectó el sexismo presente) y 52 a Falsos Positivos (el sistema generó una alarma falsa en un contenido inofensivo), acompañados de 209 Verdaderos Negativos y 157 Verdaderos Positivos. Esta distribución sugiere que el modelo adoptó una postura ligeramente conservadora, tendiendo a pasar por alto el sexismo cuando este se presenta de forma implícita o sutil.

Es fundamental matizar que las explicaciones detalladas a continuación deben considerarse como interpretaciones razonables del comportamiento de la red neuronal. Al no haber implementado técnicas de Explicabilidad Algorítmica (*XAI*) que muestren de forma empírica la atención de la red a características concretas, las causas atribuidas actúan como hipótesis derivadas de la observación.

Identificación de errores comunes y ejemplos

Se estableció un protocolo de revisión cualitativa mediante el cual analizamos y codificamos manualmente una muestra de los 30 casos en los que el modelo mostró mayor “confianza” al equivocarse (es decir, aquellos donde la probabilidad arrojada estaba más alejada del umbral de decisión). Esto permitió agrupar los siguientes escenarios problemáticos:

- Ejemplo 1: Violencia accidental confundida con violencia de género (Falso Positivo)
 - **Texto**: “*cristiano ronaldo le regaló su camiseta a la guardia de seguridad que golpeó accidentalmente con un balonazo [...] la fuerza del pelotazo pues provocó que esta cayera al suelo por lo que tuvo inmediata atención...*”
 - **Etiqueta real**: No sexista (0) | **Predicción**: Sexista (1)
 - **Hipótesis**: Es altamente probable que el modelo asocie palabras clave de su vocabulario como “golpeó”, “cayera al suelo” y “mujer” directamente con violencia física o machismo. Al carecer de la capacidad de abstracción para entender el contexto periodístico de un accidente deportivo, se dispara una falsa alarma.
- Ejemplo 2: Violencia digital contra grupos no objetivo de la tarea (Falso Positivo)
 - **Texto**: “*el pibe inalcanzable que nunca dijo ni 'hola' en clase. se filtra su pack. comparten, comparten, muchachos, comparten...*”
 - **Etiqueta real**: No sexista (0) | **Predicción**: Sexista (1)
 - **Hipótesis**: El sistema detecta correctamente un patrón claro de un delito de violencia digital (difusión no consentida de imágenes íntimas mediante la palabra “pack” y la incitación a “compartir”). Sin embargo, falla al razonar la directriz principal del reto: el sujeto pasivo de este escenario es un varón (el “pibe”). Por consiguiente, aunque el texto describe un comportamiento tóxico, queda fuera de la definición estricta de discurso sexista o misógino contra la mujer que rige la construcción del *dataset*, generando un falso positivo algorítmico.
- Ejemplo 3: *Objectification* enmascarada y ruido de plataforma (Falso Negativo)
 - **Texto**: “*reply to stay smiling friends replying to yourmommaluvs thed’s comment, i find chicks with jacked up teeth attractive. you must be in kentucky...*”
 - **Etiqueta real**: Sexista (1) | **Predicción**: No sexista (0)
 - **Hipótesis**: El mensaje contiene una clara cosificación y un uso despectivo hacia las mujeres (“chicks”), pero el modelo no logró captar el sesgo implícito. Una posible explicación radica en que la ofensa es sutil, presentándose como una falsa preferencia estética. Además, la carga semántica está altamente diluida por los metadatos de la propia red social (“replying to... comment”), una estructura sintáctica atípica de *TikTok* que evadió los filtros de limpieza, lo que podría haber dificultado que el mecanismo de atención de la red se enfocase en la parte ofensiva.

Errores por longitud y origen del texto

Al observar los errores en función de la estructura de las transcripciones, se registraron patrones descriptivos de interés. En primer lugar, la longitud media de los textos mal clasificados (91 palabras) resultó ser inferior a la media global del *dataset* (103 palabras). Aunque sería necesario un análisis estadístico por intervalos para confirmar una correlación significativa, esta observación preliminar sugiere que los mensajes excesivamente cortos podrían privar a los modelos del contexto semántico necesario para entender la ironía o el sarcasmo, resultando en interpretaciones literales.

En segundo lugar, se identificó un desafío derivado de la diversidad en las fuentes del texto de entrada. La variable `text` proporcionada agrupa de forma indiferenciada texto proveniente de subtítulos superpuestos capturados por *OCR*, transcripciones automáticas de voz (*ASR*) e, incluso, metadatos y menciones a usuarios de la propia plataforma. Esta combinación produce transcripciones con nombres aleatorios y graves errores fonéticos o tipográficos. Planteamos la hipótesis de que esta densidad de ruido estructurado influye en la capacidad del modelo de aislar de manera precisa el verdadero discurso de odio del mensaje.

Reflexiones y posibles mejoras

El análisis cualitativo de estos fallos permite trazar líneas claras de trabajo a futuro. Una posible mejora radicaría en la aplicación de un preprocesamiento mucho más avanzado sobre el corpus, incorporando modelos de corrección ortográfica e identificadores de entidades nombradas para purgar nombres de usuario y menciones atípicas.

Asimismo, se podrían generar más ejemplos de sexismo benevolente, humor sarcástico e incidentes violentos no relacionados con el género, para que el sistema aprenda a definir las fronteras o límites del sexismo. Finalmente, el uso de modelos auxiliares previamente entrenados en la detección exclusiva de ironía podría añadirse al *Ensemble* como una característica de entrada adicional, ayudando a mitigar la alta tasa de Falsos Negativos detectada.

A modo de conclusión general, la optimización del sistema *Ensemble* indica un buen ajuste a este complejo contenido, alcanzando un pico de *Accuracy* local de 0.7291 y un *F1-score* de 0.7261. Reiteramos que es fundamental interpretar este valor de 0.7261 como una métrica de calibración interna ajustada al conjunto exploratorio.

De hecho, un análisis profundo revela sesgos predictivos importantes inherentes a esta calibración. Si observamos el rendimiento detallado por clase (apoyado en la matriz de $TN=209$, $FP=52$, $FN=84$ y $TP=157$), el modelo muestra un comportamiento notoriamente conservador: es más robusto al identificar instancias inofensivas (*Recall* de 0.80 para la clase No Sexista) que al detectar agresiones reales (*Recall* de 0.65 para la clase Sexista).

Esta diferencia de 15 puntos porcentuales es la causa directa de la acumulación de Falsos Negativos. En la práctica, el ajuste del sistema priorizó no penalizar a usuarios inocentes (manteniendo bajos los Falsos Positivos), a costa de permitir que discursos de odio sutiles o enmascarados bajo ironía eludan el filtro.

3.7.4. Evaluación Final sobre el Conjunto de *Test Ciego*

Tras la calibración interna del sistema explicada en las secciones anteriores, se procedió a la fase de evaluación definitiva. Con el objetivo de validar verdaderamente el modelo, se ejecutó la inferencia completa sobre el conjunto de *Test* ciego oficial proporcionado por la organización del reto *EXIST 2025* (compuesto por 674 vídeos sin etiquetar), el cual garantiza la separación rigurosa de autores para evitar fuga de información.

Las predicciones binarias generadas por el *Ensemble* fueron enviadas a la plataforma oficial de evaluación de la competición ¹. En la [Tabla 3.15](#) se presentan las métricas finales emitidas por el sistema *PyEvALL*.

Envío Oficial	Ranking Hipotético	ICM-Hard	ICM-Hard Norm	F1 (Clase YES)
<i>Ensemble Multimodal (Late Fusion)</i>	34	-0.1008	0.4491	0.6311

Tabla 3.15: Resultados oficiales obtenidos en la Subtarea 3.1 de *EXIST 2025* con el modelo *Ensemble*

Al contrastar esta evaluación independiente con las métricas de las entregas unimodales iniciales de la competición (detalladas previamente en la [Tabla 3.1](#)), se observa una mejora en el rendimiento del sistema. El *Ensemble* alcanza un *ICM Norm* de 0.4491, superando el 0.4355 de nuestro mejor envío oficial (*BERT*) y distanciándose significativamente del 0.2874 obtenido por el modelo generativo *Llama*.

Como es habitual en este tipo de investigaciones, se registra una caída en el rendimiento al pasar del entorno de selección local ($F1: 0.7261$) al entorno ciego ($F1: 0.6311$), evidenciando el *overfitting* del conjunto exploratorio reutilizado y la dificultad que presentan las nuevas distribuciones de datos. Sin embargo, la evolución positiva respecto a los *baselines* oficiales sugiere que la estrategia de fusión multimodal aporta una mayor robustez frente al problema. La combinación del análisis espacial de la imagen con la transcripción textual resulta de gran utilidad para contextualizar el mensaje, mitigando parte de la ambigüedad presente en las redes sociales y estableciendo una base más sólida para la moderación automática.

¹<https://eval1.uned.es/>

3.8. Perspectivismo en *LeWiDi*

El reto *EXIST 2025* introduce un desafío pionero en el campo de la detección del sexismo: la noción de que el sexismo, especialmente en sus formas más sutiles (como micromachismos y paternalismos), no siempre goza de un consenso absoluto. La percepción de si un comentario es sexista o inofensivo puede variar significativamente dependiendo de los sesgos culturales, las vivencias personales y, particularmente, el género del individuo que lo evalúa. Este concepto, conocido como Perspectivismo (*Learning with Disagreement* o *LeWiDi*), defiende que el desacuerdo entre anotadores no es un “ruido” que deba limpiarse, sino una señal rica en información que debe modelarse.

En las secciones anteriores, los modelos se entrenaron mediante “Consenso Mayoritario” (fusionando todas las opiniones en una sola etiqueta unificada). En esta última fase experimental referente a la Tarea 3.1, se buscará explorar cómo varía el rendimiento empírico de las redes neuronales cuando se filtran los datos de entrenamiento por el género del anotador o se instruye a un modelo generativo a simular un rol.

3.8.1. Segmentación demográfica en *Transformers*

La primera aproximación al perspectivismo consistió en entrenar modelos discriminativos independientes basados en los datos demográficos de los anotadores humanos. A partir del conjunto de entrenamiento maestro, se extrajeron de forma aislada los votos emitidos exclusivamente por los anotadores masculinos y, en paralelo, los emitidos por las anotadoras femeninas.

Dado que un mismo vídeo podía ser evaluado por varios anotadores del mismo género (por ejemplo, dos hombres), surgieron casos de empate o “disidencia interna” (un hombre etiquetando como 1 y otro como 0). Para abordar este desacuerdo interno de manera metodológica y utilizando la arquitectura **RoBERTa-base**, se entrenaron 8 conjuntos de datos distintos (4 estrategias x 2 géneros):

- **Descartes (*Hard Consensus*)**: Se eliminaron del entrenamiento aquellos vídeos en los que los anotadores humanos del mismo género no lograron ponerse de acuerdo.
- **Ante la duda, Sexismo (*Pessimistic*)**: En caso de empate interno humano, el video se etiquetó como sexista (1).
- **Ante la duda, No Sexismo (*Optimistic*)**: En caso de empate interno humano, prevaleció la presunción de inocencia y se etiquetó como no sexista (0).
- **Desenrollado (*Unrolling*)**: No se forzó ningún consenso. Si un vídeo presentaba empate, se introdujo dos veces en el dataset: una fila con etiqueta 1 y otra fila idéntica con etiqueta 0, obligando al modelo a asimilar la dualidad de la anotación.

Para interpretar de forma científica los resultados de esta fase, es fundamental analizar la distribución resultante tras aplicar estas estrategias. En la [Tabla 3.16](#) se exponen los tamaños y el balance de clases de cada subconjunto de datos.

Estrategia	Género	Total Vídeos	No Sexista (0)	Sexista (1)
Descartes	Femenino	1984	1035	949
	Masculino	1396	787	609
<i>Pessimistic</i>	Femenino	2006	1035	971
	Masculino	1612	787	825
<i>Optimistic</i>	Femenino	2006	1057	949
	Masculino	1612	1003	609
<i>Unrolling</i>	Femenino	2644	1372	1272
	Masculino	1948	1056	892

Tabla 3.16: Distribución de los *datasets* de entrenamiento tras la segmentación por género y aplicación de estrategias de resolución de empates.

Debe reconocerse una limitación a la hora de comparar estos modelos frente al conjunto local de desarrollo (*Gold Standard* unificado de 502 instancias). Como se evidencia en la tabla, existe un factor: los *datasets* basados en anotaciones femeninas poseen un mayor volumen de datos que los masculinos. Por tanto, las variaciones en el rendimiento no pueden atribuirse exclusivamente a diferencias intrínsecas en la perspectiva de género, sino que podrían estar directamente influenciadas por la diferencia en la cantidad de ejemplos expuestos a la red durante el entrenamiento.




Figura 3.5: Resultados de la estrategia *Hard Consensus* en hombres




Figura 3.6: Resultados de la estrategia *Hard Consensus* en mujeres

En la [Figura 3.5](#) y en la [Figura 3.6](#), se evaluó el rendimiento tras aplicar la estrategia de Descartes:

- **Perspectiva Femenina:** El modelo entrenado con estos datos logra un *F1-score* de 0.6771. Según se observa en su respectiva matriz de confusión, identifica 164 Verdaderos Positivos frente a los 124 del modelo masculino, alcanzando un *Recall* de 0.68 para la clase sexista.
- **Perspectiva Masculina:** Presenta un *F1-score* de 0.6462. Como evidencia su matriz, su *Recall* para la clase sexista decae a 0.51, registrando 117 Falsos Negativos frente a 124 Verdaderos Positivos sobre el conjunto de validación unificado.




Figura 3.7: Resultados de la estrategia *Pessimistic* en hombres




Figura 3.8: Resultados de la estrategia *Pessimistic* en mujeres

En la [Figura 3.7](#) y en la [Figura 3.8](#), asumiendo la etiqueta sexista en caso de empate humano, las métricas muestran el siguiente comportamiento:

- **Perspectiva Femenina:** Alcanza aquí el mejor rendimiento global registrado en esta fase (*F1-score* de 0.6860). La adopción de esta postura conservadora no dispara de forma descontrolada los Falsos Positivos, conservando una *Precisión* de 0.72 para la clase positiva.
- **Perspectiva Masculina:** El modelo disminuye su rendimiento bajo esta directriz (F1: 0.6453). Al obligarle a asumir la etiqueta sexista en los empates, el modelo incrementa los errores al clasificar instancias de la clase 0, lo que reduce su *Accuracy* global a 0.6494.




Figura 3.9: Resultados de la estrategia *Optimistic* en hombres




Figura 3.10: Resultados de la estrategia *Optimistic* en mujeres

En la [Figura 3.9](#) y en la [Figura 3.10](#), asumiendo la etiqueta no sexista en los empates, se observa:

- **Perspectiva Masculina:** El modelo logra un *Accuracy* general de 0.6713, pero presenta un *Recall* de 0.54 para la clase sexista, arrojando 110 Falsos Negativos en su matriz frente a los datos del *Gold Standard*.
- **Perspectiva Femenina:** Aunque su *Accuracy* global decae (0.6534), su *Recall* para la clase sexista se sitúa en 0.71, reduciendo los Falsos Negativos a 71.




Figura 3.11: Resultados de la estrategia *Unrolling* en hombres




Figura 3.12: Resultados de la estrategia *Unrolling* en mujeres

Como podemos observar en la [Figura 3.11](#) y en la [Figura 3.12](#), la aplicación de *Unrolling* produce un ajuste evidente en ambos perfiles:

- **Convergencia de métricas:** Al duplicar los datos empatados, las diferencias de rendimiento entre el conjunto de entrenamiento de hombres (*F1-score*: 0.6687) y el de mujeres (*F1-score*: 0.6654) prácticamente desaparecen.
- **Análisis:** Ambos modelos calcan sus métricas de *Recall* para la clase Sexista (0.56). Esta similitud sugiere que la estrategia de desenrollado, al exponer a la red a la dualidad de las etiquetas, homogeneiza el comportamiento predictivo, difuminando el impacto del filtrado demográfico original.

3.8.2. Análisis de Sensibilidad al *Prompt* en LLMs (*Persona Prompting*)

La segunda estrategia evaluó la sensibilidad de los modelos generativos ante variaciones semánticas en la instrucción (*Prompt Engineering*). Es esencial clarificar que el objetivo de este experimento no es simular de forma válida perspectivas humanas reales, sino cuantificar cómo la alteración explícita de la palabra clave asociada al género en el *prompt* activa diferentes sesgos estadísticos preadquiridos por la inteligencia artificial.

Aprovechando la capacidad de los LLMs para adaptar sus salidas, se aplicó la técnica de *Persona Prompting* sobre el modelo *Mistral-7B-Instruct-v0.3* en un entorno *Zero-Shot*. En lugar de pedirle una clasificación neutral, se diseñaron dos *prompts* que inyectaron una instrucción de rol directamente en el contexto del modelo. El *prompt* diseñado fue el siguiente:

[INST] Actúa como un hombre. Eres un experto analizando redes sociales. Clasifica el siguiente texto en una de estas dos categorías: 'Sexista' o 'No Sexista'. Devuelve ÚNICAMENTE la etiqueta correspondiente, sin explicaciones adicionales. Texto: {texto} [/INST] Etiqueta:

De manera simétrica, para evaluar la instrucción opuesta, se sustituyeron exclusivamente las referencias de género (“Actúa como una mujer”, “Eres una experta...”).

En las [Figura 3.13](#) y [Figura 3.14](#) se puede observar cómo la inyección del rol altera la distribución de las predicciones del modelo frente a los mismos 502 registros del *Test* de desarrollo.




Figura 3.13: Resultados de la técnica *Persona Prompting* instruyendo el rol de hombre




Figura 3.14: Resultados de la técnica *Persona Prompting* instruyendo el rol de mujer

3.8.3. Análisis de los Resultados Exploratorios

Para facilitar la comparativa de los impactos demográficos detallados en las secciones anteriores, en la [Tabla 3.17](#) se aglutinan los resultados obtenidos por todas las arquitecturas y estrategias tras la segmentación por género.

Arquitectura	Estrategia de <i>LeWiDi</i>	Rol / Género	<i>Accuracy</i>	<i>F1-score</i> (Macro)
RoBERTa-base	Descartes (<i>Hard Consensus</i>)	Femenino	0.6773	0.6771
		Masculino	0.6554	0.6462
	<i>Pessimistic</i> (Duda = Sexismo)	Femenino	0.6912	0.6860
		Masculino	0.6494	0.6453
	<i>Optimistic</i> (Duda = Inocencia)	Femenino	0.6534	0.6532
		Masculino	0.6713	0.6638
	Desenrollado (<i>Unrolling</i>)	Femenino	0.6713	0.6654
		Masculino	0.6753	0.6687
Mistral-7B-Instruct	<i>Persona Prompting</i>	Instrucción Femenina	0.5757	0.5655
		Instrucción Masculina	0.5578	0.5417

Tabla 3.17: Rendimiento comparativo de las estrategias exploratorias filtradas por género.

El análisis de estos resultados permite extraer varias observaciones descriptivas sobre el comportamiento de las redes neuronales en este escenario. En primer lugar, los modelos *Transformers* entrenados con los *datasets* femeninos alcanzaron de forma consistente métricas más altas frente al *Gold Standard* unificado (pico de *F1-score* de 0.6860) que sus contrapartes masculinas (cuyo máximo se situó en 0.6687). No obstante, como se advirtió previamente, el riesgo de un sesgo por el tamaño de la muestra impide concluir con seguridad que existan características superiores en dichas anotaciones.

En segundo lugar, se observan diferencias ante la gestión empírica de la duda. Mientras que la variante *Pessimistic* maximizó el rendimiento en el *dataset* filtrado femenino, en el caso del masculino la mejor respuesta se obtuvo preservando la ambigüedad mediante *Unrolling*.

Finalmente, los resultados de *Persona Prompting* evidencian la adaptación de los *LLMs* a los sesgos inducidos por la formulación de la instrucción. El modelo instruido con la palabra “mujer” logró un *F1-score* de 0.5655, frente al 0.5417 arrojado bajo la instrucción “hombre”. Al examinar sus matrices, el *prompt* masculino generó una tasa mayor de Falsos Negativos (148 instancias frente a las 135 generadas por el *prompt* femenino). Planteamos como hipótesis que la inyección de la palabra “hombre” activa estereotipos estadísticos preentrenados en la red que derivan en una evaluación más restrictiva a la hora de tipificar el sexismo.

Es importante remarcar que el diseño metodológico de toda esta fase es de naturaleza exploratoria. Las métricas exponen el comportamiento de los modelos y las variaciones de los *datasets*, y en ningún caso deben extrapolarse para formular juicios psicológicos o sociológicos sobre el comportamiento real de hombres y mujeres.

3.9. Experimentación Multietiqueta (Tarea 3.3)

La Tarea 3.3 del desafío *EXIST 2025* plantea un problema de clasificación mucho más específico y complejo que la mera detección binaria, estructurándose como un reto jerárquico y multietiqueta. En su formulación original, el sistema debe primero discriminar si un contenido es sexista o inofensivo (primer nivel de la jerarquía) y, únicamente en caso afirmativo, categorizarlo en una o varias de cinco tipologías concretas simultáneamente (clasificación multietiqueta en el segundo nivel).

Cabe matizar explícitamente que la experimentación detallada en esta sección constituye un análisis parcial y exploratorio de las capacidades de los modelos para fines puramente académicos, por lo que no reproduce la evaluación jerárquica completa de la subtarea 3.3 oficial de *EXIST 2025*. Para acotar el alcance de este Trabajo de Fin de Máster, se ha definido un análisis condicionado: se asume que el primer nivel jerárquico ya está resuelto, filtrando el conjunto de datos para evaluar a los modelos exclusivamente sobre los vídeos que ya estaban catalogados previamente como sexistas.

Asimismo, en lugar de desplegar una única arquitectura compleja con una capa de salida multietiqueta conjunta, el problema se ha abordado de forma simplificada mediante una estrategia conocida como *Binary Relevance* o *One-vs-Rest*. Se ha aislado cada categoría y se han entrenado clasificadores binarios independientes para cada tipología. Si bien esto simplifica la fase de optimización, conlleva una limitación estructural: las redes no son capaces de aprender las posibles correlaciones entre las distintas categorías de sexismo.

Bajo este entorno controlado, las cinco categorías evaluadas son:

- ***Ideological and Inequality***: El texto desacredita el movimiento feminista, rechaza la desigualdad de género o victimiza a un hombre.
- ***Stereotyping and Dominance***: Expresa ideas falsas sobre los roles de la mujer (sumisa o cuidadora) o tareas inadecuadas, afirmando la superioridad masculina.
- ***Objectification***: Presenta a la mujer como un objeto, describiendo cualidades físicas obligatorias para cumplir cánones de belleza o hipersexualización.
- ***Sexual Violence***: Sugerencias sexuales, petición de favores o acoso explícito de naturaleza sexual (violación o agresión).
- ***Misogyny and Non-Sexual Violence***: Expresión de odio puro y violencia no sexual hacia las mujeres.

Para abordar esta tarea, se replicó la metodología de experimentación unimodal utilizada en la Tarea 3.1. Se seleccionó el modelo con mejor rendimiento de cada familia arquitectónica para entrenarlo de manera independiente frente a cada una de las 5 etiquetas:

- ***Transformers***: roberta-base.

- **LLM:** Mistral-7B-Instruct.
- **Visión Estática:** ConvNeXt, entrenado sobre secuencias de 4 *frames*.
- **Visión Temporal:** TimeSFormer, procesando 16 *frames* por inferencia.

3.9.1. Preparación del Dataset Multietiqueta

A diferencia de la Tarea 3.1, la naturaleza multietiqueta del problema requiere un tratamiento especial de los datos. A partir del *JSON* original, se filtraron exclusivamente aquellos vídeos catalogados previamente como sexistas (etiqueta 1 en la Tarea 3.1). Para unificar las discrepancias entre anotadores respecto al tipo de sexismo detectado, se aplicó una lógica *OR*: si al menos un anotador marcaba una de las cinco etiquetas en su evaluación, el vídeo se consideraba positivo para dicha clase.

Es necesario reconocer que esta heurística de unificación transforma la incertidumbre del *Learning with Disagreement (LeWiDi)* en etiquetas rígidas (*Hard Labels*), perdiendo la distribución suave original y tendiendo a sobre-representar las categorías (sesgo hacia la sensibilidad). Por tanto, estas etiquetas actúan como un terreno de calibración experimental y no deben interpretarse como una verdad absoluta y neutral.

Dado el fuerte desbalance intrínseco en la distribución de las subcategorías, la división del conjunto original en *Train* (80 %) y *Test* (20 %) se ejecutó mediante la función `iterative_train_test_split` de la librería `skmultilearn`. Este enfoque garantiza un particionado estratificado, asegurando que las proporciones de las clases minoritarias se mantengan estables en ambos subconjuntos. A partir de este *CSV* maestro, se generaron las réplicas correspondientes para el entrenamiento de visión estática y temporal.

3.9.2. Resultados y Análisis Cruzado por Tipología

El entrenamiento aislado de los cuatro mejores modelos contra las cinco etiquetas reveló un comportamiento dependiente de la modalidad de los datos (texto frente a imagen/movimiento) y de la distribución estadística de cada clase. En la [Tabla 3.18](#) se resumen las métricas *F1-Score (Macro)* y *Accuracy* obtenidas sobre el conjunto de *Test* de desarrollo multietiqueta. Dado el enfoque de *Binary Relevance*, las métricas se reportan de forma aislada por etiqueta y no se incluyen métricas globales *multilabel*.

Etiqueta	Modelo	Inferencia	Accuracy	F1-score
Ideological-Inequality	roberta-base	-	0.7130	0.7050
	mistral	-	0.4957	0.4473
	convnext 4 frames	max-pooling	0.5391	0.5391
		mean-pooling	0.6087	0.5859
		majority vote	0.6000	0.5911
	timesformer	-	0.5957	0.5908
Stereotyping-Dominance	roberta-base	-	0.6609	0.5963
	mistral	-	0.6435	0.4429
	convnext 4 frames	max-pooling	0.7522	0.4758
		mean-pooling	0.7304	0.5114
		majority vote	0.7391	0.5271
	timesformer	-	0.7087	0.5624
Objectification	roberta-base	-	0.7435	0.5087
	mistral	-	0.7478	0.5114
	convnext 4 frames	max-pooling	0.6043	0.5098
		mean-pooling	0.6957	0.5082
		majority vote	0.6652	0.5116
	timesformer	-	0.7304	0.5399
Sexual Violence	roberta-base	-	0.8522	0.4601
	mistral	-	0.8522	0.4601
	convnext 4 frames	max-pooling	0.8522	0.4601
		mean-pooling	0.8522	0.4601
		majority vote	0.8522	0.4601
	timesformer	-	0.8522	0.4601
Misogyny and Non-Sexual Violence	roberta-base	-	0.8217	0.4511
	mistral	-	0.8043	0.4861
	convnext 4 frames	max-pooling	0.8217	0.4511
		mean-pooling	0.8217	0.4511
		majority vote	0.8217	0.4511
	timesformer	-	0.7913	0.4615

Tabla 3.18: Resultados de *Accuracy* y *F1-score* de cada una de las etiquetas

El análisis comparativo de las métricas de rendimiento (*F1-score Macro* y *Accuracy*) arroja tres observaciones fundamentales que sugieren cómo se comportan las redes neuronales frente al tipo de sexismo:

1. **El dominio del Texto en la Ideología y el Estereotipo:** Para la etiqueta *Ideological and Inequality*, el modelo puramente textual **RoBERTa-base** dominó la clasificación con un F1 de **0.7050**, muy superior al resto de modelos, incluyendo a *Mistral* que obtuvo un pobre 0.4473. El contenido ideológico y político en plataformas como *TikTok* recae casi exclusivamente en el discurso hablado o escrito, haciendo que las modalidades visuales (**ConvNeXt**: 0.5911, **TimeSFormer**: 0.5908) queden relegadas a un papel secundario. En la categoría *Stereotyping and Dominance*, **RoBERTa** volvió a

liderar (F1: 0.5963), seguido de cerca por la visión temporal (0.5624), sugiriendo que los estereotipos sí poseen una carga visual de acciones o roles que el modelo de vídeo logra captar en mejor medida que el de imagen estática.

2. **Indicios sobre el movimiento en la Cosificación:** En la etiqueta *Objectification*, los modelos de texto (RoBERTa: 0.5087) y de imagen estática (ConvNeXt: 0.5116) mostraron dificultades, obteniendo métricas cercanas a la clasificación aleatoria. Sin embargo, la arquitectura de visión temporal **TimeSFormer** logró despuntar ligeramente (F1: **0.5399**). A falta de pruebas de evaluaciones en un entorno de test ciego, este resultado sirve como un indicio exploratorio de que la cosificación en formato vídeo podría captarse con mayor eficacia modelando el movimiento (poses, movimientos de cámara o acciones sugerentes en el tiempo) que analizando un fotograma congelado.
3. **Colapso predictivo ante el desbalanceo de clases raras:** Para las categorías extremadamente minoritarias en el *dataset* (*Sexual Violence* y *Misogyny and Non-Sexual Violence*), los cuatro modelos sin excepción sufrieron un colapso. El valor de *F1-score Macro* de **0.4601** (con un *Accuracy* de 0.8522) observado en *Sexual Violence* ilustra el *baseline* mayoritario: debido a la extrema escasez de ejemplos positivos de violencia sexual, las redes neuronales no logran extraer patrones y optan por predecir sistemáticamente la clase negativa (0) en todas las instancias. El 0.4601 no representa un aprendizaje deficiente, sino el valor matemático resultante de obtener un *Recall* perfecto en la clase mayoritaria y un cero absoluto en la minoritaria. Ninguna modalidad pudo sobreponerse a esta barrera estadística sin la aplicación previa de técnicas agresivas de *Oversampling* o ajustes en la ponderación de la función de pérdida.

3.10. Resumen Global de Resultados

A lo largo de este capítulo, se ha desplegado una extensa batería de experimentos que abarca múltiples modalidades (texto, imagen y vídeo) y enfoques arquitectónicos (modelos discriminativos y generativos). Dada la gran cantidad de combinaciones de hiperparámetros, técnicas de *Data Augmentation* y lógicas de consolidación evaluadas, resulta importante destacar los hitos más relevantes de la investigación antes de extraer las conclusiones finales.

En la [Tabla 3.19](#) se consolida exclusivamente el modelo con mejor rendimiento de cada fase experimental para la clasificación binaria de sexismo (Tarea 3.1). Esta visión panorámica permite apreciar de un vistazo la evolución de las métricas desde los *baselines* iniciales hasta llegar a la solución multimodal definitiva.

Modalidad	Mejor Arquitectura	Técnica Destacada	Accuracy	F1-score
Texto (<i>Baseline</i>)	bert-base-multilingual-cased	<i>Fine-Tuning</i>	0.6275	0.6215
Texto (Discrim.)	roberta-base	<i>Fine-Tuning</i>	0.6972	0.6934
Texto (Generativo)	Mistral-7B-Instruct	<i>PEFT</i> (<i>QLoRA</i>)	0.7171	0.7141
Visión Estática	ConvNeXt	4 frames (<i>Mean-Pool</i>)	0.6275	0.6245
Visión Temporal	TimeSformer	10 % <i>Augmentation</i> (Clase 1)	0.5956	0.5956
Fusión (Desarrollo)	<i>Ensemble</i> (Local)	<i>Late Fusion</i> (0.35/0.55/0.10)	0.7291	0.7261
Fusión (<i>Test</i> Ciego)	<i>Ensemble</i> (Oficial)	Evaluación PyEvALL	0.6418	0.6311

Tabla 3.19: Resumen de los mejores modelos obtenidos por modalidad para la Tarea 3.1.

Como se observa empíricamente en la tabla, dentro del entorno de desarrollo local ninguna modalidad aislada fue capaz de superar al Mistral-7B-Instruct en la métrica *F1-score*. La mejora más significativa a nivel interno se produjo al fusionar los grandes modelos de lenguaje con la extracción de características espaciales de la visión estática y temporal, sugiriendo el potencial del enfoque multimodal para el análisis del sexismo en redes sociales modernas. Si bien la evaluación independiente sobre el conjunto ciego oficial ajusta el rendimiento real del sistema a un *F1-score* de 0.6311 (reflejando el sobreajuste previo al conjunto local de validación), la arquitectura unificada logra una mejora evidente frente a los envíos unimodales originales de la competición.

Adicionalmente, los experimentos complementarios de la Tarea 3.3 sugirieron que la detección de tipologías específicas requiere enfoques especializados (por ejemplo, el movimiento temporal para captar la cosificación, o el texto puro para el sesgo ideológico), mientras que la experimentación exploratoria con *LeWiDi* sugirió que las diferencias demográficas en la anotación podrían influir en el comportamiento del modelo, si bien este hallazgo debe interpretarse con suma cautela debido a los factores presentes en las distribuciones de los datos.

Conclusiones y Trabajo Futuro

Este capítulo ofrece una síntesis de la investigación realizada, valorando el grado de cumplimiento de los objetivos iniciales y destacando los hallazgos más relevantes obtenidos tras la extensa variedad de experimentos. Asimismo, se exponen las limitaciones encontradas, se proponen líneas de investigación futuras para dar continuidad al proyecto, y se detalla y justifica el esfuerzo temporal y computacional invertido en su desarrollo.

4.1. Conclusiones

Consecución de Objetivos

La evaluación de los objetivos planteados al inicio de esta memoria muestra un grado de cumplimiento muy satisfactorio en términos generales, si bien es necesario realizar una valoración individualizada para señalar aquellos que se han alcanzado de forma parcial:

- **Estudiar el estado del arte:** Cumplido. Se ha fundamentado la investigación en la literatura reciente sobre *Deep Learning*, PLN y Visión Artificial aplicados a la detección de contenido de odio.
- **Preprocesar y adecuar el conjunto de datos:** Cumplido. Se desarrolló un *pipeline* robusto de limpieza textual mediante *regex* y extracción temporal de *frames* mediante *OpenCV*, además de implementar lógicas matemáticas para el manejo de etiquetas bajo el paradigma *LeWiDi*.
- **Implementar y ajustar (*fine-tuning*) modelos:** Cumplido. Se entrenaron y compararon con éxito arquitecturas discriminativas (*RoBERTa*), generativas (*Mistral*), de visión estática (*ConvNeXt*) y de visión temporal (*TimeSFormer*).
- **Proponer y desarrollar estrategias de fusión:** Cumplido. Se diseñó, optimizó y evaluó un sistema *Ensemble* basado en *Late Fusion* mediante la suma ponderada de probabilidades.
- **Participar en la tarea 3.1 de *EXIST 2025*:** Cumplido. Se enviaron las predicciones oficiales utilizando *BERT* y *Llama* (*zero-shot*), estableciendo el *baseline* del proyecto.

- **Desarrollar marco de evaluación local (Tarea 3.1 y 3.3): Alcanzado parcialmente.** Si bien se generó un entorno de evaluación riguroso, el marco local de la Tarea 3.1 presentó un fuerte sesgo (*overfitting*) al reutilizar el *holdout* para la selección de hiperparámetros y la ponderación. Asimismo, la Tarea 3.3 no se abordó como un sistema multietiqueta jerárquico completo, sino que se condicionó a un análisis exploratorio simplificado (*One-vs-Rest*) que sufrió un colapso predictivo ante el desbalanceo extremo de las clases minoritarias.
- **Explorar el impacto del perspectivismo:** Cumplido. Se demostró la sensibilidad algorítmica a la perspectiva de género mediante la segmentación demográfica de los anotadores y técnicas de *Persona Prompting*.

Resumen de los Hallazgos

Los resultados de la experimentación sugieren fuertemente que el sexismo en plataformas digitales es un fenómeno multimodal. Ningún modelo unimodal logró igualar el rendimiento del sistema unificado mediante *Late Fusion* en el entorno de validación local (donde alcanzó un *F1-score* de 0.7261). Al evaluar su capacidad predictiva frente al conjunto ciego oficial de la competición, el *Ensemble* obtuvo un *F1-score* de 0.6311. Esta caída de rendimiento evidencia la existencia de un sobreajuste (*overfitting*) previo durante la fase de selección, pero, aun así, la arquitectura unificada logró una mejora objetiva frente a los enfoques individuales. El análisis exploratorio detallado indicó que el texto resulta especialmente útil para detectar cargas ideológicas, mientras que la información visual y temporal parece aportar un contexto valioso para abordar fenómenos complejos como la cosificación.

Además, los experimentos de perspectivismo han mostrado observaciones empíricas de gran valor para el diseño de IAs: la anotación del discurso de odio realizada desde una perspectiva femenina resultó en modelos con métricas de recuperación (*Recall*) más sólidas. Por su parte, la simulación de roles en Grandes Modelos de Lenguaje demostró que inyectar el rol “masculino” en el *prompt* dispara la tasa de falsos negativos. Si bien estos hallazgos están condicionados por el tamaño de los *datasets* y los sesgos estadísticos preentrenados en los *LLMs*, sugieren que la identidad demográfica (ya sea real o simulada) altera la evaluación algorítmica del discurso de odio.

Implicaciones

Los resultados obtenidos respaldan el potencial de combinar *LLMs* ajustados mediante *PEFT* (*QLoRA*) con *Vision Transformers*. Se observa empíricamente que, para moderar plataformas modernas de vídeos cortos, el análisis de texto aislado puede resultar insuficiente, recomendándose su hibridación con la semántica del movimiento y la disposición

espacial para comprender la verdadera intencionalidad del contenido.

Limitaciones

La principal limitación técnica encontrada ha sido el desbalanceo extremo en las clases minoritarias del *dataset* multietiqueta (especialmente en *Sexual Violence* y *Misogyny and Non-Sexual Violence*). Esta carencia de ejemplos positivos provocó un colapso predictivo en todas las familias de modelos, que optaron por predecir matemáticamente la clase mayoritaria. Por otro lado, hemos tenido la limitación derivada de haber reutilizado el mismo conjunto local de desarrollo para la selección de hiperparámetros y pesos del *Ensemble*, lo que generó un sesgo al alza en las métricas internas reportadas. Finalmente, la extracción del texto incrustado en el vídeo introdujo ruido y “basura algorítmica” (como *tags* y menciones) que dificultó la comprensión semántica de las redes.

Contribuciones

Este trabajo aporta una metodología documentada de manera exhaustiva para el tratamiento multimodal de datos en español e inglés. Se ha analizado el comportamiento comparativo de modelos discriminativos y generativos, se han evaluado distintas lógicas estadísticas de agregación de fotogramas (*Mean-Pooling*, *Majority-Vote*), y se ha explorado el impacto de los sesgos demográficos (*Le WiDi*) en el entrenamiento de la inteligencia artificial.

Consideraciones Éticas

El uso de modelos de inteligencia artificial para la moderación de contenido humano conlleva profundas implicaciones éticas. Como ha ilustrado el análisis de errores y de perspectivismo de este documento, los modelos tienden a heredar e incluso amplificar los sesgos de sus datos de entrenamiento. Las decisiones de censura o bloqueo automatizadas en redes sociales no deben ser tomadas como verdades absolutas, sino que deben contextualizarse y contar con supervisión humana para evitar la discriminación y el silenciamiento sistémico.

4.2. Trabajo Futuro

Mejoras Metodológicas y Preprocesamiento

A corto plazo, una línea de trabajo esencial consiste en implementar filtros de limpieza de texto mucho más robustos para mitigar el ruido introducido por el *OCR* y las transcripciones de audio automáticas, traduciendo los metadatos visuales a un formato puramente semántico. Asimismo, resultaría crítico aplicar técnicas de *Oversampling* avanzado o penalización de pesos funcionales (*Class Weights*) para solventar el colapso predictivo de los modelos ante el desbalanceo de las categorías más graves.

Extensiones del Estudio Multimodal

Aunque este trabajo ha fusionado texto, imagen estática y secuencias temporales de vídeo, el sonido aporta información vital no verbal (tono de voz, sarcasmo acústico, risas). Una extensión natural del sistema consistirá en integrar modelos especializados en características acústicas, como *Wav2Vec* o *Audio Spectrogram Transformers*, añadiendo una nueva dimensión a la ecuación del *Ensemble*. Además, sería interesante investigar técnicas de *Early Fusion* o arquitecturas de atención cruzada (*Cross-Attention*) que permitan a los modelos interconectar y evaluar texto e imagen de forma simultánea, y no en etapas separadas.

Aplicaciones Prácticas

A nivel aplicado, la arquitectura híbrida documentada podría sentar las bases para una herramienta de *software* capaz de asistir a los equipos de *Trust & Safety* de plataformas digitales. Esta herramienta no buscaría censurar autónomamente, sino priorizar y marcar de forma automática aquellos contenidos que, por su combinación de factores textuales y visuales, presenten una alta probabilidad de albergar discursos de odio, optimizando así el tiempo de revisión humana.

4.3. Planificación Temporal del Trabajo Realizado

En este apartado se detalla el tiempo y los recursos empleados en la investigación y redacción del presente Trabajo de Fin de Máster. Dada la magnitud de la experimentación requerida, el mayor esfuerzo no recayó en las entregas iniciales de la competición, sino en el análisis avanzado, entrenamiento y depuración de modelos a posteriori. Las horas globales estimadas se resumen en la [Tabla 4.1](#).

Tarea	Horas Estimadas
Revisión del Estado del Arte e Investigación Teórica:	50
- Análisis del discurso de odio, <i>Transformers</i> , y <i>LLMs</i> .	
- Estudio del Perspectivismo (<i>LeWiDi</i>) y métricas de evaluación.	
Familiarización con el Entorno y Tecnologías:	50
- Despliegue en <i>Google Colab</i> , librerías (<i>PyTorch</i> , <i>Hugging Face</i>).	
- Lógicas de extracción multimedia (<i>OpenCV</i> , <i>Decord</i>).	
Tratamiento de Datos y Entregas Preliminares (EXIST 2025):	70
- Limpieza de <i>datasets</i> , gestión de nulos y estructuración de <i>frames</i> .	
- <i>Splits</i> estratificados para la tarea binaria y multietiqueta.	
Experimentación Avanzada <i>a posteriori</i> y Desarrollo:	140
- Ejecución y entrenamiento intensivo en GPUs (entorno L4 de Colab).	
- <i>Debugging</i> , resolución de errores de memoria (OOM), HPO.	
- Algoritmos de <i>Late Fusion</i> y <i>Persona Prompting</i> en <i>Mistral</i> .	
Elaboración de la Memoria y Formato:	70
- Análisis cruzado de resultados, extracción de gráficas y conclusiones.	
- Redacción intensiva, maquetación en $\text{\LaTeX}$ y revisión final.	
Total	380

Tabla 4.1: Estimación de la planificación temporal del trabajo realizado.

Como se refleja en la tabla, el proyecto ha requerido una inversión aproximada de 380 horas. Cabe destacar el elevado coste computacional de la fase de Experimentación Avanzada. Durante esta etapa, se consumieron más de 300 unidades de cómputo en la plataforma *Google Colab* utilizando hardware de alto rendimiento (*GPUs NVIDIA L4*) para poder procesar los grandes volúmenes de datos de imágenes y vídeo, y realizar el *Fine-Tuning* de arquitecturas pesadas como *ConvNeXt*, *TimeSFormer* y el modelo de lenguaje *Mistral-7B*. Este volumen de experimentación es el que ha permitido estructurar y fundamentar los hallazgos descritos a lo largo de este documento.

Referencias

- [1] Laura Plaza et al. “Overview of EXIST 2025: Learning with Disagreement for Sexism Identification and Characterization in Tweets, Memes, and TikTok Videos”. En: *International Conference of the Cross-Language Evaluation Forum for European Languages*. Springer. 2025, págs. 266-289.
- [2] Lin Tian, Johanne R Trippas y Marian-Andrei Rizoiu. “MARIO at EXIST 2025: A Simple Gateway to Effective Multilingual Sexism Detection”. En: *arXiv preprint arXiv:2507.10996* (2025).
- [3] Tom M. Mitchell. *Machine Learning*. New York: McGraw-Hill, 1997.
- [4] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. New York: Springer, 2006.
- [5] Trevor Hastie, Robert Tibshirani y Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Second. New York: Springer, 2009.
- [6] Andrew G. Barto. “Reinforcement Learning: Connections, Surprises, Challenges”. En: *AI Magazine* 40.1 (2019), págs. 3-15.
- [7] Min-Ling Zhang y Zhi-Hua Zhou. “A Review on Multi-label Learning Algorithms”. En: *IEEE Transactions on Knowledge and Data Engineering* 26.8 (2013), págs. 1819-1837.
- [8] Shervin Minaee et al. “Deep Learning-based Text Classification: A Comprehensive Review”. En: *ACM Computing Surveys (CSUR)* 54.3 (2021), págs. 1-40.
- [9] Andrej Karpathy et al. “Large-scale Video Classification with Convolutional Neural Networks”. En: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2014, págs. 1725-1732.
- [10] Tadas Baltrušaitis, Chaitanya Ahuja y Louis-Philippe Morency. “Multimodal Machine Learning: A Survey and Taxonomy”. En: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 41.2 (2018), págs. 423-443.
- [11] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.
- [12] Yann LeCun, Yoshua Bengio y Geoffrey Hinton. “Deep Learning”. En: *Nature* 521.7553 (2015), págs. 436-444.
- [13] François Chollet. *Deep Learning with Python*. Second. Shelter Island, NY, USA: Manning Publications, 2021.
- [14] Lutz Prechelt. “Early Stopping - But When?” En: *Neural Networks: Tricks of the Trade*. Springer, 2002, págs. 55-69.
- [15] Yoshua Bengio. “Practical Recommendations for Gradient-Based Training of Deep Architectures”. En: *Neural Networks: Tricks of the Trade*. Second. Springer, 2012, págs. 437-478.
- [16] Dominic Masters y Carlo Luschi. “Revisiting Small Batch Training for Deep Neural Networks”. En: *arXiv preprint arXiv:1804.07612* (2018).

- [17] Sebastian Ruder. “An Overview of Gradient Descent Optimization Algorithms”. En: *arXiv preprint arXiv:1609.04747* (2016).
- [18] Anders Krogh y John Hertz. “A Simple Weight Decay can Improve Generalization”. En: *Advances in Neural Information Processing Systems (NeurIPS)* 4 (1991).
- [19] Ilya Loshchilov y Frank Hutter. “Decoupled Weight Decay Regularization”. En: *arXiv preprint arXiv:1711.05101* (2017).
- [20] Shai Shalev-Shwartz y Shai Ben-David. *Understanding Machine Learning: From Theory to Algorithms*. Cambridge, UK: Cambridge University Press, 2014.
- [21] Kevin P. Murphy. *Machine Learning: A Probabilistic Perspective*. Cambridge, MA, USA: MIT Press, 2012.
- [22] Jinseok Nam et al. “Large-scale Multi-label Text Classification—Revisiting Neural Networks”. En: *Joint European Conference on Machine Learning and Knowledge Discovery in Databases (ECML PKDD)*. Springer. 2014, págs. 437-452.
- [23] Xue Ying. “An Overview of Overfitting and its Solutions”. En: *Journal of Physics: Conference Series*. Vol. 1168. 2. IOP Publishing. 2019, pág. 022022.
- [24] Nitish Srivastava et al. “Dropout: A Simple Way to Prevent Neural Networks from Overfitting”. En: *The Journal of Machine Learning Research* 15.1 (2014), págs. 1929-1958.
- [25] Mohammad Mahdi Bejani y Mehdi Ghatte. “A Systematic Review on Overfitting Control in Shallow and Deep Neural Networks”. En: *Artificial Intelligence Review* 54.8 (2021), págs. 6391-6438.
- [26] James Bergstra y Yoshua Bengio. “Random Search for Hyper-parameter Optimization”. En: *Journal of Machine Learning Research* 13.2 (2012).
- [27] Qian Li et al. “A Survey on Text Classification: From Traditional to Deep Learning”. En: *ACM Transactions on Intelligent Systems and Technology (TIST)* 13.2 (2022), págs. 1-41.
- [28] Bonan Min et al. “Recent Advances in Natural Language Processing via Large Pre-trained Language Models: A Survey”. En: *ACM Computing Surveys* 56.2 (2023), págs. 1-40.
- [29] Diksha Khurana et al. “Natural Language Processing: State of the Art, Current Trends and Challenges”. En: *Multimedia Tools and Applications* 82.3 (2023), págs. 3713-3744.
- [30] Dan Jurafsky y James H. Martin. *Speech and Language Processing*. Third. London: Pearson, 2014.
- [31] Ashish Vaswani et al. “Attention Is All You Need”. En: *Advances in Neural Information Processing Systems (NeurIPS)* 30 (2017).
- [32] Jacob Devlin et al. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. En: *arXiv preprint arXiv:1810.04805* (2018).
- [33] Yinhan Liu et al. “RoBERTa: A Robustly Optimized BERT Pretraining Approach”. En: *arXiv preprint arXiv:1907.11692* (2019).
- [34] Marc Marone et al. “mmbert: A Modern Multilingual Encoder with Annealed Language Learning”. En: *arXiv preprint arXiv:2509.06888* (2025).

- [35] Rahul Mehta y Vasudeva Varma. “LLM-RM at SemEval-2023 Task 2: Multilingual Complex NER using XLM-RoBERTa”. En: *Proceedings of the 17th International Workshop on Semantic Evaluation (SemEval-2023)*. 2023, págs. 453-456.
- [36] Xinyang Zhang et al. “TwHIN-BERT: A Socially-Enriched Pre-trained Language Model for Multilingual Tweet Representations at Twitter”. En: *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. 2023, págs. 5597-5607.
- [37] Ismael Garrido-Muñoz, Fernando Martínez-Santiago y Arturo Montejo-Ráez. “MarIA and BETO are sexist: evaluating gender bias in large language models for Spanish”. En: *Language Resources and Evaluation* 58.4 (2024), págs. 1387-1417.
- [38] Javier De la Rosa et al. “BERTIN: Efficient Pre-Training of a Spanish Language Model using Perplexity Sampling”. En: *arXiv preprint arXiv:2207.06814* (2022).
- [39] Juan Manuel Pérez et al. “RoBERTuito: a pre-trained language model for social media text in Spanish”. En: *Proceedings of the Thirteenth Language Resources and Evaluation Conference*. 2022, págs. 7235-7243.
- [40] Dat Quoc Nguyen, Thanh Vu y Anh-Tuan Nguyen. “BERTweet: A pre-trained language model for English Tweets”. En: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. 2020, págs. 9-14.
- [41] Kevin Clark et al. “ELECTRA: Pre-training Text Encoders as Discriminators Rather Than Generators”. En: *arXiv preprint arXiv:2003.10555* (2020).
- [42] Wayne Xin Zhao et al. “A Survey of Large Language Models”. En: *arXiv preprint arXiv:2303.18223* (2023).
- [43] Katikapalli Subramanyam Kalyan. “A survey of GPT-3 family large language models including ChatGPT and GPT-4”. En: *Natural Language Processing Journal* 6 (2024), pág. 100048.
- [44] Hakan Inan et al. “Llama Guard: LLM-based Input-output Safeguard for Human-AI Conversations”. En: *arXiv preprint arXiv:2312.06674* (2023).
- [45] Hao Peng, Roy Schwartz y Noah A Smith. “PaLM: A Hybrid Parser and Language Model”. En: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*. 2019, págs. 3644-3651.
- [46] Tim Dettmers et al. “QLoRA: Efficient Finetuning of Quantized LLMs”. En: *arXiv preprint arXiv:2305.14314* (2023).
- [47] Albert Q Jiang et al. “Mistral 7B”. En: *arXiv preprint arXiv:2310.06825* (2023).
- [48] Abhimanyu Dubey et al. “The Llama 3 Herd of Models”. En: *arXiv preprint arXiv:2407.21783* (2024).
- [49] Gemma Team et al. “Gemma 2: Improving Open Language Models at a Practical Size”. En: *arXiv preprint arXiv:2408.00118* (2024).
- [50] Joao Carreira y Andrew Zisserman. “Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset”. En: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017, págs. 6299-6308.

- [51] Alexey Dosovitskiy et al. "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale". En: *arXiv preprint arXiv:2010.11929* (2020).
- [52] Ze Liu et al. "Swin Transformer: Hierarchical Vision Transformer using Shifted Windows". En: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, págs. 10012-10022.
- [53] Zhuang Liu et al. "A ConvNet for the 2020s". En: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2022, págs. 11976-11986.
- [54] Kaiming He et al. "Deep Residual Learning for Image Recognition". En: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, págs. 770-778.
- [55] Gedas Bertasius, Heng Wang y Lorenzo Torresani. "Is Space-Time Attention All You Need for Video Understanding?" En: *Proceedings of the 38th International Conference on Machine Learning (ICML)*. PMLR. 2021, págs. 813-824.
- [56] Anurag Arnab et al. "ViViT: A Video Vision Transformer". En: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, págs. 6836-6846.
- [57] Zhan Tong et al. "VideoMAE: Masked Autoencoders are Data-Efficient Learners for Self-Supervised Video Pre-training". En: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 35. 2022, págs. 10078-10093.
- [58] Sinno Jialin Pan y Qiang Yang. "A Survey on Transfer Learning". En: *IEEE Transactions on Knowledge and Data Engineering* 22.10 (2009), págs. 1345-1359.
- [59] Xipeng Qiu et al. "Pre-trained Models for Natural Language Processing: A Survey". En: *Science China Technological Sciences* 63.10 (2020), págs. 1872-1897.
- [60] Jeremy Howard y Sebastian Ruder. "Universal Language Model Fine-tuning for Text Classification". En: *arXiv preprint arXiv:1801.06146* (2018).
- [61] Jesse Dodge et al. "Fine-Tuning Pretrained Language Models: Weight Initializations, Data Orders, and Early Stopping". En: *arXiv preprint arXiv:2002.06305* (2020).
- [62] Takuya Akiba et al. "Optuna: A Next-generation Hyperparameter Optimization Framework". En: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 2019, págs. 2623-2631.
- [63] Omer Sagi y Lior Rokach. "Ensemble Learning: A Survey". En: *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery* 8.4 (2018), e1249.
- [64] Dhanesh Ramachandram y Graham W Taylor. "Deep Multimodal Learning: A Survey on Recent Advances and Trends". En: *IEEE Signal Processing Magazine* 34.6 (2017), págs. 96-108.
- [65] Barbara Plank. "The "Problem" of Human Label Variation: On Ground Truth in Data, Modeling and Evaluation". En: *arXiv preprint arXiv:2211.02570* (2022).
- [66] Valerio Basile et al. "We Need to Consider Disagreement in Evaluation". En: *Proceedings of the 1st Workshop on Benchmarking: Past, Present and Future*. 2021, págs. 15-21.
- [67] Ameet Deshpande et al. "Toxicity in ChatGPT: Analyzing Persona-assigned Language Models". En: *arXiv preprint arXiv:2304.05335* (2023).

-
- [68] Marina Sokolova y Guy Lapalme. “A Systematic Analysis of Performance Measures for Classification Tasks”. En: *Information Processing & Management* 45.4 (2009), págs. 427-437.
 - [69] Grigorios Tsoumakas y Ioannis Katakis. “Multi-Label Classification: An Overview”. En: *International Journal of Data Warehousing and Mining (IJDWM)* 3.3 (2007), págs. 1-13.
 - [70] Enrique Amigo y Agustín Delgado. “Evaluating Extreme Hierarchical Multi-label Classification”. En: *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. 2022, págs. 5809-5819.

A.1. Aplicación Web para la Visualización y Prueba del Modelo

Como culminación del presente Trabajo de Fin de Máster, se ha desarrollado y desplegado una aplicación web interactiva que ejecuta el sistema multimodal completo (*Ensemble* mediante *Late Fusion*). Esta herramienta permite clasificar nuevas instancias de vídeo en tiempo real.

Para superar las limitaciones de memoria VRAM (15 GB) de los entornos gratuitos y evitar el colapso del sistema, se ha diseñado una arquitectura inteligente de carga secuencial y liberación dinámica de memoria. Esto permite ejecutar iterativamente modelos masivos que, en un despliegue estático tradicional, requerirían infraestructura de alto coste.

Arquitectura y Tecnologías Utilizadas

Para hacer viable el despliegue del sistema *Ensemble* completo (combinando *Mistral*, *ConvNeXt* y *TimeSFormer*), la aplicación utiliza una arquitectura puente que separa el *backend* de cómputo del *frontend* de visualización:

- **Backend y Cómputo (*Google Colab*):** El núcleo de procesamiento se ejecuta en un entorno de *Google Colab* equipado con una *GPU NVIDIA T4*, montando *Google Drive* para la carga local de los pesos de los modelos. Aquí se ejecuta la lógica pesada y la cuantización de *Mistral-7B* en 4-bits mediante *QLoRA*.
- **Túnel de Conexión (*Gradio*):** Mediante la librería *Gradio*, el entorno de Colab genera un túnel inverso temporal (URL pública `.gradio.live`) que expone la interfaz interactiva hacia el exterior.
- **Frontend Estático (*Hugging Face Spaces*):** Para dotar al proyecto de una URL institucional y permanente, se ha habilitado un *Space* en *Hugging Face*. Dicho espacio funciona como un contenedor estático (mediante un archivo `index.html`) que embebe la interfaz generada por Colab. Por tanto, el cómputo masivo no recae sobre los limitados servidores de Hugging Face, sino sobre la GPU de Google.

Esta arquitectura implica que la disponibilidad de la aplicación está sujeta a que el cuaderno de ejecución en *Google Colab* se encuentre activo.

Acceso a la Aplicación y Código Fuente

La herramienta se encuentra vinculada para su visualización desde cualquier navegador web estándar en la siguiente URL:

<https://huggingface.co/spaces/visumania2/DeepSexist-App>

Asimismo, con el fin de garantizar la transparencia y reproducibilidad de esta investigación, el código fuente completo del proyecto está alojado en un repositorio público. Este repositorio contiene los cuadernos de entrenamiento originales (incluyendo el historial de versiones), los *scripts* de gestión del *dataset* y los cuadernos de despliegue de esta misma aplicación (omitendo los datos audiovisuales restringidos por la competición):

<https://github.com/visumania/DeepSexist>

Manual de Usuario

El uso de la aplicación consta del siguiente flujo simplificado:

1. Acceder a la URL habilitada.
2. Cargar un archivo de vídeo (*.mp4*, *.avi*) en el componente principal de la pantalla.
3. Pulsar el botón “Ejecutar Pipeline Multimodal”.
4. El sistema procesará de forma automatizada las vías requeridas: transcripción de audio a texto, *mean-pooling* de 4 fotogramas visuales y análisis de la matriz del movimiento.
5. Tras el procesado, se visualizarán las probabilidades de sexismo independientes de cada modelo y el resultado final calculado por la suma ponderada del *Ensemble* (35 % texto, 55 % imagen y 10 % vídeo).

Ejemplo de Uso

A continuación, se detalla un caso de uso práctico procesado por el *Ensemble*:

- **Vídeo introducido:** Clip de 15 segundos con un discurso basado en roles tradicionales.

- **Transcripción automática (*Whisper*):** “*El lugar de las mujeres está en casa, no en una oficina dirigiendo empresas*”.
- **Modelo Texto (*Mistral-35 %*):** Probabilidad de Sexismo: 98.20 %.
- **Modelo Imagen (*ConvNeXt-55 %*):** Probabilidad de Sexismo: 62.40 %.
- **Modelo Vídeo (*TimeSFormer-10 %*):** Probabilidad de Sexismo: 71.00 %.
- **Resultado Final (*Ensemble*):** Probabilidad del *Ensemble*: 75.79 %. Resultado final: **SEXISTA**.

Capturas de Pantalla

A continuación, en la [Figura A.1](#) se muestra el aspecto visual de la aplicación web en funcionamiento:




Figura A.1: Interfaz web desarrollada con Gradio alojada mediante un *iframe* en *Hugging Face Spaces*.